2026학년도 2학기 인문데이터 수량분석

제2강 R 프로그래밍

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 9월 7일 월요일

오늘의 목표

1. Posit Cloud에서 RStudio를 열고 R 코드를 실행할 수 있다.
2. 객체, 함수, 자료형 등 R의 기본 문법을 설명할 수 있다.
3. CSV 파일을 R로 불러와 어떤 자료인지 확인할 수 있다.
4. R Markdown 문서를 만들어 Knit할 수 있다.

사전 준비

1. Posit Cloud 무료 계정 — `https://posit.cloud/plans/free`
2. 교재 자료(코드 + 데이터) 내려받기
   - `https://humanitiesdata.org/humanities_data_r_2e_code.zip`

1 **왜 R인가?**
탐색적 자료 분석
R이라는 언어

2 실습 환경 만들기

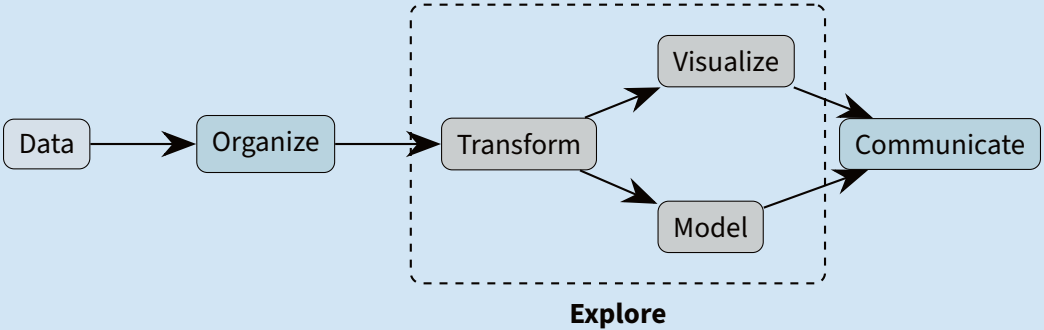
3 R 기본 문법

4 데이터 불러오기

5 R Markdown

6 마무리

탐색적 자료 분석(EDA)의 흐름



이 학기의 지도

3–5강은 **Organize**와 **Explore**, 6강은 **Data**, 8–16강은 데이터 유형별 **Explore**를 다룬다.

탐색적 자료 분석이란?

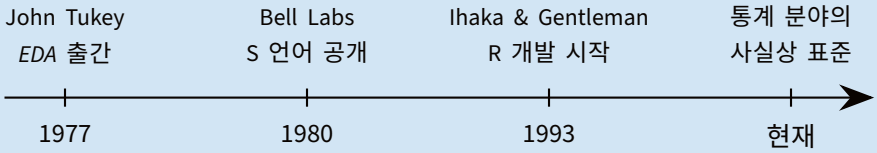
Exploratory Data Analysis (John Tukey, 1977)

- 시각화와 요약 통계로 데이터를 **직접** 들여다보는 접근
- 가설을 검정하기 전에 **가설을 만들어 내는** 것이 목적
- 형식적 통계 모형화 **이전에**, 또는 그것을 **대신하여** 수행

인문학 연구에서 EDA가 잘 맞는 이유

- 인문학의 질문은 대개 “이 가설이 참인가”보다 “여기서 무엇이 보이는가”에 가깝다.
- 자료가 지저분하고(messy) 복잡해서, 모형을 세우기 전에 자료를 알아야 한다.
- 자료의 양과 복잡성이 커질수록 눈으로 훑는 것만으로는 부족해진다.

R과 EDA는 함께 자랐다



왜 이름이 "R"인가?

- 알파벳에서 S의 **바로 앞 글자**
- 두 개발자 이름의 첫 글자 (**R**oss, **R**obert)

이 강의가 R을 쓰는 이유

- 무료이고 완전한 오픈소스
- 통계와 시각화가 언어에 내장
- 디지털 인문학 패키지 생태계

1 왜 R인가?

2 **실습 환경 만들기**
Posit Cloud와 RStudio
자료와 패키지

3 R 기본 문법

4 데이터 불러오기

5 R Markdown

6 마무리

두 가지 길

	Posit Cloud	**RStudio Desktop**
설치	필요 없음 (웹 브라우저)	R + RStudio 각각 설치
인터넷	반드시 필요	없어도 됨
성능	무료 요금제는 제한적	내 컴퓨터 성능만큼
파일	클라우드에 보관	내 컴퓨터에 보관
사용 시간	무료 요금제는 월 사용량 제한	제한 없음

이 강의의 방침

- **수업 시간**: Posit Cloud로 통일한다 (모두 같은 화면을 본다).
- **과제**: 둘 중 무엇을 써도 좋다. 결과가 같으면 된다.

⚠ 무료 요금제는 사용량 제한이 있으니 RStudio Desktop도 설치해 두기를 권한다.

Posit Cloud 시작하기

계정 만들기

1. `https://posit.cloud/plans/free` 접속 후 `Sign Up`
2. 구글 계정 또는 이메일로 가입 (**학교 이메일 권장**)

새 프로젝트 만들기

1. 왼쪽 `Your Workspace` 선택
2. 오른쪽 위 `New Project` ➔ `New RStudio Project`
3. 잠시 기다리면 브라우저 안에 RStudio 화면이 열린다.
4. 왼쪽 위 프로젝트 이름(`Untitled Project`)을 눌러 `qah-2026`으로 바꾼다.

💡 프로젝트 하나가 **폴더 하나**다. 이 강의의 파일은 모두 이 프로젝트 안에 둔다.

RStudio 화면 구성

Source (편집기)

.Rmd/.R 파일을 쓰는 곳

저장되는 것은 여기뿐

Environment

지금 만들어 둔 객체 목록

클릭하면 표로 볼 수 있다

Console (콘솔)

코드가 실제로 실행되는 곳

한 줄짜리 시험용

Files / Plots / Help

파일 목록, 그림, 도움말

패키지 설치 상태

콘솔에 쓴 코드는 **저장되지 않는다**. 과제에 낼 코드는 반드시 편집기(Source)에 쓴다.

교재 자료 올리기

내려받기 (내 컴퓨터)

`https://humanitiesdata.org/` ➔ `Code + Data`

- 내려받은 ZIP 파일은 압축을 풀지 **않은** 채로 둔다.

올리기 (Posit Cloud)

1. 오른쪽 아래 `Files` 탭 ➔ `Upload`
2. ZIP 파일 선택 ➔ `OK` (**자동으로 압축이 풀린다**)
3. 폴더 이름을 `hdr`로 바꾼다 (선택 ➔ `Rename`).
4. `hdr/data/`에 `acs_cbsa.csv`가 보이면 성공.

패키지 설치하기

```r
# 설치: 딱 한 번만 (컴퓨터에 내려받기)
install.packages("tidyverse")

# 불러오기: R을 켤 때마다 (거내 쓰기)
library(tidyverse)
```

패키지란?

다른 사람이 만들어 공개한 **함수 꾸러미**.
R의 가장 큰 장점이다.

tidyverse: 이 강의가 쓰는 메타패키지

- **readr** 데이터 읽기 (read_csv) — 2강
- **ggplot2** 시각화 — 3강
- **dplyr** 데이터 걸러 내기와 요약 — 4강
- **tidyr** 표의 형태 바꾸기 — 5강

💡 install.packages는 **따옴표 필요**, library는 **따옴표 없이**도 된다.

1 왜 R인가?

2 실습 환경 만들기

3 R 기본 문법
- 계산과 객체
- 벡터와 자료형
- 함수
- 오류와 코드 형식

4 데이터 불러오기

5 R Markdown

6 마무리

R을 계산기로 써 보기

```
1 1 + 1
[1] 2
1 seq(1, 100)
 [1]   1   2   3   4   5   6   7
 [8]   8   9  10  11  12  13  14
[15]  15  16  17  18  19  20  21
...
```

[1]은 무슨 뜻인가?

- 그 줄의 **첫 값이 몇 번째 값인지**를 세어 주는 것일 뿐
- [15] = 이 줄은 15번째 값부터 시작
- 계산 결과와는 아무 상관이 없다

객체 만들기

```r
# 화살표 <- 로 이름을 붙인다
mynum <- 3 + 5
```

(출력 없음: 결과가 저장되었다)

```r
mynum + 1
```

```
[1] 9
```

객체(object)에는 무엇이든 담긴다

수치, 문자, 데이터셋, 그림, 함수, 모형

R에서 이름을 짓는 규칙

- 반드시 **문자**로 시작
- 밑줄 _과 마침표 . 사용 가능
- ✓ 소문자 + 밑줄: `my_data`
- ✗ 대문자 섞기: `MyData`

어디에 대문자를 썼는지 기억할 필요가 없어진다.

여러 값을 한 덩어리로: 벡터

```r
# c() = combine
years <- c(1443, 1446, 1447)
years
```

```
[1] 1443 1446 1447
```

```r
years - 1392
```

```
[1] 51 54 55
```

한꺼번에 계산된다

벡터에 수치 하나를 빼면 **모든 값**에 적용된다. 반복문 없이 표 전체를 다루는 R의 기본 방식이다.

한 벡터 = 한 자료형

```r
c(1443, "세종")
```

```
[1] "1443" "세종"
```

수치가 조용히 문자로 바뀐다. ⚠

자료형(data type)

자료형	표시	설명	예
character	<chr>	문자열: 글자, 숫자, 공백, 문장부호	"세종", "NE"
double	<dbl>	소수점을 포함할 수 있는 수	20.0, 1051.2
integer	<int>	정수	1, 146

용어 정리

- **string**(문자열) = character 값
- **numeric**(수치) = double + integer
- 논리값(<lgl>)과 날짜(<date>)는 뒤에서 다룬다.

왜 중요한가?

자료형에 따라 **그릴 수 있는 그래프**와 **할 수 있는 계산**이 달라진다. 3–4강에서 바로 쓰인다.

함수와 인자

일반 형태

`함수이름(인자1 = 입력1, 인자2 = 입력2)`

인자(argument)의 이름은 정해져 있고, **입력**(input)은 우리가 준다.

```r
# 이름으로 지정 (순서 무관)
seq(from = 1, to = 10)

# 위치로 지정 (순서가 중요!)
seq(1, 10)

# 선택적 인자 by 추가
seq(from = 1, to = 10, by = 0.5)
```

```
 [1]  1.0  1.5  2.0  2.5  3.0
 [6]  3.5  4.0  4.5  5.0  5.5
[11]  6.0  6.5  7.0  7.5  8.0
[16]  8.5  9.0  9.5 10.0
```


처음에는 **이름으로 지정**하는 습관을 들이면 실수가 줄어든다.

모르는 함수 앞에서: 도움말

```
# 물음표 + 함수 이름
?seq

# 이름이 기억나지 않을 때
??sequence
```

어디에 뜨는가

RStudio 오른쪽 아래 Help 탭

도움말 페이지 읽는 순서

Description 이 함수가 무엇을 하는가

Usage 인자의 이름과 기본값

Arguments 각 인자의 의미 → **여기를 본다**

Value 무엇을 돌려주는가

Examples 실행 가능한 예제 → **복사해서 돌려 본다**

오류 메시지는 적이 아니다

Error와 Warning은 다르다

Error 실행이 **멈췄다**. 고쳐야 한다.

Warning 실행은 **되었다**. 결과가 의도와 같은지 확인한다.

입문자가 가장 자주 만나는 세 가지 문제

`could not find function` `library(tidyverse)` 등 패키지 로드를 안 했다.

`object not found` 이름을 잘못 썼거나(대소문자!), 이름을 정의한 줄을 아직 실행하지 않았다.

맨 앞이 `+` 괄호나 따옴표가 닫히지 않았다. `Esc`로 빠져나온다.

💡 오류 메시지를 **그대로 복사해서** 검색하거나 eTL Q&A에 올린다.

코드 형식 (교재 1.8)

✓ **좋은 형식**

```
mynum <- 3 + 5
seq(from = 1, to = 10, by = 0.5)
cbsa <- read_csv(
  file.path("hdr", "data",
            "acs_cbsa.csv")
)
```

✗ **나쁜 형식**

```
mynum<-3+5
seq(from=1 ,to=10 ,by=0.5)
cbsa<-read_csv(file.path("hdr",
"data","acs_cbsa.csv"))
```

네 가지 규칙

1. =와 <- 앞뒤에 공백 하나씩
2. 쉼표 **뒤**에만 공백
3. +, * 앞뒤에 공백
4. 줄이 길면 인자 단위로 줄을 바꾸고 두 칸 들여쓴다

💡 형식은 **읽는 사람**을 위한 것이다.

1 왜 R인가?

2 실습 환경 만들기

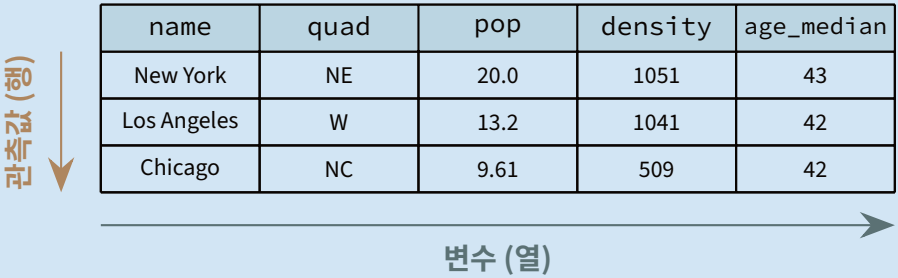
3 R 기본 문법

4 **데이터 불러오기**
표 형식 데이터
이 학기에 쓸 데이터

5 R Markdown

6 마무리

표 형식 데이터(tabular data)



name	quad	pop	density	age_median
New York	NE	20.0	1051	43
Los Angeles	W	13.2	1041	42
Chicago	NC	9.61	509	42

관측값(observation)

하나의 사례. 여기서는 **대도시권 하나**.

변수(variable)

각 사례에 대해 잰 값. 여기서는 인구, 밀도, 나이 중앙값 등.

CSV 파일 읽기

```
1 library(tidyverse)
2
3 cbsa <- read_csv(file.path("hdr", "data", "acs_cbsa.csv"))
4 cbsa
```

```
# A tibble: 934 x 13
   name         geoid quad    lon   lat   pop density
   <chr>        <dbl> <chr> <dbl> <dbl> <dbl>   <dbl>
 1 New York     35620 NE     -74.1  40.8 20.0    1051.
 2 Los Angeles 31080 W    -118.   34.2 13.2    1041.
 3 Chicago      16980 NC     -88.0  41.7  9.61    509.
# i 924 more rows
# i 6 more variables: age_median <dbl>, hh_income_median <dbl>, ...
```

➔ 934개의 **관측값**과 13개의 **변수**. 이름 위의 <chr>, <dbl>이 자료형이다.

file.path()와 tibble

왜 file.path()를 쓰는가

```
1 file.path("hdr", "data", "x.csv")
[1] "hdr/data/x.csv"
```

Windows와 macOS는 폴더 구분 기호가 다르다. 이 함수를 쓰면 **어느 컴퓨터에서든** 같은 코드가 동작한다.

tibble이란

- tidyverse가 쓰는 표 형식 객체
- 첫 10행만 보여 준다
- 자료형을 함께 표시한다
- Environment 탭에서 클릭하면 전체를 표로 볼 수 있다

파일을 못 찾는다는 오류가 나면, Files 탭에서 **폴더 이름부터** 확인한다.

교재의 세 가지 핵심 데이터셋

한 학기 내내 다시 만나게 될 자료

`acs_cbsa.csv`	미국 대도시권 934곳의 인구 · 소득 · 임대료 (3–5강)
`food_prices.csv`	13개 품목의 상대 가격 146년치 (5강, 11–12강)
`wiki_uk_meta.csv.gz`	영국 작가 75인의 위키백과 자료 (8–10강)

왜 이 자료들인가

- 대도시권은 행정 구역이 아니라 **사회적 통합도**로 정의된 단위다.
- 물가는 숫자로 읽는 생활사이자 무역사다.
- 위키백과 자료 하나를 텍스트 ➔ 네트워크 ➔ 시간 순으로 겹쳐 읽는다.

한국의 데이터

공개 아카이브 몇 가지

한국사데이터베이스 국사편찬위원회. 조선왕조실록, 승정원일기 등 원문과 번역
- https://db.history.go.kr/

모두의 말뭉치 국립국어원. 현대 한국어 말뭉치 (연구용 신청)
- https://corpus.korean.go.kr/

공공데이터포털 행정안전부. 문화재, 도서관, 지명 등
- https://www.data.go.kr/

6강 「데이터 수집」에서 **내 연구 질문에 맞는 표를 직접 만드는** 방법을 배운다. 그때 위 아카이브를 다시 쓴다.

1 왜 R인가?

2 실습 환경 만들기

3 R 기본 문법

4 데이터 불러오기

5 **R Markdown**
코드와 글을 한 문서에

6 마무리

.Rmd 파일의 구조

````
---
title: "숙제02"
author: "박수민"
output: html_document
---

## 자료 불러오기

```{r}
library(tidyverse)
cbsa <- read_csv("hdr/data/acs_cbsa.csv")
```

표에는 934개의 관측값이 있다.
````

세 부분

YAML 맨 위 --- 사이. 제목, 저자, 출력 형식

텍스트 마크다운 문법으로 쓰는 설명

코드 청크 ```{r} 과 ``` 사이

실행하는 법

청크 오른쪽 위 **녹색 삼각형**(→ Run) 클릭. 결과가 청크 바로 아래에 나타난다.

Knit: 하나의 문서로 굽기



저장되는 것은 글과 코드뿐

그림과 표는 저장되지 않는다. 파일이 작고 깔끔해지며, 결과는 **언제든 다시 만들 수 있다**.

재현 가능성(reproducibility)

Knit은 **빈 상태에서** 코드를 처음부터 다시 돌린다. Knit이 되면 남의 컴퓨터에서도 돌아간다.

과제는 `.Rmd` 파일로 제출한다. **Knit이 오류 없이 되어야** 채점 대상이다.

1 왜 R인가?

2 실습 환경 만들기

3 R 기본 문법

4 데이터 불러오기

5 R Markdown

6 **마무리**

오늘 배운 것

환경

- Posit Cloud + RStudio 네 칸
- `install.packages` vs. `library`
- 프로젝트 = 폴더 하나

문법

- 객체 `<-`, 벡터 `c()`
- 자료형 `<chr>` `<dbl>` `<int>`
- 함수와 인자, `?함수이름`

데이터

- 관측값(행)과 변수(열)
- `read_csv`, `file.path`, tibble

문서

- `.Rmd` = YAML + 텍스트 + 청크
- Knit ➔ 재현 가능성

확인 질문

스스로 답해 보기

1. `install.packages("tidyverse")`는 왜 한 번만 실행하면 되고, `library(tidyverse)`는 왜 R을 켤 때마다 실행해야 하는가?
2. 출력 `[15]`는 15라는 값을 뜻하는가? 아니라면 무엇을 뜻하는가?
3. `c(1443, "세종")`의 자료형은 무엇이 되는가? 왜 그런가?
4. 콘솔에 쓴 코드와 편집기에 쓴 코드는 무엇이 다른가?
5. Knit이 성공한다는 것은 무엇을 보장해 주는가?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간에 배울 것

- 제3강 탐색적 자료 분석 (1): 그래픽 문법 [교재 2장]
  - `ggplot2`로 산점도 그리기
  - 데이터의 열을 그림의 위치·색·크기에 연결하기

다음 시간까지 할 일

1. Posit Cloud 프로젝트에 `hdr` 폴더가 올라가 있는지 확인하기
2. `library(tidyverse)`가 오류 없이 실행되는지 확인하기

❗ 문제가 있는 경우 eTL Q&A에 올리자.

[숙제02] 산점도 그리기 (3점)

- 파일명: `hw02-2026-00000.Rmd`
  - `2026-00000`은 자신의 학번으로 바꿀 것
  - 파일명의 대소문자, 하이픈 등이 서식에 어긋나면 감점
- 제출 기한: 2026-09-14 09:00 (월요일 오전 9시) eTL
- 3강(09/09) 내용까지 필요하다. 자세한 안내는 eTL 공지 참조.

❗ Knit이 오류 없이 되는지 반드시 확인하고 제출할 것!