2026학년도 2학기 인문데이터 수량분석

제3강 탐색적 자료 분석 (1)

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 9월 9일 수요일

오늘의 목표

1. 그래픽 문법의 세 요소(데이터, 미학 매핑, 기하 객체)를 설명할 수 있다.
2. `ggplot2`로 산점도, 선그래프, 막대그래프를 그릴 수 있다.
3. 데이터의 열을 색과 크기에 대응시켜 정보를 한 겹 더 얹을 수 있다.
4. 스케일과 라벨을 다듬어 발표에 쓸 수 있는 그림으로 만들 수 있다.

사전 준비

1. Posit Cloud의 `qah-2026` 프로젝트를 연다.
2. `hdr/data/`에 `acs_cbsa.csv`와 `food_prices.csv`가 있는지 확인한다.
3. 콘솔에서 `install.packages("ggrepel")`을 실행해 둔다.

1 **왜 그림을 그리는가**
요약 통계의 한계
그래픽 문법

2 첫 그림 그리기

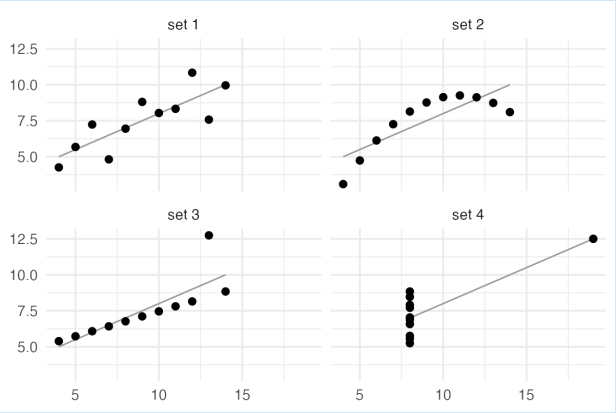
3 기하 객체 바꾸기

4 미학 매핑 더하기

5 스케일, 라벨, 테마

6 마무리

같은 수치, 다른 자료



네 자료의 요약 통계

- **평균**: x는 9, y는 7.50
- **표준편차**: 3.32와 2.03
- **상관계수**: 0.816
- **회귀직선**: 같음

네 자료가 **모두 같다**.

그림을 그리기 전까지는 무엇을 다루고 있는지 알 수 없다.

- Anscombe(1973)의 네 자료. R에 anscombe이라는 이름으로 들어 있다.

시각화가 EDA에서 하는 일

교재가 시각화부터 시작하는 세 가지 이유

1. **즉각적인 보상**: 코드 몇 줄로 자료의 모양이 곧바로 보인다.
2. **코드 검증**: 결과 그림이 예상과 다르면 코드가 틀렸다는 뜻이다. 프로그래밍을 처음 배우는 사람에게 특히 중요하다.
3. **규모 무관**: 자료가 아주 작아도, 아주 커도 쓸모가 있다.

인문학 자료에서는 더욱

- 인문학의 자료는 대개 지저분하고, 결측이 많고, 범주가 고르지 않다.
- 평균 하나로 뭉뚱그리면 사라지는 것들(예외, 이상치, 군집)이 곧 **연구 질문의 출발점**인 경우가 많다.

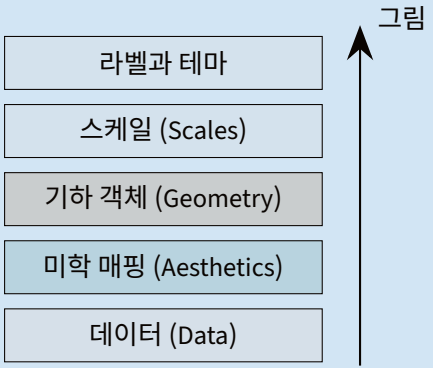
그래픽 문법(grammar of graphics)

핵심 아이디어

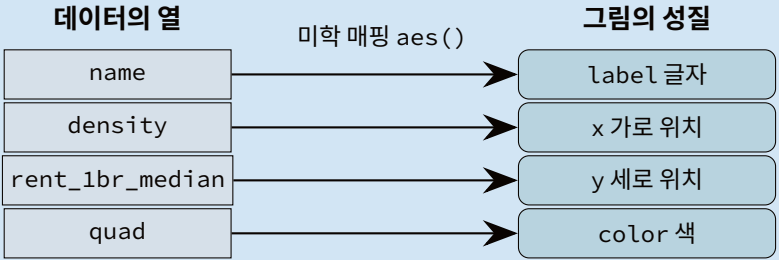
그림은 서로 독립적인 **층(layer)**을 쌓아 만든다. 단어를 규칙에 따라 이어 붙여 문장을 만드는 것과 같다.

왜 "문법"인가

- 그림 종류마다 따로 배우지 않는다.
- 층을 바꿔 끼우면 다른 그림이 된다.
- ⚠ 대신 처음 배울 때가 조금 가파르다.



한 층을 만드는 데 필요한 것



데이터

어느 표를 쓸 것인가

미학 매핑

어느 열을 어느 성질에 이을 것인가

기하 객체

각 행을 무엇으로 그릴 것인가

1 왜 그림을 그리는가

2 **첫 그림 그리기**
산점도
텍스트 기하 객체

3 기하 객체 바꾸기

4 미학 매핑 더하기

5 스케일, 라벨, 테마

6 마무리

오늘의 자료 (1): cbsa

미국 대도시권(CBSA) 934곳

행정 구역이 아니라 **큰 인구 중심지와 그에 긴밀히 통합된 주변 지역**을 묶은 단위다. 경계가 정치가 아니라 생활로 그어져 있다. 미국 인구조사국의 **American Community Survey**(2021년 5년 요약)에서 왔고, **한 행이 대도시권 하나**, 열은 13개다.

열	담고 있는 값	열	담고 있는 값
`name`, `geoid`	이름과 고유 번호	`age_median`	나이 중앙값
`lon`, `lat`	중심의 경도와 위도	`hh_income_median`	가구 소득 중앙값(달러)
`quad`	방위(NE, NC, S, W, O)	`percent_own`	자가 거주 가구 비율(%)
`division`	지역 구분 9개	`rent_1br_median`	원룸 월세 중앙값(달러)
`pop`	인구(백만 명)	`rent_perc_income`	소득 대비 월세 비율(%)
`density`	인구 밀도(km^2 당)		

💡 quad의 O는 본토 밖(하와이, 알래스카, 푸에르토리코)이다.

자료 준비하기

```r
library(tidyverse)

cbsa <- read_csv(file.path("hdr", "data", "acs_cbsa.csv"))
cbsa <- slice_head(cbsa, n = 30)    # 인구가 가장 많은 30곳만 남긴다
```

```
# A tibble: 30 x 4
  name         quad  density rent_1br_median
  <chr>        <chr>   <dbl>           <dbl>
1 New York     NE      1051.            1430
2 Los Angeles W       1041.            1468
3 Chicago      NC       509.            1060
# i 27 more rows
```

왜 30곳만 남기는가

934곳을 모두 그리면 점이 뭉개진다.
`slice_head()`는 4강에서 배운다.

오늘 쓸 네 개의 열

`name`(이름), `quad`(방위),
`density`(인구 밀도),
`rent_1br_median`(원룸 임대료)

첫 산점도: 코드 읽기

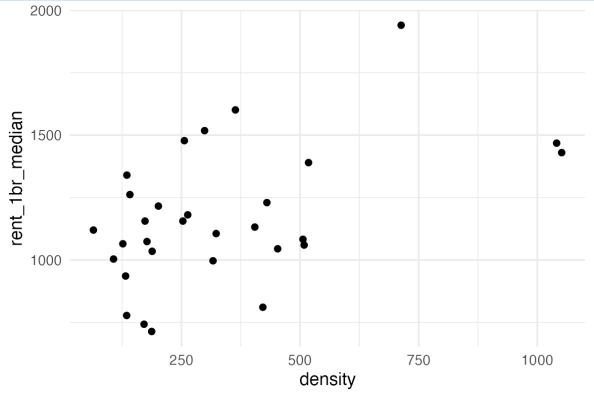
```
cbsa |>
  ggplot() +
    geom_point(aes(x = density, y = rent_1br_median))
```

한 줄씩

`cbsa |>`	이 표를 다음 함수에 넘긴다 (파이프)
`ggplot()`	빈 도화지를 편다
`+`	층을 하나 얹는다
`geom_point()`	각 행을 **점 하나**로 그린다
`aes()`	density는 가로 위치, rent_1br_median은 세로 위치

층을 잇는 것은 +이지 |>가 아니다. 가장 흔한 오류다.

첫 산점도: 결과 읽기



R이 알아서 정한 것

축의 범위, 눈금, 격자선, 점의 색과 크기와 모양

무엇이 보이는가

- 뚜렷한 추세는 **없다**.
- 밀도는 높은데 임대료는 중간인 두 곳
- 유난히 비싼 도시 한 곳

💡 "관계가 없다"도 발견이다. 다만 **어느 도시인지** 알 수 없는 것이 답답하다.

점 대신 이름을 찍기

```
cbsa |>
  ggplot() +
    geom_text(aes(
      x = density,
      y = rent_1br_median,
      label = name
    ))
```

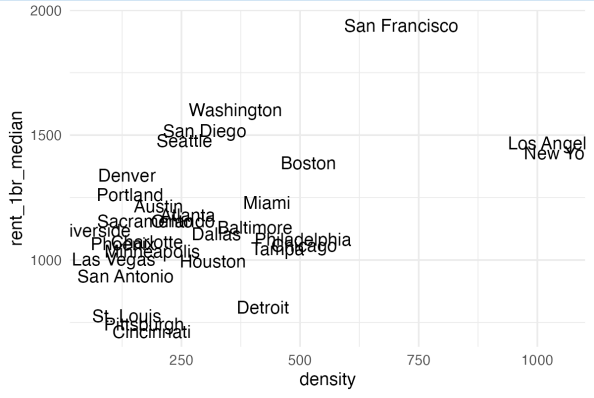
geom_text()

기하 객체를 바꾸면 `label`이라는 미학이 하나 더 필요해진다. 어느 열의 값을 글자로 쓸 것인가.

계산적 방법에 대한 흔한 비판

수치 패턴을 좇느라 개별 대상을 놓친다는 것. 라벨은 그 비판에 대한 하나의 답이다. 읽는 사람이 **자기가 아는 것**을 그림 위에 겹쳐 읽을 수 있게 해 준다.

글자가 겹친다



얻은 것

가장 비싼 곳(San Francisco), 가장 밀집한 곳(New York, Los Angeles)을 바로 짚을 수 있다.

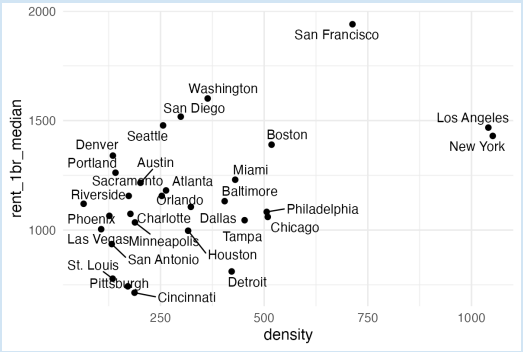
잃은 것

- 왼쪽 아래에서 글자가 겹친다.
- 가장자리 글자가 잘린다.
- 글자의 **어디**가 그 값인지 모호하다.

점과 라벨을 함께: ggrepel

```
library(ggrepel)

cbsa |>
  ggplot() +
    geom_point(aes(
      x = density,
      y = rent_1br_median
    )) +
    geom_text_repel(aes(
      x = density,
      y = rent_1br_median,
      label = name
    ))
```



✓ 층을 **두 개** 얹었다. 값은 점이, 이름은 글자가 맡는다.

1 왜 그림을 그리는가

2 첫 그림 그리기

3 **기하 객체 바꾸기**
선과 막대
어떤 그림을 고를까

4 미학 매핑 더하기

5 스케일, 라벨, 테마

6 마무리

오늘의 자료 (2): food_prices

```
# A tibble: 146 x 14
   year   tea sugar peanuts coffee cocoa wheat   rye  rice
  <dbl> <dbl> <dbl>   <dbl>  <dbl> <dbl> <dbl> <dbl> <dbl>
1  1870  129.  151.    203.   88.1  78.8  88.1  103.  83.5
2  1871  132.  167.    222.  109.   66.7 118.   105.  84.5
# i 144 more rows
# i 5 more variables: corn <dbl>, barley <dbl>, pork <dbl>,
#   beef <dbl>, lamb <dbl>
```

한 행이 한 해

1870–2015년 146년. 열 하나가 품목 하나다 — 차, 설탕, 땅콩, 커피, 코코아, 밀, 호밀, 쌀, 옥수수, 보리, 돼지고기, 소고기, 양고기.

값은 금액이 아니라 지수

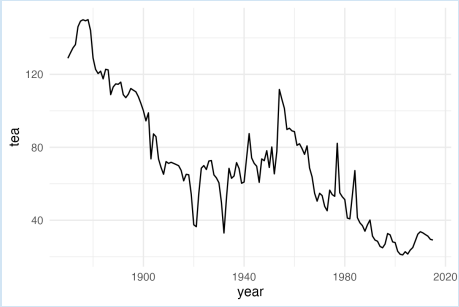
1900년 실질 가격을 100으로 놓은 값이다. 그래서 1900년 행은 열세 품목이 모두 정확히 100이다.

- 국제 시세(런던 도매가격, 세계은행 등)를 달러로 환산해 미국 소비자물가로 나눈 **실질** 가격이다. 어느 한 나라의 소매가가 아니다. (Jacks 2019, *Cliometrica* 13(2))

시간에 따른 변화: geom_line()

```
food_prices <- read_csv(
  file.path("hdr", "data",
            "food_prices.csv")
)

food_prices |>
  ggplot() +
    geom_line(aes(
      x = year, y = tea
    ))
```



그린 것

146개 행을 해 순서대로 이은 선. tea 자리를 sugar로 바꾸면 설탕 값이 그려진다.

가로축이 시간이고 값이 이어져 흐를 때 선을 쓴다.

선 하나를 역사로 읽기

그림에서 읽히는 것

- 1870년부터 1920년까지 **꾸준히** 내려간다.
- 1920–30년대에는 급락과 반등을 되풀이한다.
- 1950년대에 한 번 올랐다가, 이후 2015년까지 다시 길게 내려간다.

여기서 시작되는 질문

- 사치품이던 차는 언제부터 일상품이 되었는가?
- 값이 요동친 그 해에는 무슨 일이 있었는가?

➔ 그림은 답이 아니라 **어디를 들여다볼지**를 알려 준다. 답은 사료에서 찾아야 한다.

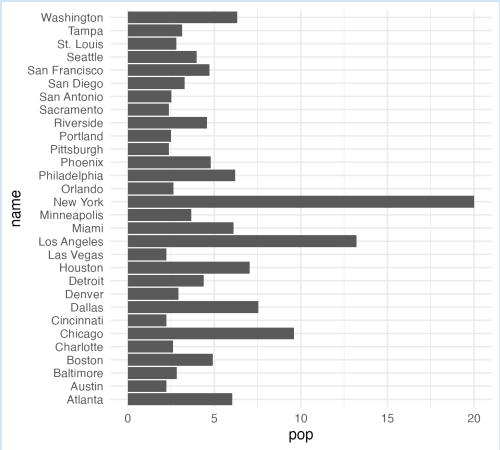
범주별 크기 비교: geom_col()

```
cbsa |>
  ggplot() +
    geom_col(aes(x = pop, y = name))
```

막대의 방향

- 범주를 x에 두면 세로 막대
- 범주를 y에 두면 가로 막대
- 이름이 길면 **가로**가 읽기 쉽다.

막대가 **알파벳 순**으로 늘어서 비교가 어렵다. 순서를 바꾸려면 그림이 아니라 **자료**를 손봐야 한다 (4강).



기하 객체 고르기

함수	그리는 것	필수 미학	쓰는 때
`geom_point()`	점	`x, y`	두 수치의 관계
`geom_line()`	선	`x, y`	시간에 따른 변화
`geom_col()`	막대	`x, y`	범주별 크기 비교
`geom_text()`	글자	`x, y, label`	개별 사례 식별

바뀌는 것은 한 단어뿐

`geom_point`를 `geom_line`으로 바꾸면 그림이 바뀐다. 나머지 코드는 그대로다. 이것이 "문법"의 힘이다.

더 있다

`ggplot2`에는 수십 개의 기하 객체가 있고, 다른 패키지가 계속 더한다. 필요할 때마다 이 강의에서 하나씩 만난다.

1 왜 그림을 그리는가

2 첫 그림 그리기

3 기하 객체 바꾸기

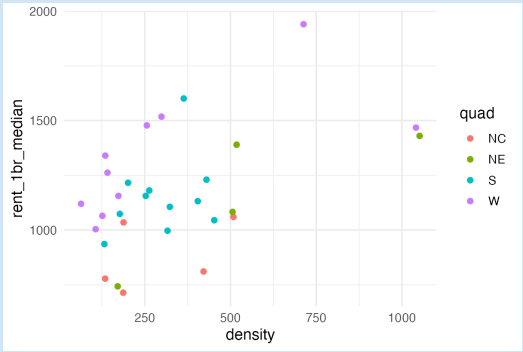
4 **미학 매핑 더하기**
선택적 미학

5 스케일, 라벨, 테마

6 마무리

색으로 한 겹 더: color

```
cbsa |>
  ggplot() +
    geom_point(aes(
      x = density,
      y = rent_1br_median,
      color = quad
    ))
```



한 단어의 값어치

`color = quad` 한 줄로 **세 번째 변수**가 그림에 들어왔고, 범례까지 자동으로 생겼다.

30곳 안에는 quad가 NE, NC, S, W 넷뿐이라 색도 넷이다.

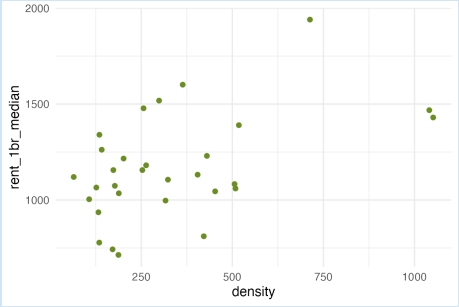
aes() 안이냐 밖이냐

열에 잇기 — aes() 안

```
geom_point(aes(
  x = density,
  y = rent_1br_median,
  color = quad
))
```

값을 고정하기 — aes() 밖

```
geom_point(aes(
  x = density,
  y = rent_1br_median
), color = "olivedrab")
```



❗ aes() 안은 “열 이름”, 밖은 “색 이름”이다. `aes(color = "olivedrab")`이라고 쓰면 모든 점이 **엉뚱한 한 가지 색**으로 칠해지고 쓸데없는 범례가 생긴다.

쓸 수 있는 미학들

미학	뜻	주로 쓰는 곳
`x, y`	가로/세로 위치	거의 모든 기하 객체 (필수)
`color`	선과 점, 글자의 색	범주 구분
`fill`	채우기 색	막대의 내부
`size`	점의 크기, 글자 크기	수치의 크기
`shape`	점의 모양	흑백 인쇄용 범주 구분
`alpha`	불투명도 (`1` = 불투명, `0` = 투명)	점이 겹칠 때

공통의 이름

기하 객체가 달라도 미학의 이름은 최대한 같게 지어져 있다. 한 번 익히면 계속 쓴다.

고정값으로 자주 쓰는 것

`alpha`와 `size`는 열에 잇기보다 `aes()` 밖에서 **고정값**으로 쓰는 일이 많다.

1 왜 그림을 그리는가

2 첫 그림 그리기

3 기하 객체 바꾸기

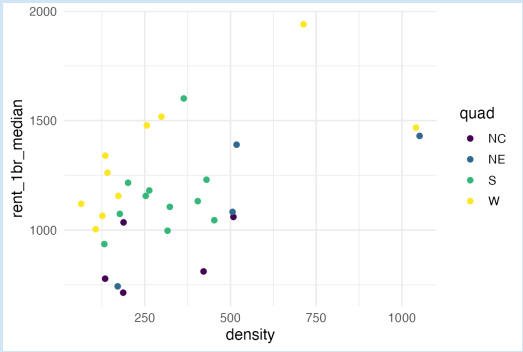
4 미학 매핑 더하기

5 **스케일, 라벨, 테마**
- 스케일
- 라벨과 테마
- 코드 쓰는 법

6 마무리

색을 바꾸기: scale_color_viridis_d()

```
cbsa |>
  ggplot() +
    geom_point(aes(
      x = density,
      y = rent_1br_median,
      color = quad
    )) +
    scale_color_viridis_d()
```



스케일이란

값을 실제로 **보이는 것**(색, 눈금, 범례)으로 옮기는 규칙. 관례상 기하 객체 뒤에 쓴다.

✓ 색각 이상, 흑백 인쇄, 낡은 프로젝터에서도 살아남는 배색이다.

_d와 _c

scale_color_viridis_d()

discrete — 문자열 같은 **범주**에 색을 하나씩 배정한다. (quad: NE, NC, S, W)

scale_color_viridis_c()

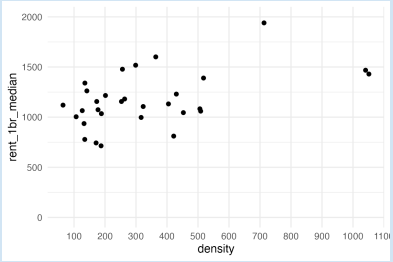
continuous — 수치의 크기에 따라 색을 연속으로 바꾼다. (pop: 2.2에서 20까지)

```
cbsa |>
  ggplot() +
    geom_point(aes(
      x = density, y = rent_1br_median, color = pop
    )) +
    scale_color_viridis_c()
```

⚠ 범례의 순서가 마음에 들지 않는가? 범주는 **알파벳 순**으로 놓인다. 바꾸려면 그림이 아니라 자료를 고쳐야 한다 (4강).

축을 손보기

```
cbsa |>
  ggplot() +
    geom_point(aes(
      x = density,
      y = rent_1br_median
    )) +
    scale_x_continuous(
      n.breaks = 10,
      minor_breaks = NULL
    ) +
    scale_y_continuous(
      limits = c(0, 2000)
    )
```



n.breaks 눈금 개수(대략)

minor_breaks 보조 격자선

limits 축의 시작과 끝

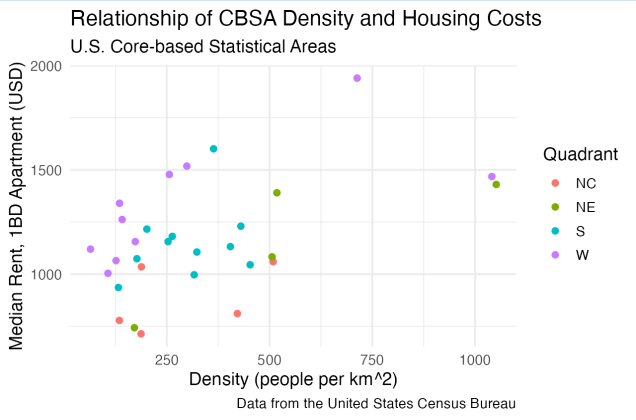
축의 범위는 **해석에 개입**한다. 0부터 그릴지 아닐지도 선택이다.

발표용으로 다듬기: labs()

```
cbsa |>
  ggplot() +
    geom_point(aes(x = density, y = rent_1br_median, color = quad)) +
    labs(
      x = "Density (people per km^2)",
      y = "Median Rent, 1BD Apartment (USD)",
      color = "Quadrant",
      title = "Relationship of CBSA Density and Housing Costs",
      subtitle = "U.S. Core-based Statistical Areas",
      caption = "Data from the United States Census Bureau"
    )
```

- 축과 범례의 이름은 물론 제목, 부제, 출처까지 여기서 붙인다.
- 지정하지 않은 항목은 기본값(열 이름)이 그대로 남는다.

라벨을 붙인 그림



언제 붙이는가

- **탐색 중**: 붙이지 않는다. 열 이름 그대로가 오히려 낫다.
- **남에게 보일 때**: 반드시 붙인다.

출처(caption)는 인문학 논문의 각주와 같다.

테마: 그림의 옷차림

```r
# 탐색용 (교재의 기본값)
theme_set(theme_minimal())

# 발표·출판용
install.packages("ggthemes")
library(ggthemes)
theme_set(theme_tufte())
```

테마가 바꾸는 것

축, 눈금, 격자선, 배경 — 즉 **자료가 아닌 모든 것**

`theme_tufte()`

Edward Tufte의 원칙: 잉크를 최대한 아껴 자료만 남긴다.

`theme_set()`은 한 번만 실행하면 이후의 **모든** 그림에 적용된다. `.Rmd`라면 맨 위 청크에 둔다.

반복 줄이기: 상속

✗ **같은 말을 두 번 쓰고 있다**

```
cbsa |>
  ggplot() +
    geom_point(aes(x = density, y = rent_1br_median)) +
    geom_text_repel(aes(
      x = density, y = rent_1br_median, label = name
    ))
```

✓ **공통의 미학은 `ggplot()`에 한 번만**

```
cbsa |>
  ggplot(aes(density, rent_1br_median)) +
    geom_point() +
    geom_text_repel(aes(label = name))
```

- `ggplot()`에 쓴 미학은 그 위의 **모든 층**이 물려받는다.
- 맨 앞 두 개는 `x =`, `y =`라는 이름을 생략할 수 있다.

그림 코드의 형식 (교재 2.7)

```
cbsa |>
  ggplot(aes(density, rent_1br_median)) +
    geom_point(aes(color = quad)) +
    scale_color_viridis_d() +
    labs(x = "Density", y = "Rent")
```

세 가지 규칙

1. ggplot은 두 칸 들여쓴다.
2. 그 아래 층들은 네 칸 들여쓴다.
3. 층 하나마다 줄을 바꾼다.

자주 만나는 세 가지 문제

- 층이 안 그려짐 ➔ |>를 +로
- 색이 이상함 ➔ 고정값을 aes() 밖으로
- object not found ➔ 열 이름의 철자

1 왜 그림을 그리는가

2 첫 그림 그리기

3 기하 객체 바꾸기

4 미학 매핑 더하기

5 스케일, 라벨, 테마

6 **마무리**

오늘 배운 것

문법

- 데이터 ➔ 미학 매핑 ➔ 기하 객체
- 층을 잇는 것은 +
- `aes()` 안은 열 이름, 밖은 고정값

기하 객체

- `geom_point`, `geom_line`
- `geom_col`, `geom_text`
- `geom_text_repel` (`ggrepel`)

미학

- `x`, `y`, `label`
- `color`, `fill`, `size`, `shape`, `alpha`

다듬기

- `scale_color_viridis_d/_c`
- `scale_x_continuous`
- `labs()`, `theme_set()`

확인 질문

스스로 답해 보기

1. `ggplot()` 다음에는 왜 `|>`가 아니라 `+`를 쓰는가?
2. `aes()` **안**에 `color = "red"`라고 쓰면 무슨 일이 일어나는가?
3. `geom_text()`가 `geom_point()`보다 미학을 하나 더 요구하는 이유는 무엇인가?
4. 같은 자료를 `geom_line()`으로 그릴지 `geom_col()`로 그릴지는 무엇이 결정하는가?
5. 탐색 단계에서 `labs()`를 굳이 쓰지 않아도 되는 이유는?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간에 배울 것

- 제4강 탐색적 자료 분석 (2): 데이터 조직화 [교재 3장]
  - 조건에 맞는 행만 고르고, 필요한 열만 남기고, 정렬하기
  - 오늘 미뤄 둔 문제(막대의 순서, 범례의 순서) 해결하기

다음 시간까지 할 일

1. 오늘 그린 그림 중 하나를 골라, 기하 객체나 미학을 하나만 바꿔 다시 그려 보기
2. `ggrepel` 설치가 되지 않았다면 해결해 두기

[숙제02] 산점도 그리기 (3점)

- 파일명: `hw02-2026-00000.Rmd` (`2026-00000`은 자신의 학번)
- 제출 기한: **2026-09-14 09:00** (월요일 오전 9시) eTL
- 오늘 배운 내용으로 충분히 풀 수 있다. 자세한 안내는 eTL 공지 참조.
- Knit이 오류 없이 되는지 반드시 확인하고 제출할 것!

참고 자료

- ggplot2 치트시트 — `https://rstudio.github.io/cheatsheets/data-visualization.pdf`
- 전체 기하 객체 목록 — `https://ggplot2.tidyverse.org/reference/`