2026학년도 2학기 인문데이터 수량분석

제6강 데이터 수집

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 9월 21일 월요일

오늘의 목표

1. 무엇을 관측할지 정하고, 그에 맞는 직사각형 표를 설계할 수 있다.
2. 변수 이름과 칸의 값을 일관된 원칙으로 적을 수 있다.
3. 결측과 불확실한 정보, 날짜를 원칙에 따라 기록할 수 있다.
4. CSV·엑셀 파일을 읽고 쓰며, 한글 자료에서 흔한 문제를 손볼 수 있다.

사전 준비

1. Posit Cloud의 `qah-2026` 프로젝트를 연다.
2. 콘솔에서 `library(tidyverse)`를 실행해 둔다.

❗ [숙제03]은 **오늘 09:00** 마감이었다. 제출을 확인한다.

1 **자료를 만드는 사람**
왜 이제야 배우는가
무엇을 관측할 것인가

2 표 만들기의 원칙

3 날짜 적기

4 파일로 주고받기

5 자료에 붙이는 설명

6 마무리

다섯 강 동안 우리는 손님이었다

지금까지 쓴 자료

`acs_cbsa.csv`, `acs_state.csv`, `food_prices.csv`. 모두 누군가 이미 정돈해 둔 것을 받아 쓴 것이다.

남이 만든 자료의 한계

- 내 연구 질문에 꼭 맞는 자료는 대개 존재하지 않는다.
- 인문학의 자료는 더욱 그렇다. 문헌·유물·기록은 아직 표가 아니다.

오늘부터는 만드는 쪽

- 무엇을 세고, 어떻게 적을 것인가.
- 그 결정이 앞으로 할 수 있는 분석을 전부 결정한다.

교재가 수집을 기초 다섯 장 가운데 **맨 마지막**에 둔 까닭이 여기 있다. 그려 보고 걸러 보고 이어 본 사람만이 **어떤 표가 필요한지** 안다.

시간은 어디에 쓰이는가



데이터 분석의 오랜 통설

분석에 드는 시간의 대부분은 자료를 **모으고 고치는** 데 쓰인다. 정확한 수치라기보다 경험에서 나온 말이다.

줄이는 방법은 하나뿐

나중에 고치는 것이 아니라 **처음부터 맞게** 적는 것이다. 고칠 것이 없으면 곧장 탐색으로 갈 수 있다.

➔ 오늘 배우는 것은 R 문법이 아니라 **자료를 적는 규율**이다. 그중 절반은 엑셀 창 앞에서 지켜야 하는 것이다.

자료를 만들기 전에 던지는 두 질문

무엇을 관측하는가 (things)

한 행이 무엇 하나를 가리키는가. 책 한 권인가, 저자 한 사람인가, 조리법 하나인가.

무엇을 재는가 (properties)

그 하나에 대해 적어 둘 속성이 무엇인가. 쪽수, 무게, 출판 연도, 국적…

관측 단위가 다르면 표를 나눈다

책의 속성과 저자의 속성은 **서로 다른 표**에 적는다. 한 저자가 여러 책을 썼고, 한 책을 여럿이 쓰기도 하기 때문이다.

➔ 5강에서 배운 그대로다. 나누어 적고, 분석할 때 키로 **이어 붙인다**.

⚠ 이것을 지키지 않으면 저자의 생년을 그가 쓴 책 수만큼 반복해 적게 된다.

오늘의 예제: 요리책 자료

cookbooks — 한 행이 책 한 권

book_title	author	pages	weight
Joy of Cooking	Irma Rombauer	1200	2177
Le Guide Culinaire	Georges Escoffier	680	1995
The English Huswife	Gervase Markham	384	450

authors — 한 행이 사람 한 명

author	nationality	birth_year
Irma Rombauer	US	1877
Georges Escoffier	FR	1846
Gervase Markham	UK	1568

- 교재 5장이 쓰는 예제다. 요리책은 문학·생활사·물질문화가 겹치는 인문학 자료이기도 하다.
- 두 표를 잇는 것은 `author` 열이다.
- ⚠ 사람 **이름**을 키로 삼는 것은 위험하다. 동명이인이 있고 표기가 흔들린다. 자료가 커지면 `author_id` 같은 번호를 따로 두는 편이 낫다.

직사각형으로 담는다

	A	B	C	D	E
1	**book_title**	**author**	**pages**	**weight**	**notes**
2	Joy of Cooking	Irma Rombauer	1200	2177	
3	Le Guide Culinaire	Georges Escoffier	680	1995	
4	Dietary Principles	Hu Sihui			절판
5					

- 굵게 표시한 칸이 A1이다. 머리글은 **한 줄**, 그 아래로는 자료뿐이다.
- 한 시트에 표 하나. 열의 개수는 모든 행에서 같다. 그래서 **직사각형**이다.
- 첫 줄을 굵게 하는 정도의 서식은 괜찮다. 입력할 때 눈이 편하다.

이런 스프레드시트는 곤란하다

	A	B	C	D
1	요리책 조사			
2				
3	책 이름	저자	쪽수	무게
4			(쪽)	(g)
5	Joy of Cooking	Irma Rombauer	1,200	2177
6	Dietary Principles	Hu Sihui	미상	-
7	**합계**		1200	2177

무엇이 잘못되었나

- ✗ 제목과 빈 줄 탓에 자료가 A1에서 시작하지 않는다.
- ✗ 머리글이 두 줄이다. 단위는 사전에 적는다.
- ✗ 1,200은 수가 아니라 글자다.
- ✗ 결측을 미상과 -로 섞어 적었다.
- ✗ 합계 행과 색칠은 자료가 아니다.

1 자료를 만드는 사람

2 **표 만들기의 원칙**
- 변수 이름
- 한 칸에 하나
- 결측과 불확실

3 날짜 적기

4 파일로 주고받기

5 자료에 붙이는 설명

6 마무리

변수 이름 짓기

세 가지만 쓴다

소문자, **숫자**, **밑줄**. 그리고 반드시 **문자로 시작**한다.

✗ 피할 이름	무엇이 문제인가	✓ 고친 이름
`Book Title`	공백이 있어 백틱이 필요하다	`book_title`
`2nd_author`	숫자로 시작한다	`author_2`
`weight(g)`	괄호와 단위가 섞였다	`weight`
`Nationality`	대문자 위치를 기억해야 한다	`nationality`
`yr_of_pub_ed`	지나치게 줄여 뜻이 흐리다	`pub_year`

- 3강에서 그림 축 이름을 지을 때, 4강에서 `mutate`로 열을 만들 때 이미 이 규칙을 따르고 있었다.
- 짧게 쓰되 뜻이 남아야 한다. 반년 뒤의 내가 읽을 이름이다.

한글로 된 열 이름은 어떤가

쓸 수는 있다

R은 한글 열 이름을 받아들인다. 다만 공백이 있으면 `` `책 이름` ``처럼 백틱으로 감싸야 한다.

그래도 권하지 않는다

- 인코딩이 어긋나면 열 이름부터 깨진다.
- 자동완성과 오타 확인이 불편하다.
- 밖으로 내보낼 때 문제가 생기기 쉽다.

그러면 한글 이름은 어디에 적는가

데이터 사전의 `long_name` 칸에 적는다. 열 이름은 `pub_year`, 사전에는 “출판 연도”. 그림의 축 이름으로 그대로 쓸 수 있다.

→ 값도 마찬가지다. `"여성"`·`"female"`·`"F"`를 섞지 않고 하나로 정한다.

한 칸에는 하나의 값만

원칙

칸 안에 들어가는 것은 **잰 값 하나**뿐이다. 단위도, 기호도, 주석도, 두 번째 값도 넣지 않는다.

단위와 기호

`"1200쪽"`, `"$3.50"`, `"2177 g"`는 모두 글자다. 단위가 필요하면 **열 이름**이나 **데이터 사전**에 적는다.

주석과 표시

`"1200*"`, `"1200(추정)"`처럼 별표나 괄호를 붙이지 않는다. 적을 것이 있으면 **열을 하나 더** 만든다.

- 단위가 여럿 섞였다면 단위 열을 따로 두되, 가능하면 **하나의 단위로 환산**해 적는 편이 낫다.
- 판단 기준은 간단하다. **그 열로 계산이나 정렬이 되는가?**

고쳐 적기

✗ 한 칸에 여럿

book_title	pages
Joy of Cooking	1,200쪽
Le Guide Culinaire	680 (초판)
The English Huswife	384*

✓ 열을 나눈다

book_title	pages	edition	notes
Joy of Cooking	1200	current	
Le Guide Culinaire	680	first	
The English Huswife	384	current	쪽수 재확인 필요

- 별표 하나가 열 하나로 바뀌었다. 이제 “재확인이 필요한 책”을 `filter`로 골라낼 수 있다.

→ `notes` 열은 하나만 두고, 자유롭게 적는다. **규칙적으로 반복되는** 표시라면 그때는 별도의 열로 승격시킨다.

형식은 자료가 아니다

흔한 습관

의심스러운 칸을 노란색으로 칠하고, 확정된 칸은 굵게 하고, 빠뜨린 줄은 빨갛게 둔다.

`read_csv`가 읽는 것

글자와 수치뿐이다. 색도 굵기도 테두리도 **읽히지 않는다**. CSV 파일에는 애초에 그런 것을 담을 자리가 없다.

그러면 어떻게 하는가

뜻이 있는 표시는 전부 **열**로 만든다. `verified`에 TRUE/FALSE를 적어 두면 색보다 정확하고 셀 수도 있다.

- 색으로 표시한 자료는 자기 자신에게도 위험하다. 반년 뒤에 노란색이 무슨 뜻이었는지 기억나지 않는다.
- 굳이 칠하고 싶다면 칠하되, **같은 뜻을 열에도 적어 둔다**.

빈칸의 뜻

약속

직사각형 안의 **빈칸은 결측**을 뜻한다. 그리고 결측일 때만 비운다.

빈칸 대신 쓰면 안 되는 것

- ✗ `0` — 0이라는 값과 구별되지 않는다.
- ✗ `-999`, `9999` — 평균에 섞여 들어간다.
- ✗ `"미상"`, `"-"` — 수치 열이 글자 열이 된다.

R에서는 NA

빈칸은 `read_csv`가 `NA`로 읽어 준다. `NA`는 “모른다”는 뜻의 특별한 값이며, `NA + 1`은 `NA`다.

➔ 빈칸으로 두는 것이 프로그램을 가리지 않는 **유일한** 표기법이다. 엑셀에서도, R에서도, 파이썬에서도 같은 뜻으로 읽힌다.

모르는 것과 없는 것

빈칸 하나로는 구별되지 않는 두 가지

“찾아봤지만 자료에 없다”와 “아직 찾아보지 않았다”는 전혀 다른 상태다.

교재의 단서

구별이 필요하면 "none"처럼 정해 둔 표시를 쓸 수 있다. 단, **반드시 문서로 남긴다**.

또 하나의 방법

checked 같은 열을 두어 조사 여부를 따로 적는다. 수집이 어디까지 진행되었는지도 함께 남는다.

- 여럿이 함께 자료를 만들 때 특히 요긴하다. 빈칸이 “내 담당이 아직 안 끝났다”는 뜻인지 아닌지를 서로 알 수 있다.
- 어느 쪽을 택하든 **한 가지**로 정하고 끝까지 지킨다.

불확실한 정보 적기

인문학 자료의 일상

“1670년경”, “1314–1330년 활동”, “1세기 초 로마 출생”. 모르는 것이 아니라 **덜 아는** 것이다.

한 칸에 다 적으면

`"1670년경"`은 글자다. 정렬도 계산도 되지 않는다. 세기별 집계도 할 수 없다.

나누어 적으면

`year`에는 최선의 추정치 `1670`, `year_approx`에는 `TRUE`, `notes`에는 근거를 적는다.

✓ 이렇게 두면 “확실한 연도만으로” 다시 계산해 보는 일이 `filter` 한 줄이다.

❗ 불확실성을 **지우지 않고 기록하는** 것이 핵심이다. 추정치만 남기면 나중에 그것이 추정이었다는 사실이 사라진다.

결측이 있는 자료 다루기

```r
# 결측을 어떻게 읽을지 지정한다
books <- read_csv(
  "cookbooks.csv",
  na = c("", "NA", "-", "미상")
)

# 결측이 몇 개인지 세기
books |>
  summarize(n_miss =
    ↪  sum(is.na(pages)))

# 결측을 빼고 평균 내기
books |>
  summarize(m = mean(pages,
                     na.rm = TRUE))
```

is.na()

값이 결측이면 TRUE다. `x == NA`는 답이 NA이므로 쓸 수 없다.

na.rm = TRUE

요약 함수에 붙인다. 빼지 않으면 평균이 통째로 NA가 된다.

⚠ `na.rm = TRUE`는 편리하지만 조용하다. **몇 개를 뺐는지** 세어 보고 글로 밝힌다.

1 자료를 만드는 사람

2 표 만들기의 원칙

3 **날짜 적기**

4 파일로 주고받기

5 자료에 붙이는 설명

6 마무리

날짜는 왜 어려운가

같은 하루의 여러 얼굴

`2026-09-21`, `21/09/2026`, `09/21/2026`, `2026.9.21`, “단기 4359년”, “숭정기원후…”

스프레드시트가 손을 댄다

엑셀은 날짜처럼 보이는 것을 **말없이** 날짜로 바꾼다. 파일을 열었다 저장하는 것만으로 값이 달라진다.

`03/04/2026`은 언제인가

한국·유럽에서는 4월 3일, 미국에서는 3월 4일이다. 자료만 보고는 알 수 없다.

되돌릴 수 없다

한 번 바뀐 뒤에는 원래 무엇이었는지 알 수 없다. 자료를 열어 보기만 했는데 자료가 변한다.

⚠ 유전학에서는 유전자 이름이 날짜로 바뀌는 일이 반복되어, 결국 **이름 규칙 쪽을 바꾸는** 것으로 결론이 났다.

연·월·일을 따로 적는다

author	birth_year	birth_month	birth_day	notes
Julia Child	1912	8	15	
Gervase Markham	1568			추정 연도
Hu Sihui				1314–1330 활동
Marcus Gavius Apicius	1			1세기 초 로마

교재의 권고

연, 월, 일을 **각각의 열**에 수로 적는다. 시·분·초가 필요하면 역시 열을 나눈다.

왜 이 방법인가

아는 만큼만 적고 **모르는 칸만** 비울 수 있다. 연도만 아는 인물이 흔한 인문학 자료에 잘 맞는다.

💡 월은 이름이 아니라 **수**로 적는다. “8”과 “August”와 “8월”이 섞이지 않는다.

국제 표준 ISO 8601

YYYY-MM-DD

2026년 9월 21일은 2026-09-21. 큰 단위부터 적으므로 **글자 그대로 정렬해도** 시간 순서가 된다.

좋은 점

- 읽는 방식이 하나뿐이라 오해가 없다.
- R의 날짜 함수들이 그대로 알아본다.

수집 단계에서 걸리는 점

- 스프레드시트가 열었다 저장할 때 형식을 망가뜨린다.
- 월이나 일을 모르는 경우를 적을 방법이 없다.

➔ 그래서 **모을 때는 열을 나누고**, R 안에서 정리한 자료를 다시 저장할 때 ISO 8601로 합친다.

💡 날짜를 실제로 다루는 법(간격 계산, 요일·계절별 비교)은 11강에서 배운다.

1 자료를 만드는 사람

2 표 만들기의 원칙

3 날짜 적기

4 **파일로 주고받기**
저장 형식
한글 자료의 함정

5 자료에 붙이는 설명

6 마무리

CSV: 그냥 글자다

```
book_title,author,pages,weight,notes
Joy of Cooking,Irma Rombauer,1200,2177,
Le Guide Culinaire,Georges Escoffier,680,1995,
"Mastering the Art of French Cooking, Vol. 1",Julia Child,684,1450,
Dietary Principles,Hu Sihui,,,절판
```

규칙은 둘뿐

한 줄이 한 행, 쉼표가 열의 경계다. 값 안에 쉼표가 있으면 따옴표로 감싼다.

왜 일반 텍스트인가

어느 프로그램으로도 열린다. 20년 뒤에도 열린다. 무엇이 바뀌었는지 눈으로 볼 수 있다.

- 마지막 줄의 `,,,`가 `pages`와 `weight`의 결측이다. 쉼표 사이에 아무것도 없다.
- CSV 파일은 메모장으로 열어 볼 수 있다. 자료가 이상할 때 가장 먼저 해 볼 일이다.

읽는 함수들

함수	쓰는 파일	패키지
`read_csv()`	쉼표로 나뉜 파일	`readr`
`read_csv2()`	**세미콜론**으로 나뉜 파일	`readr`
`read_tsv()`	탭으로 나뉜 파일	`readr`
`read_delim()`	그 밖의 구분자 (`delim =`)	`readr`
`read_excel()`	`.xlsx`, `.xls`	`readxl`

```
1 library(readxl)    # tidyverse에 딸려 오지만 따로 불러야 한다
2
3 books <- read_excel("cookbooks.xlsx")
4 books <- read_excel("cookbooks.xlsx", sheet = "books")
```

`read_csv2()`가 필요한 까닭: 소수점에 쉼표를 쓰는 나라에서는 열 구분자로 세미콜론을 쓴다. 유럽에서 받은 파일이 한 열로 읽히면 이것을 의심한다.

엑셀로 모으고 CSV로 남긴다

```
1 write_csv(books, "cookbooks.csv")
```

모으는 동안은 .xlsx

CSV로 열었다 저장하기를 반복하면 그때마다 값이 조금씩 변형된다. 수집 중에는 엑셀 형식으로 둔다.

끝나면 .csv

공유하고 보존할 때는 일반 텍스트로 저장한다. `write_csv()`가 UTF-8로 써 준다.

⚠ `write_csv()`로 쓴 한글 파일을 윈도우 엑셀에서 곧바로 열면 깨져 보일 수 있다. 그럴 때는 `write_excel_csv()`를 쓴다. 엑셀이 알아보는 표시를 앞에 붙여 준다.

➔ 원본 파일은 절대 덮어쓰지 않는다. 고친 결과는 **새 이름**으로 저장한다.

글자가 깨질 때

```
# A tibble: 3 x 2
  ì±… ì´ë¦„           ì²«ì˜ ~
  <chr>                <dbl>
1 ìŒì‹ë””ë¯¸ë°©          312
```

```r
# 어떤 인코딩인지 짐작해 본다
guess_encoding("kosis.csv")

# 그 인코딩으로 다시 읽는다
read_csv(
  "kosis.csv",
  locale = locale(encoding = "EUC-KR")
)
```

왜 깨지는가

한글을 저장하는 방식이 둘이다.
UTF-8(요즘 표준)과
EUC-KR(윈도우에서는 CP949).
다른 쪽으로 읽으면 깨진다.

- 내보낼 때는 엑셀의 “CSV UTF-8” 형식을 고른다. 다음 사람이 겪을 일을 미리 없앤다.
- 자료가 깨진 것이 아니다. **읽는 방식**이 어긋난 것이다. 파일은 그대로 있다.

내려받은 통계표 손질하기 (1)

```
"연도별 도서관 이용 현황"
"단위: 천 명"

"연도","전체","공공","대학"
"2020년","1,234","890","344"
"2021년","-","1,002","401"
```

```
lib <- read_csv(
  "library.csv",
  skip = 4,
  na = c("", "-", "..."),
  col_names = c(
    "year", "total",
    "public", "univ"
  )
)
```

- `skip = 4` — 제목, 단위, 빈 줄, 머리글까지 위의 네 줄을 건너뛴다.
- `na =  ` — 결측을 나타내는 기호를 **전부** 적어 준다.
- `col_names =  ` — 머리글 줄까지 건너뛰었으므로 이름을 직접 지어 준다.

⚠ `skip`으로 몇 줄을 건너뛸지는 **파일을 직접 열어** 세어 본다. 빈 줄도 한 줄로 센다.

내려받은 통계표 손질하기 (2)

```
lib |>
  mutate(year = parse_number(year)) |>    # "2020년" -> 2020
  pivot_longer(
    c(public, univ), names_to = "type", values_to = "count"
  )
```

parse_number()

글자에서 수만 골라낸다. 천 단위 쉼표, 단위 표시, 통화 기호를 걷어 낸다.

그다음은 5강

연도가 열로 늘어선 넓은 표라면 pivot_longer로 길게 만든다.
여기서부터는 이미 배운 길이다.

- total의 "1,234"는 read_csv가 천 단위 쉼표를 걷어 내고 이미 수로 읽었다. 이미 수인 열에 parse_number를 쓰면 오류가 난다.
- 열 이름이 한글이거나 공백투성이라면 rename()으로 바꾼다.
  `rename(year = `연도`)`처럼 **새 이름 = 옛 이름** 순서다.

공개 자료는 어디에 있나

```r
# 주소를 그대로 넣어도 읽힌다
read_csv("https://humanitiesdata.org/data/food_prices.csv")
```

국내

- 공공데이터포털 `data.go.kr`
- 국가통계포털 KOSIS `kosis.kr`
- 한국사데이터베이스 (국사편찬위원회)
- 한국고전종합DB (한국고전번역원)

국외

- Europeana, HathiTrust
- Chronicling America (미국 신문)
- Wikidata, VIAF

내려받은 자료에는 **이용 조건**이 붙어 있다. 출처와 재배포 가능 여부를 확인한다.

원본은 사라질 수 있다. 한 번 내려받아 **내 폴더에 두고** 읽는 편이 안전하다.

1 자료를 만드는 사람

2 표 만들기의 원칙

3 날짜 적기

4 파일로 주고받기

5 **자료에 붙이는 설명**

6 마무리

데이터 사전(data dictionary)

variable	long_name	units	description
book_title	Book Title		영어로 적은 책 이름
pages	Number of pages		현재 유통본 기준 쪽수
weight	Book weight	grams	현재 유통본 기준 무게
nationality	Author's Nationality		ISO 두 글자 국가 코드
birth_year	Author's birth year		수치, 미상이면 비움

- 변수마다 한 행. 정식 이름, 단위, 그리고 **정확히 무엇을 적은 것인지**.
- `long_name`은 그림의 축 이름과 표의 머리글로 그대로 쓸 수 있다.

➔ 사전 자체도 CSV 파일 하나다. 자료와 같은 폴더에 나란히 둔다.

자료와 함께 남길 것

출처와 시점

어디서 가져왔는가, 언제 내려받았는가.
웹 자료는 조용히 바뀐다.

판단의 기록

애매한 것을 어느 쪽으로 정했는가.
번역서의 저자는 누구로 적었는가.

범위와 기준

무엇을 포함하고 무엇을 뺐는가.
“단행본만”, “1945년 이전만”.

이용 조건

라이선스와 인용 방법. 남에게 넘길 수 있는 자료인지.

이런 결정은 **반드시** 생긴다. 기록하지 않으면 자료를 믿을 근거가 사라진다.

R Markdown 문서 첫머리에 적어 두면 분석과 설명이 한 파일에 남는다.

교재의 아홉 가지 지침

표의 모양

1. A1에서 시작하는 머리글 한 줄, 그 아래 관측값.
2. 열 이름은 소문자·숫자·밑줄, 문자로 시작, 짧게.
3. 글자 값의 코드를 일관되게 유지한다.
4. 한 칸에 하나. 단위·기호·주석 금지.

적는 방식과 남기는 방식

5. 필요하면 `notes` 열을 따로 둔다.
6. 빈칸은 결측일 때만 쓴다.
7. 날짜는 연·월·일을 각각의 열로.
8. 수집 중에는 `xlsx`, 보존·공유는 CSV.
9. 데이터 사전을 만든다.

→ 전부 오늘 하나씩 살펴본 것이다. 이 아홉 줄이 5장의 요약이다.

원칙보다 중요한 것

교재가 스스로 붙인 단서

이것은 **하나의 견해**이며, 다른 선택도 똑같이 타당할 수 있다. 그러나 가장 중요한 것은 **일관성**이다.

어겨도 되는 때

자료의 성격상 그래야 할 이유가 분명할 때. 예컨대 결측을 세 가지로 구별해야 하는 자료가 있다.

어길 때 해야 할 일

왜 그랬는지 적어 둔다. 데이터 사전에 한 줄이면 된다.

- 규칙을 다 지킨 자료보다, **규칙을 밝혀 둔** 자료가 쓸모 있다.
- 규칙이 흔들리기 쉬운 때는 여럿이 나누어 입력할 때다. 시작 전에 사전을 먼저 쓰고 공유한다.

무엇을 세기로 했는가

자료를 만드는 일은 이미 해석이다

『음식디미방』과 『규합총서』와 『조선무쌍신식요리제법』을 한 표에 넣기로 한 순간, 이 셋이 **같은 종류**라는 판단을 내린 것이다.

분류는 자연물이 아니다

"장르", "국적", "성별"의 항목을 정하는 것은 발견이 아니라 **결정**이다. 누군가는 그 칸에 들어가지 못한다.

빠진 것도 자료다

한글로 남지 않은 요리서, 저자 이름이 지워진 책. 표에 없는 것이 곧 세상에 없었다는 뜻은 아니다.

- ➔ 그래서 데이터 사전은 기술 문서이면서 동시에 **해석의 기록**이다.
- 💡 이 문제를 정면으로 다룬 책이 D'Ignazio & Klein, *Data Feminism*이다 (교재 5.1의 권장 문헌).

1 자료를 만드는 사람

2 표 만들기의 원칙

3 날짜 적기

4 파일로 주고받기

5 자료에 붙이는 설명

6 **마무리**

오늘의 함수와 인자

함수 / 인자	하는 일	쓰는 때
`read_csv2()`,`read_delim()`	다른 구분자로 읽기	한 열로 읽힐 때
`read_excel()`	엑셀 파일 읽기	`.xlsx`
`write_csv()`,`write_excel_csv()`	저장하기	공유·보존
`guess_encoding()`	인코딩 짐작	글자가 깨질 때
`parse_number()`	글자에서 수 뽑기	`"2020년"`
`rename()`	열 이름 바꾸기	이름이 지저분할 때
`skip =`	앞의 몇 줄 건너뛰기	제목 행
`na =`	결측 기호 지정	`"-"`, `"미상"`
`col_names =`	열 이름 직접 주기	머리글을 건너뛴 뒤
`locale =`	인코딩 지정	`"EUC-KR"`

오늘 배운 것

표를 설계하기

- 관측 단위가 다르면 표를 나눈다
- A1에서 시작하는 직사각형
- 소문자·숫자·밑줄로 지은 짧은 이름

칸에 적기

- 한 칸에 하나, 단위·주석은 다른 열로
- 빈칸은 결측일 때만
- 불확실은 지우지 말고 열로 남긴다

주고받기

- 날짜는 연·월·일을 각각의 열로
- 수집은 `xlsx`, 보존은 CSV
- `skip`·`na`·`locale`로 손질하기

남기기

- 데이터 사전, 출처와 판단의 기록
- 원칙을 다 지키기보다 밝혀 두기

확인 질문

스스로 답해 보기

1. 책의 정보와 저자의 정보를 굳이 두 표로 나누는 까닭은 무엇인가?
2. `pages` 열에 `"1,200쪽"`이라고 적으면 무엇을 할 수 없게 되는가?
3. 결측을 `0`이나 `-999`로 적으면 왜 위험한가?
4. “1670년경”을 표에 적는 방법을 열 두 개를 써서 설명해 보라.
5. 한글이 깨져 보일 때 자료가 망가진 것인가? 무엇을 고쳐야 하는가?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간에 배울 것

- 제7강 행렬 대수 [교재 외]
  - 벡터와 행렬이 무엇이고 그 연산이 무엇을 하는지
  - 두 문서, 두 인물, 두 이미지가 얼마나 비슷한지 재는 법

다음 시간까지 할 일

1. 자기 관심 주제로 관측값 열 개짜리 표를 하나 직접 만들어 보기
2. 그 표의 데이터 사전을 CSV로 함께 작성해 보기
3. 만들면서 판단이 필요했던 대목을 `notes`에 적어 둘 것

[숙제04] 데이터 재구조화 (3점) — 진행 중

- 파일명: `hw04-2026-00000.Rmd` (`2026-00000`은 자신의 학번)
- 제출 기한: **2026-09-28 월요일 09:00** eTL

❗ Knit이 오류 없이 되는지 반드시 확인하고 제출할 것!

참고 자료

- 데이터 불러오기 치트시트 — `https://rstudio.github.io/cheatsheets/data-import.pdf`
- Broman & Woo, “Data Organization in Spreadsheets” — `https://doi.org/10.1080/00031305.2017.1375989`
- 공공데이터포털 — `https://www.data.go.kr/`
- 국가통계포털 KOSIS — `https://kosis.kr/`