2026학년도 2학기 인문데이터 수량분석

제7강 행렬 대수

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 9월 23일 수요일

오늘의 목표

1. 인문학 자료가 어떻게 행렬이 되는지 설명할 수 있다.
2. 두 문서(또는 두 인물, 두 이미지)가 얼마나 비슷한지 수치로 잴 수 있다.
3. 행렬이 벡터에 무슨 일을 하는지 기하학적으로 설명할 수 있다.
4. 행렬식·고윳값·계수가 각각 무엇을 알려 주는지 말할 수 있다.

사전 준비

1. 오늘은 코드보다 종이와 연필이 쓸모 있다. 필기구를 꺼내 둔다.
2. 고등학교에서 배운 좌표평면과 벡터를 떠올려 둔다. 그 이상은 필요하지 않다.

❗ [숙제04]는 **2026-09-28 월요일 09:00** 마감이다.

1 **인문학 자료는 어떻게 행렬이 되는가**
지금까지 만든 표를 다시 본다
세 가지 자료, 하나의 모양

2 벡터: 작품 하나를 화살표 하나로

3 행렬 곱: 비교와 연결을 한꺼번에

4 선형변환: 행렬은 함수다

5 행렬의 성질 읽기

6 마무리

여섯 강 동안 우리가 만든 것

되짚어 보면

`read_csv`로 읽고, `filter`와 `mutate`로 고치고, `join`으로 잇고, `pivot`으로 모양을 바꾸었다. 결과는 언제나 **직사각형 표** 하나였다.

그 표에서 글자 열을 떼어 내면

작품 이름, 저자 이름 같은 이름표를 가장자리로 밀어 내고 나면 가운데에는 **수만 격자로 남는다**. 이것을 **행렬(matrix)**이라 한다.

- ➔ 오늘은 새 자료를 배우지 않는다. **이미 가진 자료를 다르게 보는 법**을 배운다.
- 💡 오늘 배우는 연산 하나하나가 8강(텍스트 · 차원 축소), 9강(네트워크), 15강(이미지)에서 그대로 다시 나온다.

자료 (1) 텍스트 — 문서-단어 행렬

	님	사랑	하늘	바람	죽음
진달래꽃	86	40	22	31	5
님의 침묵	257	113	35	18	12
하늘과 바람과 별과 시	3	27	84	62	19

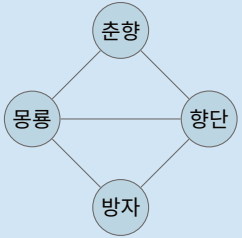
읽는 법

한 행이 작품 하나, 한 열이 단어 하나, 한 칸이 **그 작품에 그 단어가 몇 번 나왔는지**다.
김소월·한용운·윤동주의 시집에서 다섯 단어를 세었다고 하자.

⚠ 실제 문서-단어 행렬은 열이 수만 개이고, 칸의 대부분이 0이다.

→ 이 표를 직접 만드는 일이 8강에서 할 일이다.

자료 (2) 인물 관계 — 인접 행렬



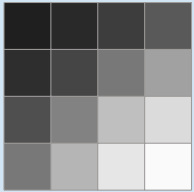
$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix} \begin{matrix} \text{춘향} \\ \text{몽룡} \\ \text{향단} \\ \text{방자} \end{matrix}$$

읽는 법

행도 인물, 열도 인물이다. 두 사람이 한 장면에 함께 나오면 1, 아니면 0. 관계에 방향이 없으므로 대각선을 축으로 좌우가 같다.

➔ 주고받은 편지, 함께 이름을 올린 논문, 한 문장에 같이 나온 단어도 이 모양이다.

자료 (3) 이미지 — 픽셀 행렬



$$\begin{bmatrix} 30 & 40 & 60 & 90 \\ 45 & 70 & 120 & 160 \\ 80 & 130 & 190 & 220 \\ 120 & 180 & 230 & 250 \end{bmatrix}$$

읽는 법

한 칸이 화소(pixel) 하나, 값은 밝기다. `0`이 검정, `255`가 흰색이다. 스캔한 고문서의 한 귀퉁이를 확대한 셈이다.

💡 색이 있는 사진은 빨강·초록·파랑 세 장의 행렬을 겹쳐 놓은 것이다. 15강에서 다룬다.

세 자료가 같은 모양이라는 것

다른 점

하나는 단어를 세었고, 하나는 사람을 이었고, 하나는 빛을 쟀다. 연구 질문도 학문 분야도 다르다.

같은 점

셋 다 **수가 직사각형으로 놓인 표**다. 컴퓨터가 보기에는 구별할 수 없다.

그래서 생기는 일

텍스트 분석 도구, 네트워크 분석 도구, 이미지 분석 도구가 따로 있는 것이 아니다. **같은 연산**을 자료만 바꾸어 쓴다.

이것이 오늘 수학을 잠깐 하는 이유다. 연산 하나를 이해해 두면 세 강의를 한꺼번에 이해하게 된다.

1 인문학 자료는 어떻게 행렬이 되는가

2 **벡터: 작품 하나를 화살표 하나로**
- 벡터란 무엇인가
- 내적
- 코사인 유사도

3 행렬 곱: 비교와 연결을 한꺼번에

4 선형변환: 행렬은 함수다

5 행렬의 성질 읽기

6 마무리

벡터 = 표의 한 줄

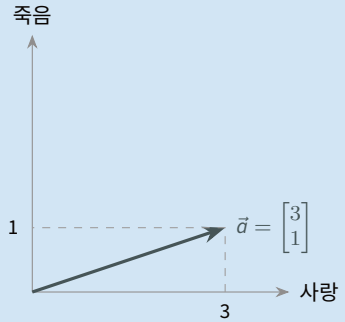
정의

여러 수를 **순서대로** 묶은 것. 행렬의 한 행 또는 한 열이 곧 벡터다.

『진달래꽃』의 행

$\vec{v} = \begin{bmatrix} 86 & 40 & 22 & 31 & 5 \end{bmatrix}$

차례로 님, 사랑, 하늘, 바람, 죽음의 빈도다.

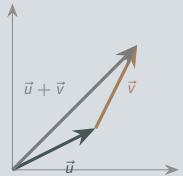


➔ 단어가 둘이면 평면 위의 화살표다. 1만 개면 1만 차원이라 **그릴 수는 없지만 계산은 똑같다.**

❗ 작품 한 편이 점 하나가 된다 — 이 발상이 오늘의 전부다.

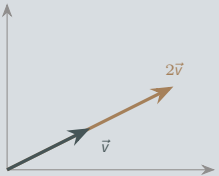
벡터의 덧셈과 상수곱

덧셈: 같은 자리끼리 더한다



두 문서를 한 뭉치로 합치면 단어 빈도가 이렇게 더해진다.

상수곱: 모든 자리에 같은 수를 곱한다



방향은 그대로, 길이만 바뀐다. 같은 투로 두 배 길게 쓴 글이다.

상수곱이 방향을 바꾸지 않는다는 사실을 기억해 둔다. 잠시 뒤 **분량이 다른 작품을 비교하는** 열쇠가 된다.

내적: 두 벡터를 하나의 수로

계산법

대응하는 자리끼리 곱해서 모두 더한다.

$$\begin{bmatrix}3\\1\end{bmatrix} \cdot \begin{bmatrix}1\\3\end{bmatrix} = 3 \times 1 + 1 \times 3 = 3 + 3 = 6$$

왜 이렇게 계산하는가

둘 다 많이 쓴 단어가 있으면 그 항의 곱이 커진다. 한쪽만 쓴 단어는 다른 쪽이 0이라 아무것도 보태지 못한다.

그래서 내적이 큰 두 문서는

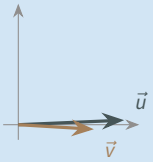
같은 단어를 함께 많이 쓴 문서다. 결과는 벡터가 아니라 **수** 하나다.

💡 단어 빈도는 음수가 될 수 없으므로 문서 벡터끼리의 내적은 항상 0 이상이다.

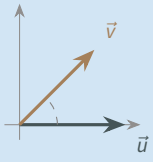
내적이 재는 것은 방향의 일치

기하학적 의미

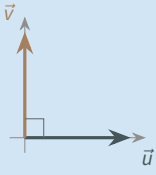
$\vec{u} \cdot \vec{v} = |\vec{u}|\,|\vec{v}| \cos\theta$ (θ는 두 화살표가 벌어진 각, $|\vec{u}|$는 화살표의 길이)



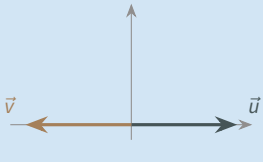
같은 방향 ($\theta = 0^\circ$)
$\cos\theta = 1$
내적 **최대**



예각 ($\theta = 45^\circ$)
$0 < \cos\theta < 1$
내적 **양수**



수직 ($\theta = 90^\circ$)
$\cos\theta = 0$
내적 **0**



반대 방향 ($\theta = 180^\circ$)
$\cos\theta = -1$
내적 **최소**

➔ 내적은 **방향이 얼마나 일치하는가**와 **길이가 얼마나 긴가**를 한꺼번에 담고 있다. 바로 이 점이 문제가 된다.

내적만으로 문서를 비교하면 생기는 일

세 문서 (단어 두 개만 세었다고 하자)

문서 $\vec{a}$ 짧은 시 한 편 — 사랑 3회, 죽음 1회
문서 $\vec{b}$ 같은 시인의 시집 한 권 — 사랑 30회, 죽음 10회
문서 $\vec{c}$ 다른 시 한 편 — 사랑 1회, 죽음 3회

내적으로 재면

$$\vec{a} \cdot \vec{b} = 3(30) + 1(10) = 100$$
$$\vec{a} \cdot \vec{c} = 3(1) + 1(3) = 6$$

그런데

$\vec{b}$가 $\vec{a}$와 비슷한 것은 맞지만, 점수가 이렇게까지 큰 것은 **분량이 열 배**이기 때문이다.

이대로 두면 **긴 작품이 언제나 이긴다**. 장편소설이 단편보다 모든 작품과 더 비슷하다는 결론이 나온다.

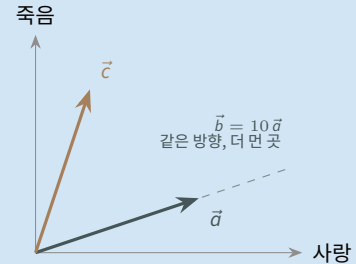
코사인 유사도: 길이를 지우고 방향만 본다

정의

내적을 두 벡터의 길이로 나눈다.

$$\cos\theta = \frac{\vec{u}\cdot\vec{v}}{|\vec{u}|\,|\vec{v}|}$$

길이가 지워지고 **방향의 일치**만 남는다.



벡터의 길이

$$|\vec{a}| = \sqrt{3^2 + 1^2} = \sqrt{10} \approx 3.16$$
$$|\vec{b}| = \sqrt{30^2 + 10^2} = \sqrt{1000} \approx 31.6$$

➔ $\vec{b} = 10\,\vec{a}$이므로 두 화살표는 **방향이 완전히 같다**. 어휘 구성이 같다는 뜻이다.

계산해 보면

결과

비교	내적	길이로 나누면	코사인 유사도
$\vec{a}$와 $\vec{b}$	100	$100/(3.16 \times 31.6)$	**1.00**
$\vec{a}$와 $\vec{c}$	6	$6/(3.16 \times 3.16)$	**0.60**

읽는 법

빈도는 음수가 없으므로 값은 **0과 1 사이**다. 1이면 어휘 구성이 같고, 0이면 겹치는 단어가 없다.

무엇이 달라졌나

내적으로는 100 대 6이었다. 분량을 지우니 1.00 대 0.60이 된다.

💡 작품의 길이가 제각각인 인문학 자료라서 코사인이 특히 잘 맞는다.

인문학에서 코사인 유사도가 하는 일

저자 판별

『연방주의자 논고』 중 저자를 모르는 12편이 누구의 글에 가까운지 단어 사용만으로 따졌다 (Mosteller & Wallace, 1964).

이본(異本) 비교

같은 작품의 여러 판본이 서로 얼마나 벌어져 있는지 잰다. 필사 계통을 추정하는 데 쓴다.

시대와 장르의 지도

작품 수백 편 사이의 유사도를 모두 구해 놓으면 가까운 것끼리 모인 지도를 그릴 수 있다. 8강에서 해 본다.

번안과 표절

두 텍스트가 우연이라 보기 어려울 만큼 가까운지 따진다.

❗ 코사인이 1에 가깝다고 두 글의 **뜻**이 같은 것은 아니다. 단어 구성이 비슷할 뿐이다. 그 수치가 무엇을 뜻하는지 판단하는 일은 연구자의 몫이다.

R에서 벡터 연산

```r
a <- c(3, 1)     # 사랑, 족음
b <- c(30, 10)

sum(a * b)       # 내적
sqrt(sum(a^2))   # 벡터의 길이

sum(a * b) /
  (sqrt(sum(a^2)) *
   sqrt(sum(b^2)))
```

```
[1] 100
[1] 3.162278
[1] 1
```

두 가지 곱셈

`*` 자리마다 따로 곱한다

`%*%` 곱해서 더한다 (내적)

⚠ `a * b`와 `a %*% b`는 전혀 다른 결과를 낸다. 앞은 벡터 `c(90, 10)`, 뒤는 수 `100`이다.

1 인문학 자료는 어떻게 행렬이 되는가

2 벡터: 작품 하나를 화살표 하나로

3 **행렬 곱: 비교와 연결을 한꺼번에**
- 행렬의 기본
- 행렬 곱
- 조심할 것과 특별한 행렬

4 선형변환: 행렬은 함수다

5 행렬의 성질 읽기

6 마무리

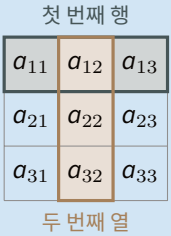
행렬 읽는 법

크기와 자리

행이 m개, 열이 n개면 $m \times n$ **행렬**이다. i번째 행, j번째 열의 칸을 a_{ij}라 쓴다.

두 가지로 볼 수 있다

- 행을 쌓은 것 — 작품 하나가 한 행
- 열을 늘어놓은 것 — 단어 하나가 한 열



덧셈과 상수곱은 벡터와 같다. **같은 자리끼리** 더하고, 모든 칸에 같은 수를 곱한다. 크기가 같은 행렬끼리만 더할 수 있다.

전치: 행과 열을 맞바꾼다

A^T

$$A = \begin{bmatrix} 3 & 1 & 4 \\ 30 & 10 & 40 \end{bmatrix} \Rightarrow A^T = \begin{bmatrix} 3 & 30 \\ 1 & 10 \\ 4 & 40 \end{bmatrix}$$ (2×3이 3×2가 된다)

자료로 보면

'문서 $\times$ 단어' 표가 '단어 $\times$ 문서' 표가 된다. 담긴 정보는 하나도 달라지지 않는다.

그런데 왜 필요한가

곧 볼 곱셈에서 **문서끼리 비교할지 단어끼리 비교할지**가 전치를 어디에 두느냐로 갈린다.

➔ 5강의 `pivot_longer`·`pivot_wider`가 표의 모양을 바꾸었듯, 전치는 행렬의 모양을 바꾼다.

행렬 곱의 규칙

곱할 수 있는 조건

앞 행렬의 **열 개수**와 뒤 행렬의 **행 개수**가 같아야 한다.

$$(m \times n) \quad \times \quad (n \times p) \quad = \quad (m \times p)$$

각 칸을 채우는 법

AB의 (i,j) 칸 $=$ A의 i**번째 행**과 B의 j**번째 열**의 **내적**

계산해 보기

$$\begin{bmatrix} 2 & 3 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 8 & 3 \\ 14 & 5 \end{bmatrix} \qquad 2 \times 1 + 3 \times 2 = 8$$

행렬 곱은 **내적을 무더기로 한꺼번에** 하는 장치다. 이 한 문장이 이 절의 전부다.

쓰임 (1) 모든 문서쌍을 한 번에 비교하기

A가 3×5 문서-단어 행렬이라면

AA^T는 $(3 \times 5)(5 \times 3) = 3 \times 3$ 행렬이고, 그 (i, j) 칸은 **문서 i와 문서 j의 내적**이다.

AA^T — 문서끼리

작품 세 편 사이의 유사도를 한 번의 곱셈으로 모두 얻는다. 대각선은 자기 자신과의 내적, 즉 길이의 제곱이다.

A^TA — 단어끼리

$(5 \times 3)(3 \times 5) = 5 \times 5$. 두 단어가 **같은 작품에 함께** 얼마나 나타나는지를 잰다.

➔ 전치를 어디에 두느냐로 **작품의 지도**와 **단어의 연결망**이 갈린다($8 \cdot 9$강).

💡 작품이 500편이면 비교해야 할 쌍이 12만 개가 넘는다. 손으로는 불가능하지만 곱셈 한 줄이면 끝난다.

쓰임 (2) 한 다리 건너 아는 사이 세기

인접 행렬 A

$$\begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$ 춘향 / 몽룡 / 향단 / 방자

그 제곱 $A^2 = A \times A$

$$\begin{bmatrix} 2 & 1 & 1 & \mathbf{2} \\ 1 & 3 & 2 & 1 \\ 1 & 2 & 3 & 1 \\ \mathbf{2} & 1 & 1 & 2 \end{bmatrix}$$

A^2의 (i,j) 칸이 뜻하는 것

i에서 출발해 **두 걸음**에 j에 닿는 길의 수. 춘향과 방자는 직접 연결이 없지만(A에서 0) 두 걸음 길이 **두 개**다 — 몽룡을 거치거나, 향단을 거치거나.

- ➔ 대각선은 그 사람의 이웃 수다. 춘향은 2명, 몽룡은 3명.
- ❗ A^3은 세 걸음이다. 곱셈 한 번이 **관계망을 한 겹씩** 넓혀 간다. 9강의 중심성과 경로 계산이 모두 여기서 나온다.

쓰임 (3) 단어마다 무게를 달리 주기

대각행렬을 오른쪽에 곱하면 열마다 다른 수가 곱해진다

$$\begin{bmatrix} 3 & 1 \\ 30 & 10 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 5 \end{bmatrix} = \begin{bmatrix} 3 & 5 \\ 30 & 50 \end{bmatrix}$$

첫째 단어는 그대로, 둘째 단어는 5배

왜 무게를 다르게 주는가

‘것’ · ‘하다’처럼 어디에나 나오는 단어는 두 문서가 비슷한지 알려 주는 바가 없다.

드문 단어일수록 크게

몇몇 작품에만 나오는 단어가 그 작품을 구별해 준다. 여기에 큰 무게를 준다.

➔ 8강에서 배울 **TF-IDF**가 바로 이 대각행렬을 고르는 방법이다. 지금은 “단어마다 무게를 달리 준다”는 뜻만 알아 두면 된다.

곱셈에서 조심할 두 가지

순서를 바꿀 수 없다

AB와 BA는 다르다. 크기조차 다를 수 있다. A가 3×5면 AA^T는 3×3, A^TA는 5×5다.

0이 아닌 것끼리 곱해도 0이 될 수 있다

수에서는 $ab = 0$이면 둘 중 하나가 0이다. 행렬에서는 $A \neq O, B \neq O$이면서 $AB = O$일 수 있다.

자료로 옮기면

'문서 $\times$ 단어'에 '단어 $\times$ 문서'를 곱하는 것과 그 반대는 **전혀 다른 표**를 만든다. 앞은 작품 사이의 관계, 뒤는 단어 사이의 관계다.

곱셈의 순서를 정하는 일이 곧 **무엇을 무엇과 비교할지** 정하는 일이다.

영행렬과 항등행렬

영행렬 O

모든 칸이 0인 행렬.

$$O = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

성질 $A + O = A$, $AO = OA = O$

항등행렬 I

대각선이 1, 나머지가 0인 정사각 행렬.

$$I_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

성질 $AI = IA = A$ (아무것도 바꾸지 않는다)

💡 수의 0과 1에 해당한다. 항등행렬은 모든 단어에 무게 1을 준 대각행렬이다.

➔ I는 역행렬($AA^{-1} = I$)과 고윳값($(A - \lambda I)\vec{v} = \vec{0}$)의 정의에 들어 있다.

R에서 행렬 만들기

```r
A <- matrix(
  c(3, 1, 4, 30, 10, 40),
  nrow = 2, byrow = TRUE)

dim(A)        # 크기
t(A)          # 전치
A %*% t(A)    # 문서끼리
t(A) %*% A    # 단어끼리
```

```
> dim(A)
[1] 2 3

> A %*% t(A)
     [,1] [,2]
[1,]   26  260
[2,]  260 2600
```

⚠ `byrow = TRUE`를 빠뜨리면 수가 **열 방향**으로 채워진다. 표를 보이는 대로 적으려면 반드시 넣는다.

➔ 두 결과의 크기를 비교해 본다. 2×2와 3×3이다.

1 인문학 자료는 어떻게 행렬이 되는가

2 벡터: 작품 하나를 화살표 하나로

3 행렬 곱: 비교와 연결을 한꺼번에

4 선형변환: 행렬은 함수다
행렬이 벡터에 하는 일
세 가지 기본 변환

5 행렬의 성질 읽기

6 마무리

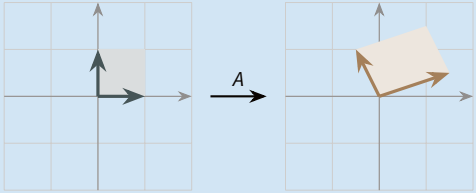
행렬 × 벡터 = 새로운 벡터

핵심

행렬은 수를 담아 두는 상자가 아니라 **벡터를 옮기는 함수**다.

$$A\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1.5x - 0.5y \\ 0.5x + y \end{bmatrix}$$

$$\left(A = \begin{bmatrix} 1.5 & -0.5 \\ 0.5 & 1 \end{bmatrix}\right)$$



원래 공간 변환된 공간

➔ 격자의 눈금이 평행사변형으로 기울었을 뿐, **직선은 직선으로** 남고 **원점은 원점에** 그대로 있다.

선형이라는 말의 뜻

두 조건

1. $A(\vec{u}+\vec{v}) = A\vec{u} + A\vec{v}$ — 먼저 더하고 변환하나, 각각 변환하고 더하나 같다.
2. $A(c\vec{v}) = c\,(A\vec{v})$ — 먼저 늘리고 변환하나, 변환하고 늘리나 같다.

그래서 생기는 성질

직선은 휘지 않고, 평행한 직선은 평행한 채로 남고, 원점은 움직이지 않는다.

왜 이것만 다루는가

세상의 변환이 다 선형인 것은 아니다.
다만 선형인 것만이 **행렬 하나로 적히고**, 계산이 쉽다.

❗ 자료 분석의 많은 기법이 선형이다. 편해서 그렇게 쓰는 것이지 자료가 원래 선형이어서가 아니다. **이 한계를 아는 것도 공부다.**

회전 · 확대 · 대칭

회전

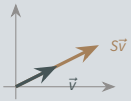
$$\begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$



원점을 중심으로 θ만큼 돌린다.

확대

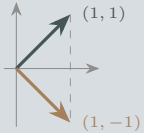
$$\begin{bmatrix} k & 0 \\ 0 & k \end{bmatrix}$$



방향은 그대로 두고 k배 늘린다.

대칭

$$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$



축을 기준으로 뒤집는다.

y축 대칭은 $\begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$, $y = x$ 대칭은 $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ (x와 y 좌표를 맞바꾼다).

이미지에서는 이것이 전부다

스캔한 고문서가 기울어져 있을 때

화소의 좌표에 **회전 행렬**을 곱해 바로 세운다. 아카이브 이미지를 다룰 때 가장 먼저 하는 일이다.

크기를 맞출 때

해상도가 제각각인 이미지 수천 장을 비교하려면 **확대 변환**으로 같은 크기로 맞춘다.

뒤집힌 판본

탁본이나 목판 인쇄에서 좌우가 뒤집힌 상은 **대칭 변환**으로 되돌린다.

지도에서도

둥근 지구 위의 위도 · 경도를 평면 위의 좌표로 바꾸는 일도 좌표 변환이다. 13강에서 다시 만난다.

→ 사진 편집 프로그램의 '회전' · '크기 조정' · '좌우 반전' 단추가 하는 계산이 바로 이것이다.

1 인문학 자료는 어떻게 행렬이 되는가

2 벡터: 작품 하나를 화살표 하나로

3 행렬 곱: 비교와 연결을 한꺼번에

4 선형변환: 행렬은 함수다

5 행렬의 성질 읽기
- 행렬식과 역행렬
- 고윳값과 고유벡터
- 계수(rank)

6 마무리

행렬식: 넓이가 몇 배가 되는가

행렬식 $\det(A)$ 란

그 변환이 공간을 얼마나 늘리거나 줄이는지를 나타내는 **수 하나**다.

값이 알려 주는 것

$\det(A) = 0$	차원이 줄어든다. 넓이가 0이 된다. **되돌릴 수 없다.**
$\det(A) < 0$	좌우가 뒤집힌다.
$\lvert\det(A)\rvert > 1$	넓이(3차원이면 부피)가 커진다.
$\lvert\det(A)\rvert < 1$	넓이가 작아진다.

💡 행렬식은 **정사각 행렬에만** 있다. 행과 열의 수가 같아야 한다.

2×2 행렬의 행렬식

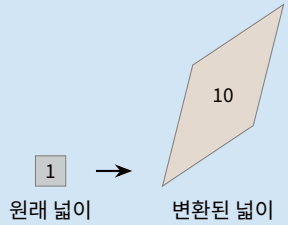
공식

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

계산 예시

$$\det \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix} = 3 \cdot 4 - 1 \cdot 2 = 10$$

한 칸짜리 정사각형이 넓이 10짜리 평행사변형이 된다.



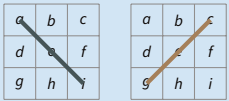
3×3 행렬의 행렬식 — 사루스 법칙

공식

$$\det \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} = aei + bfg + cdh - ceg - afh - bdi$$

읽는 법

왼쪽 위에서 내려가는 세 대각선은 **더하고**,
오른쪽 위에서 내려가는 세 대각선은 **뺀다**.



더한다 (aei) 뺀다 (ceg)

➔ a부터 i까지 차례로 $1, 2, 3/0, 1, 4/5, 6, 0$을 넣어 보면 $0 + 40 + 0 - 15 - 24 - 0 = 1$ 이다.

⚠ 4×4부터는 이런 규칙이 없다. R의 `det()`에 맡긴다.

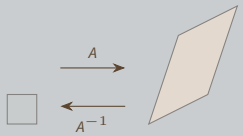
역행렬: 변환을 되돌릴 수 있는가

존재 조건

$\det(A) \neq 0$일 때에만 역행렬 A^{-1}이 있다. 이때 $AA^{-1} = I$다.

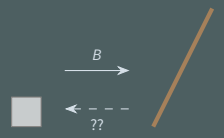
되돌릴 수 있는 경우

$A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$, $\det(A) = 6 - 1 = 5$



되돌릴 수 없는 경우

$B = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}$, $\det(B) = 4 - 4 = 0$



평면이 직선으로 납작해지면 원래 어느 점에서 왔는지 알 수 없다.

‘되돌릴 수 없다’가 인문학 자료에서 뜻하는 것

같은 정보를 두 번 적은 열

‘출판 연도’와 ‘출판 후 경과 연수’를 나란히 두면 한 열은 다른 열로 완전히 계산된다. 두 열이 있어도 정보는 하나뿐이다.

차원 축소는 일부러 납작하게 만드는 일

1만 차원의 문서를 2차원 지도에 옮기는 것은 정보를 **버리는** 대가로 눈에 보이는 그림을 얻는 일이다. 되돌릴 수 없다.

이때 행렬식은

0이 된다. 열이 늘어난 만큼 차원이 늘지 않는다.

익명화도 마찬가지

되돌릴 수 없게 만드는 것이 목적이다.

- 8강에서 문서 지도를 그릴 때, 그 그림은 자료의 전부가 아니라 **납작해진 그림자**임을 기억해야 한다.

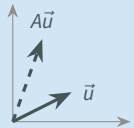
방향이 바뀌지 않는 벡터

핵심 아이디어

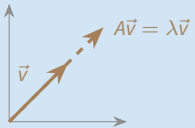
대부분의 벡터는 변환을 받으면 방향이 달라진다. 그런데 **방향이 그대로이고 길이만 바뀌는** 특별한 벡터가 있다.

$$A\vec{v} = \lambda\vec{v}$$

- $\vec{v}$ 고유벡터 — 변환을 받아도 방향이 유지되는 벡터
- λ 고윳값 — 그 방향으로 몇 배가 되는지



보통의 벡터: 방향이 달라진다



고유벡터: 방향이 그대로다

고윳값을 구하는 방법

식을 정리하면

$$
\begin{aligned}
A\vec{v} = \lambda\vec{v} &\Rightarrow A\vec{v} - \lambda\vec{v} = \vec{0} \\
&\Rightarrow A\vec{v} - \lambda I\vec{v} = \vec{0} \\
&\Rightarrow (A - \lambda I)\vec{v} = \vec{0} \\
&\Rightarrow \det(A - \lambda I) = 0
\end{aligned}
$$

절차

1. 특성방정식 $\det(A - \lambda I) = 0$을 세운다.
2. 그 방정식을 풀어 고윳값 λ를 구한다.
3. 각 λ에 대해 $(A - \lambda I)\vec{v} = \vec{0}$을 풀어 고유벡터를 구한다.

마지막 줄에서 행렬식이 다시 나온다. $\vec{v}$가 $\vec{0}$이 아니면서 납작해지려면 $\det = 0$이어야 하기 때문이다.

손으로 푸는 일은 거의 없다. R의 `eigen()`이 해 준다. 여기서는 **무엇을 구하는 것인지**만 알면 된다.

계산 예시

$A = \begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}$의 고윳값과 고유벡터

1. $A - \lambda I = \begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 3-\lambda & 1 \\ 0 & 2-\lambda \end{bmatrix}$
2. 특성방정식: $\det \begin{bmatrix} 3-\lambda & 1 \\ 0 & 2-\lambda \end{bmatrix} = (3-\lambda)(2-\lambda) = 0 \Rightarrow \lambda_1 = 3,\ \lambda_2 = 2$
3. $\lambda_1 = 3$일 때 $\begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow y = 0 \Rightarrow \vec{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

   $\lambda_2 = 2$일 때 $\begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow x + y = 0 \Rightarrow \vec{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

기본 변환들의 고윳값

변환	고윳값	고유벡터	뜻
x축 대칭	$1, -1$	x축, y축	한 방향은 그대로, 한 방향은 뒤집힘
$y = x$ 대칭	$1, -1$	대각선, 그 수직선	대각선 위는 그대로
2배 확대	2 (중복)	모든 벡터	어느 방향이든 똑같이 2배
$90°$ 회전	$\pm i$ (허수)	없음	**유지되는 방향이 하나도 없다**

정리하면

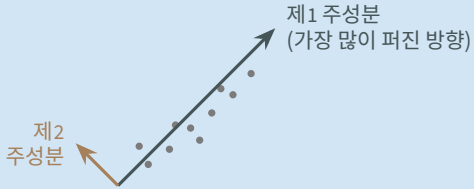
고윳값과 고유벡터는 그 변환이 **어느 방향을 특별하게 다루는지**를 알려 준다. 회전처럼 특별한 방향이 없는 변환은 실수 고윳값을 갖지 못한다.

➔ 자료 분석에서 우리가 다루는 행렬은 대개 대칭 행렬($A = A^T$)이다. 문서끼리의 유사도 행렬도, 인접 행렬도 그렇다. 이런 행렬은 항상 실수 고윳값을 갖는다.

쓰임 (1) 자료가 가장 넓게 퍼진 방향 찾기

문제

작품 500편을 단어 1만 개로 재 두었다. 종이 위에 그리려면 **어느 두 방향**을 남겨야 하는가?



답

자료가 **가장 넓게 퍼져 있는** 방향부터 남긴다. 그 방향이 고유벡터, 얼마나 퍼졌는지가 고윳값이다.

➔ 이것이 **주성분 분석(PCA)**이다. 8강에서 작품의 지도를 그릴 때 쓴다.

❗ 남은 축이 무엇을 뜻하는지는 계산이 알려 주지 않는다. 읽어 내는 일은 연구자의 몫이다.

쓰임 (2) 누가 중요한 인물인가

순환하는 정의

중요한 인물이란 **중요한 인물과 연결된** 인물이다. 정의 안에 정의가 들어 있어 그대로는 계산할 수 없다.

식으로 적으면

각자의 점수 $\vec{x}$가 이웃들의 점수 합에 비례하므로 $A\vec{x} = \lambda\vec{x}$가 된다. 곧 $\vec{x}$는 인접 행렬 A의 **고유벡터**다.

춘향전의 네 인물

이웃이 셋인 몽룡·향단이 더 높게 나온다. 다만 이웃 수를 세는 것과 달리 **이웃의 됨됨이**까지 반영된다.

➔ 이것이 **고유벡터 중심성**이다. 구글의 **PageRank**도 같은 계산이다.

💡 '중요하다'의 뜻을 어떻게 정하느냐에 따라 답이 달라진다. 9강에서 다룬다.

계수: 실제로는 몇 차원인가

정의

서로 **독립인** 행(또는 열)의 최대 개수. 여기서 독립이란 어느 한 줄도 다른 줄들을 더하고 곱해서 만들 수 없다는 뜻이다.

계수 2

$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 두 행이 서로 다른 방향을 가리킨다. 평면을 채운다.

계수 1

$\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ 둘째 행이 첫째 행의 2배다. 두 줄이 있어도 방향은 하나뿐이다.

➔ 계수가 행의 수보다 작으면 $\det = 0$이고 역행렬이 없다. 앞서 본 세 가지가 사실은 같은 이야기다.

💡 열이 100개라도 계수가 3이면, 그 표에 든 정보는 사실 **3차원**뿐이다.

계수가 인문학 자료에서 알려 주는 것

단어는 1만 개, 주제는 몇 개

문서-단어 행렬은 열이 수만 개다. 그런데 계수를 재 보면 훨씬 작다. 단어들이 **무리 지어 함께 움직이기** 때문이다.

그 무리가 곧 주제

‘임금’ · ‘상소’ · ‘조정’이 늘 함께 오르내린다면 그 셋은 독립된 세 방향이 아니라 한 방향이다.

그래서 할 수 있는 일

- 수만 차원의 자료를 수십 차원으로 줄인다.
- 그 수십 개를 **주제**로 읽는다.
- 작품 사이의 거리를 훨씬 빠르게 잰다.

이름을 붙이면

잠재 의미 분석(LSA), 토픽 모형 같은 기법이 모두 여기서 출발한다.

계수가 낮다는 것은 자료가 부실하다는 뜻이 아니다. **자료에 구조가 있다**는 뜻이다.

1 인문학 자료는 어떻게 행렬이 되는가

2 벡터: 작품 하나를 화살표 하나로

3 행렬 곱: 비교와 연결을 한꺼번에

4 선형변환: 행렬은 함수다

5 행렬의 성질 읽기

6 **마무리**

R에서 행렬 분석하기

```r
A <- matrix(c(3, 1, 2, 4), nrow = 2, byrow = TRUE)

det(A)              # 행렬식 (정사각 행렬만)
solve(A)            # 역행렬 (det가 0이 아닐 때만)
eigen(A)$values     # 고윳값
eigen(A)$vectors    # 고유벡터
qr(A)$rank          # 계수
```

⚠ `solve()`는 det가 0이면 오류를 낸다. 오류 문구에 singular라는 말이 보이면 "납작해져서 되돌릴 수 없다"는 뜻이다.

➔ 오늘 배운 개념을 직접 계산할 일은 많지 않다. 8강 이후의 함수들이 속에서 이 계산을 한다.

오늘 배운 것

1. **행렬** — 텍스트도, 인물 관계도, 이미지도 결국 수의 직사각형이다.
2. **내적과 코사인 유사도** — 분량을 지우고 두 문서가 얼마나 닮았는지 잰다.
3. **행렬 곱** — 모든 쌍의 비교를, 한 다리 건넌 관계를, 단어의 무게를 한꺼번에.
4. **선형변환** — 행렬은 수의 배열이 아니라 벡터를 옮기는 함수다.
5. **행렬식** — 얼마나 납작해지는가. 0이면 되돌릴 수 없다.
6. **고윳값과 고유벡터** — 그 변환이 특별하게 다루는 방향.
7. **계수** — 열의 수가 아니라 자료의 실제 차원.

기억할 점

수를 얻는 일은 계산이 해 준다. 그 수가 무엇을 뜻하는지 읽는 일은 우리가 한다.

확인 질문

스스로 답해 보기

1. 문서-단어 행렬에서 한 행은 무엇이고 한 열은 무엇인가?
2. 두 문서를 비교할 때 내적 대신 코사인 유사도를 쓰는 까닭은 무엇인가?
3. A가 '문서 $\times$ 단어' 행렬일 때 AA^T와 A^TA는 각각 무엇을 알려 주는가? 크기는 어떻게 다른가?
4. 인접 행렬을 제곱하면 나오는 수는 무엇을 센 것인가?
5. $\det(A) = 0$인 변환을 "되돌릴 수 없다"고 하는 까닭은 무엇인가?
6. 단어가 1만 개인데 계수가 30이라면 그 자료에 대해 무엇을 알 수 있는가?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간에 배울 것

- 특강 (2026-09-28 월) — LLM 튜토리얼
  - ChatGPT API와 Codex — 데이터 파싱, MCP와 도구 호출, Gradio로 웹 앱 만들기
  - 문의·신청: snudsh@snu.ac.kr
- 제8강 (2026-09-30 수) 텍스트 데이터 [교재 6장]
  - 문장을 단어로 쪼개어 오늘 본 문서-단어 행렬을 직접 만든다.
  - 단어마다 무게를 달리 주는 방법(TF-IDF)을 배운다.

다음 시간까지 할 일

1. 오늘 본 춘향전 인접 행렬을 종이에 놓고 A^2를 직접 계산해 보기
2. 자기 관심 분야에서 '행렬이 될 만한 자료'를 하나 떠올려 보기

행과 열이 각각 무엇이 되는지 한 문장으로 적어 볼 것

[숙제04] 데이터 재구조화 (3점) — 진행 중

- 파일명: `hw04-2026-00000.Rmd` (`2026-00000`은 자신의 학번)
- 제출 기한: **2026-09-28 월요일 09:00** eTL

❗ Knit이 오류 없이 되는지 반드시 확인하고 제출할 것!

더 보고 싶다면

- 3Blue1Brown, “Essence of Linear Algebra” (한국어 자막) — `https://www.3blue1brown.com/topics/linear-algebra`
- Mosteller & Wallace, “Inference in an Authorship Problem” (1963) — `https://doi.org/10.1080/01621459.1963.10500849`
- Underwood, *Distant Horizons* (2019) — 수치로 문학사를 읽는 법