2026학년도 2학기 인문데이터 수량분석

제9강 네트워크 데이터

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 10월 19일 월요일

일정 변경 안내

11월 이후 일정 조정

- **기말고사**: 12/07(월) → **11/16(월)**
  - 범위: 9–16강
- **자율학습일**: 11/16(월) → **11/23(월)**

새 일정의 효능

1. 16강(11/11)까지 배운 내용을 12월에 다시 복습하지 않아도 된다.
2. 11월 말에 발제를 준비할 때 기말고사 대비에 방해받지 않는다.
3. 종강을 앞당길 수 있다.

오늘의 목표

1. 관계 자료를 노드와 에지로 옮겨 에지 리스트로 적을 수 있다.
2. 에지 리스트에서 네트워크를 만들고 ggplot으로 그릴 수 있다.
3. 네 가지 중심성이 각각 무엇을 묻는지 설명하고 결과를 읽을 수 있다.
4. 에지를 어떻게 정의하느냐에 따라 같은 자료의 답이 달라짐을 보일 수 있다.

사전 준비

8강에서 설치한 hdir·cleanNLP를 그대로 쓴다. 없다면 콘솔에서 아래를 실행한다.

```
install.packages(c("cleanNLP", "remotes"))
remotes::install_github(c("taylor-arnold/rpkg/ggimg",
                          "taylor-arnold/rpkg/hdir"))
```

1 **관계를 데이터로**
네트워크란 무엇인가
표로 적는 두 방법

2 위키백과 링크 네트워크

3 중심성과 군집

4 네트워크를 달리 정의하기

5 마무리

관계는 표의 한 행에 담기지 않는다

지금까지의 표

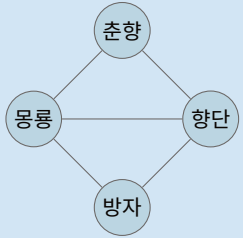
한 행이 **대상 하나**였다. 8강의 `meta`는 작가 한 명이 한 행이고, 생몰년·시대·성별이 열이었다.

그런데 묻고 싶은 것이 관계라면

누가 누구에게 편지를 보냈는가? 어느 두 인물이 한 장면에 함께 나오는가? 어떤 글이 어떤 글을 인용하는가? 관계는 대상 하나에 붙어 있지 않고 **둘 사이에** 있다.

- ➔ 관계 하나를 한 행으로 삼는 표가 필요하다. 그것이 오늘 다룰 **네트워크 자료**다.
- ❗ 관계를 표에 적어 두기만 해서는 누가 중심인지, 어떤 무리가 있는지가 보이지 않는다. 그것을 드러내는 계산과 그림을 오늘 배운다.

노드와 에지



정의

노드 대상 하나. 사람·책·나라·웹 페이지 등.

에지 두 노드 사이의 관계 하나.

네트워크 노드의 모임과 에지의 모임.

➔ 7강의 춘향전 네 인물이다. 한 장면에 함께 나오면 에지로 잇는다.

수학에서는 그래프(graph)라 하고, 노드를 꼭짓점(vertex)이라고도 부른다. R의 `igraph` 문서에 `vertex`가 자주 나오는 까닭이다.

무엇을 노드로, 무엇을 에지로

자료	노드	에지	방향
편지(간찰) 묶음	사람	편지를 보냈다	있음
소설	인물	한 장면에 함께 나온다	없음
학술 논문	논문	인용했다	있음
학술 논문	연구자	함께 논문을 썼다	없음
족보	사람	부모와 자식이다	있음
외교 기록	나라	사신을 보냈다	있음

- 같은 학술 논문 더미라도 노드를 논문으로 잡느냐 연구자로 잡느냐에 따라 **전혀 다른 네트워크**가 된다. 교재는 이 결정을 해석의 결정적 단계라 부른다.
- → 노드와 에지를 **분명하게** 정해 둘수록 결과를 읽기 쉽다.
- 마지막 줄은 10강에서 함께 읽을 논문의 자료다.

에지 리스트 vs. 인접 행렬

에지 리스트: 한 행이 에지 하나

from	to
춘향	몽룡
춘향	향단
몽룡	향단
몽룡	방자
향단	방자

인접 행렬: 한 칸이 두 노드의 관계

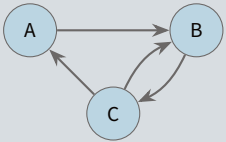
$$\begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix} \begin{matrix} \text{춘향} \\ \text{몽룡} \\ \text{향단} \\ \text{방자} \end{matrix}$$

- ➔ 에지 리스트는 에지 수만큼 행이 생긴다. 인접 행렬은 노드 수의 **제곱**만큼 칸이 생기고 대부분이 `0`이다. 노드가 72개면 5,184칸이다.
- 에지 리스트는 5강의 **정돈된 데이터**다. 한 행에 관측 하나. 그래서 `filter`와 `join`을 그대로 쓴다.

방향이 있는가

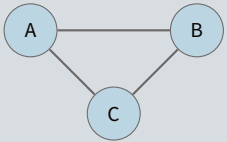
방향 있는 네트워크(directed)

A→B와 B→A가 다르다. 편지·인용·웹 링크.



방향 없는 네트워크(undirected)

A—B 하나뿐이다. 공저·한 장면에 함께 나옴.



➔ 방향 있는 네트워크는 방향을 지우면 언제든 방향 없는 네트워크가 된다. **거꾸로는 안 된다.** 없는 정보를 만들어 낼 수는 없다.

💡 인접 행렬로 보면 방향 없는 네트워크는 대각선을 축으로 좌우가 같다(7강).

1 관계를 데이터로

2 **위키백과 링크 네트워크**
에지 리스트에서 네트워크로
네트워크 그리기

3 중심성과 군집

4 네트워크를 달리 정의하기

5 마무리

네 사람으로 먼저 해 본다

```r
chunhyang <- tribble(
  ~from,  ~to,
  "춘향", "몽룡",
  "춘향", "향단",
  "몽룡", "향단",
  "몽룡", "방자",
  "향단", "방자"
)
```

tribble

표를 **한 행씩** 손으로 적는 함수다. ~가 붙은 첫 줄이 열 이름이다.

```r
library(hdir)
nwork <- hdir_network_metrics(
  chunhyang)
nwork$node |>
  select(id, degree, eigen,
         close, between)
```

```
# A tibble: 4 × 5
  id    degree eigen close between
  <chr>  <dbl> <dbl> <dbl>   <dbl>
1 춘향       2 0.781 0.25      0
2 몽룡       3 1     0.333     0.5
3 향단       3 1     0.333     0.5
4 방자       2 0.781 0.25      0
```

➔ degree가 2, 3, 3, 2다. 7강에서 A^2의 대각선으로 구한 이웃 수와 같다. 나머지 열은 3절에서 손으로 확인한다.

오늘의 자료: 위키백과 페이지 사이의 링크

```
page_citation <- read_csv(
  file.path("hdr", "data", "wiki_uk_citations.csv"))
page_citation
```

```
# A tibble: 377 × 2
  doc_id           doc_id2
  <chr>            <chr>
1 Marie de France  Geoffrey Chaucer
2 Geoffrey Chaucer William Langland
3 Geoffrey Chaucer John Gower
4 Geoffrey Chaucer John Dryden
5 Geoffrey Chaucer Philip Sidney
# ℹ 372 more rows
```

- 8강의 영국 작가 75명의 위키백과 페이지다. 본문 속 링크 가운데 **이 75명 사이를 잇는 것**만 모았다.
- 한 행이 링크 하나다. `doc_id` 페이지에서 `doc_id2` 페이지로 링크를 걸었다는 뜻이다. Marie de France는 Chaucer에게 하나를 걸었고, Chaucer는 여섯 명에게 건다.

먼저 세어 본다

```
page_citation |>
  group_by(doc_id2) |>
  summarize(count = n()) |>
  arrange(desc(count))
```

```
# A tibble: 64 × 2
  doc_id2                count
  <chr>                  <int>
1 William Shakespeare       25
2 William Wordsworth        23
3 T. S. Eliot               19
4 W. H. Auden               13
5 Edmund Spenser            12
6 John Dryden               12
7 John Keats                12
8 Percy Bysshe Shelley      12
# ℹ 56 more rows
```

왜 들어오는 링크를 세는가

나가는 링크는 페이지가 길수록 많아진다.
들어오는 링크는 **남이 걸어 준** 것이라
분량의 영향을 덜 받는다.

➔ Shakespeare가 1등인 것은 놀랍지 않다. Wordsworth가 두 개 차이로 뒤따른다는 것은 눈여겨볼 만하다.

⚠ 세기만으로는 **두세 번 클릭해서 닿는 범위**나 **누가 무리를 이루는지**를 알 수 없다. 링크 전체의 짜임을 한꺼번에 봐야 한다.

네트워크 만들기

```
1 library(hdir)
2
3 set.seed(1)    # 그림의 배치를 고정한다 (뒤에서 설명)
4 nwork <- hdir_network_metrics(page_citation, directed = FALSE)
5 node <- nwork$node
6 edge <- nwork$edge
```

hdir_network_metrics가 하는 일

에지 리스트의 **앞의 두 열**을 출발·도착 노드로 읽어 **표 두 개**를 돌려준다. 노드마다 한 행인 node, 에지마다 한 행인 edge. 계산은 igraph 패키지가 한다.

➔ 결과는 표 두 개를 묶은 목록(list)이다. 8강의 $token처럼 $로 하나씩 꺼낸다.

💡 directed = FALSE는 링크의 방향을 일단 지운다는 뜻이다. 방향은 4절에서 되살린다.

node: 노드마다 한 행

```
# A tibble: 72 × 10
  id                x       y degree  eigen    close between cluster component
  <chr>         <dbl>   <dbl>  <dbl>  <dbl>    <dbl>   <dbl> <chr>       <int>
1 Marie de …  3.24    -4.74         1 0.0244 0.00457    0      6               1
2 Geoffrey …  1.23    -1.97        16 0.409  0.00671  147.     1               1
3 William L…  3.29    -1.75         3 0.0622 0.00529    4.72   1               1
4 John Gower  2.09    -2.87         5 0.119  0.00575    7.74   1               1
5 John Dryd… -1.04    -0.950       25 0.731  0.00781  197.     1               1
6 Philip Si…  0.0202  -3.24         4 0.150  0.00595    0.378  1               1
7 Charles D…  0.755    0.0320      17 0.476  0.00714   72.1    2               1
8 William S… -0.0293  -1.08        39 1      0.00885  571.     1               1
# ℹ 64 more rows
# ℹ 1 more variable: component_size <dbl>
```

- x·y는 그림에 놓을 자리, degree부터 between까지는 중심성, cluster는 군집, component는 연결 요소다. 모두 3절에서 읽는다.
- 행이 **72개**다. 작가는 75명인데 세 명은 어디로 갔는가?

사라진 세 사람

```
meta |>
  anti_join(node,
    by = c("doc_id" = "id")) |>
  select(doc_id, born, era)
```

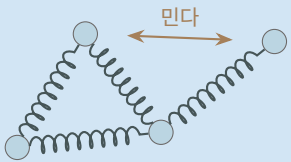
```
# A tibble: 3 × 3
  doc_id             born era
  <chr>             <dbl> <chr>
1 Margery Kempe      1373 Early
2 Charlotte Brontë   1816 Victorian
3 A. A. Milne        1882 Twentieth C
```

에지 리스트의 맹점

세 사람은 나머지 누구와도 링크를 주고받지 않아 에지 리스트에 이름이 없다. 에지 리스트에는 **아무와도 이어지지 않은 노드를 적을 자리가 없다.**

- ➔ 5강의 `anti_join`으로 `meta`에는 있고 `node`에는 없는 행을 찾았다.
- ❗ 빠진 것도 결과다. 이 자료에서는 Charlotte Brontë와 동생 Emily 사이에도 링크가 없다.

x와 y는 어디서 왔나



네트워크 그리기(graph drawing)

에지를 용수철로, 노드를 서로 밀어내는 자석으로 여기고 **힘이 평형을 이루는 자리**를 찾는다. 이어진 노드는 가까이, 전체는 너무 뭉치지 않게 놓인다.

➔ 8강의 PCA·UMAP처럼 x, y 값 자체에는 뜻이 없다. **서로의 상대적인 자리**만 읽는다.

⚠ 노드를 무작위로 흩어 놓고 시작하므로 돌릴 때마다 그림이 돌아가거나 뒤집힌다. `set.seed()`로 고정해 두어야 다시 돌려도 같은 그림이 나온다.

💡 이 크기의 네트워크에서는 Fruchterman–Reingold(1991)의 방법이 쓰인다.

edge와 그림 그리기

```
library(ggrepel)

node |>
  ggplot(aes(x, y)) +
    geom_point(alpha = 0.5) +
    geom_segment(
      aes(xend = xend,
          yend = yend),
      data = edge, alpha = 0.1) +
    geom_text_repel(
      aes(label = id), size = 3) +
    theme_void()
```

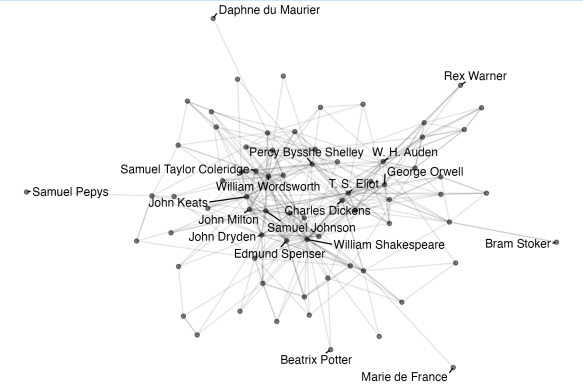
```
# A tibble: 377 × 4
      x    xend     y    yend
  <dbl>   <dbl> <dbl>   <dbl>
1  3.24  1.23   -4.74 -1.97
2  1.23  3.29   -1.97 -1.75
3  1.23  2.09   -1.97 -2.87
4  1.23 -1.04   -1.97 -0.950
# ℹ 373 more rows
```

edge 표

이름 없이 **선분의 양 끝 좌표**만 있다.
그리기 전용 표다.

- geom_segment는 (x, y)에서 (xend, yend)까지 선을 긋는다. edge의 열 이름이 바로 그 미학이다.
- 레이어마다 data를 따로 줄 수 있다(3강). 점은 node에서, 선은 edge에서 온다.

영국 작가 링크 네트워크



가운데

Shakespeare, Wordsworth, Dickens. 시대마다 가장 이름난 작가다.

바깥

du Maurier, Pepys, Marie de France. 덜 알려진 작가가 밀려났다.

- 8강의 텍스트 지도는 **시대**로 갈렸지만 링크 지도는 **이름난 정도**로 갈린다.
- 무엇을 에지로 삼느냐가 지도를 바꾼다. 이름은 화면에서 읽히도록 일부만 달았다.

1 관계를 데이터로

2 위키백과 링크 네트워크

3 **중심성과 군집**
- 직접 이어진 수
- 경로와 이웃
- 군집

4 네트워크를 달리 정의하기

5 마무리

누가 중심인가 — 네 가지 질문

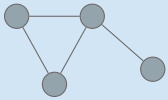
지표	열	묻는 것
연결 중심성	`degree`	에지가 몇 개 닿아 있는가
고유벡터 중심성	`eigen`	중심인 노드와 이어져 있는가
근접 중심성	`close`	다른 모든 노드에 얼마나 가까운가
매개 중심성	`between`	남들 사이를 잇는 길목에 서 있는가

중심성(centrality)

네트워크 안에서 노드가 얼마나 중요한 자리에 있는지를 나타내는 수다. 다만 “중요하다”를 어떻게 정하느냐에 따라 **지표가 여럿** 있다.

- 7강 끝에서 남긴 질문이다. 어떤 중심성을 쓸지는 **연구 질문이 정한다.**
- → 각 지표를 춘향전 네 인물로 손으로 확인한 뒤 위키백과로 넓힌다.

연결 요소(component)



1번 (4개)



2번 (2개)



3번 (1개)

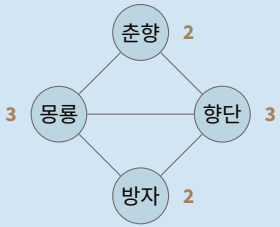
정의

에지를 따라가서 **서로 닿을 수 있는** 노드의 모임. 큰 것부터 1, 2, 3, . . . 번호를 붙인다.

➔ 위키백과 72명은 모두 1번 하나에 속한다. 이런 네트워크를 **연결되어 있다** (connected)고 한다.

⚠ 나머지 중심성은 연결 요소마다 **따로** 계산한다. 서로 다른 덩어리의 점수는 비교할 수 없다.

연결 중심성(degree)



정의

노드에 닿은 에지의 개수. 가장 계산하기 쉽고 가장 직관적이다. 다만 **바로 옆 이웃**만 본다.

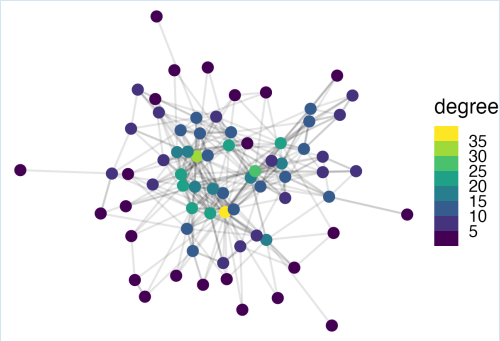
서로 링크하면 두 번 센다

Shakespeare의 degree는 39인데 이어진 작가는 31명이다. 들어오는 링크 25개와 나가는 링크 14개를 더한 값이기 때문이다.

➔ 방향을 지워도 A→B와 B→A가 **에지 두 개로 남는다**. 교재 본문은 “이웃의 수”라 했지만 실제 값은 에지 수다.

색으로 칠해 보기

```
node |>
  ggplot(aes(x, y)) +
    geom_segment(
      aes(xend = xend,
          yend = yend),
      data = edge, alpha = 0.1) +
    geom_point(
      aes(color = degree),
      size = 5) +
    scale_color_binned(
      type = "viridis",
      n.breaks = 8) +
    theme_void()
```



➔ 점의 색을 degree로 칠했다. 노란 점(39)이 Shakespeare다.

고유벡터 중심성(eigen)

7강의 순환하는 정의

중요한 노드란 **중요한 노드와 이어진** 노드다. 각 노드의 점수 s_j가 이웃 점수의 합에 비례하도록 정하면

$$\lambda s_j = \sum_{i \in j\text{의 이웃}} s_i \qquad \Longleftrightarrow \qquad A\vec{s} = \lambda\vec{s}$$

곧 $\vec{s}$는 인접 행렬의 고유벡터다. 가장 큰 점수가 1이 되도록 맞춘다.

춘향전

몽룡·향단 1, 춘향·방자 0.781.

춘향과 방자가 같은 점수

둘 다 이웃이 몽룡과 향단이다.
네트워크는 **주인공인지 하인인지 모른다.**

교재는 eigenvalue centrality라 부르지만 점수는 고유**벡터**에서 나온다.

근접 중심성(close)

	춘	몽	향	방	합	close
춘향	–	1	1	2	4	1/4 = 0.25
몽룡	1	–	1	1	3	1/3 = 0.333
향단	1	1	–	1	3	1/3 = 0.333
방자	2	1	1	–	4	1/4 = 0.25

정의

다른 모든 노드까지의 **가장 짧은 거리**(거치는 에지 수)를 더한 뒤 역수를 취한다. 멀리 있을수록 점수가 작다.

➔ 위키백과에서 Shakespeare의 값이 0.00885처럼 작은 것은 71명까지의 거리를 모두 더했기 때문이다. $1/0.00885 = 113$, 곧 나머지 작가에게 평균 1.6걸음에 닿는다.

⚠ 교재 본문은 “거리의 역수를 더한다”고 적었지만 패키지는 **거리를 더한 뒤 역수**를 낸다. 슬라이드는 화면에 뜨는 수치를 따랐다.

매개 중심성(between)



정의

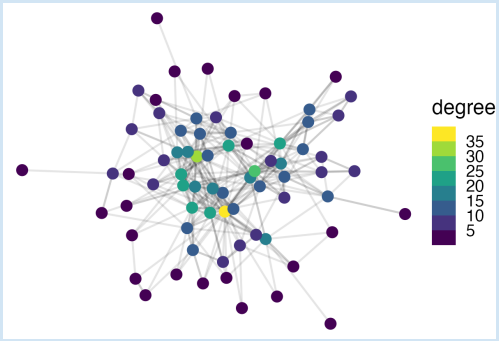
다른 두 노드 사이의 **가장 짧은 길**이 이 노드를 몇 번 지나는가. 가장 짧은 길이 여럿이면 나누어 센다.

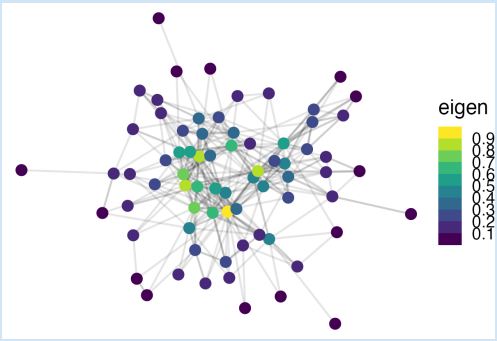
춘향전

춘향과 방자 사이의 가장 짧은 길은 둘이다. 몽룡을 거치거나 향단을 거치거나. 그래서 몽룡과 향단이 **0.5씩** 나눠 갖는다. 나머지 쌍은 바로 이어져 있어 아무도 거치지 않는다.

➔ 무리 안에서의 인기가 아니라 **무리와 무리를 잇는 다리**에 높은 점수를 준다.

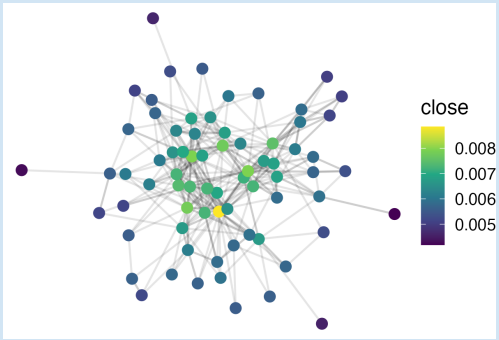
연결 중심성 vs. 고유벡터 중심성

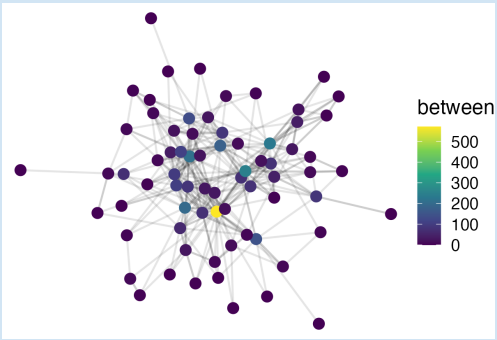




- 거의 같은 무늬다. 많이 이어진 노드는 대개 중심인 노드와도 이어져 있다.
- 고유벡터 쪽은 밝은 점이 **가운데 몇 명에게 더 몰려** 있다. 교재는 이것이 색의 눈금을 일정한 간격으로 나눈 탓이 크다고 말한다.

근접 중심성 vs. 매개 중심성





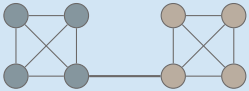
- 근접 중심성은 가운데에서 바깥으로 **부드럽게** 옅어진다.
- 매개 중심성은 대부분 0 근처이고 몇 명만 튄다. 다리가 되는 자리는 **드물다**.

순위로 나란히 놓으면

	연결	고유벡터	근접	매개
1	Shakespeare	Shakespeare	Shakespeare	Shakespeare
2	Wordsworth	Wordsworth	Wordsworth	T. S. Eliot
3	T. S. Eliot	**Milton**	T. S. Eliot	**Auden**
4	Dryden	T. S. Eliot	Dryden	Wordsworth
5	Shelley	Dryden	Shelley	Dryden
6	Milton	Keats	Auden	Shelley
7	Keats	Shelley	Milton	**Chaucer**
8	Auden	Spenser	Johnson	Austen

- **Milton**: 고유벡터 3위, 매개 10위. 중심 인물과 두루 이어졌지만 다리는 아니다.
- **Auden**: 고유벡터 13위, 매개 3위. 1930년대 작가 무리가 바깥과 맺은 22쌍 중 12쌍을 맡는다.
- **Chaucer**: Marie de France는 Chaucer를 거쳐야만 나머지에 닿는다.

군집(cluster) 찾기



정의

노드를 무리로 나누되, **무리 안의 에지는 많고 무리 사이의 에지는 적게** 나눈다.

hdir가 쓰는 방법 (walktrap)

에지를 따라 무작위로 걸으면 촘촘한 무리 안에서 오래 맴돌게 된다. 걷는 동안 **자주 함께 지나는** 노드를 한 무리로 묶는다.

⚠ `cluster` 열은 <chr>이다. 번호는 이름표일 뿐 크기나 순서의 뜻이 없다.

군집을 색으로




```
1 geom_point(
2   aes(color = cluster),
3   size = 5)
```

그림의 한계

색이 여덟 개만 되어도 구별하기 어렵다. 누가 어느 무리인지는 **표로** 읽는다.

➔ 큰 무리 넷, 그리고 바깥의 외톨이를 포함한 작은 무리 넷이 나왔다.

💡 `cluster`가 글자 열이라 `ggplot`은 색을 **따로따로** 고른다(3강).

군집을 표로 읽는다

```
node |>
  group_by(cluster) |>
  summarize(id = paste(id, collapse = "; ")) |>
  select(id)
```

```
1 Geoffrey Chaucer; William Langland; John Gower; John Dryden; Philip Sidne…
2 Charles Dickens; T. S. Eliot; George Bernard Shaw; W. B. Yeats; George Or…
3 William Wordsworth; John Keats; Lord Byron; Samuel Taylor Coleridge; Alfr…
4 W. H. Auden; Stephen Spender; Cecil Day-Lewis; Christopher Isherwood; Lou…
5 George Herbert; Henry Vaughan
```

대략 이렇게 읽힌다

1번 중세–18세기, **2번** 19세기 말–20세기, **3번** 낭만주의와 19세기, **4번** 1930년대 Auden 무리, **5번** 17세기 종교 시인 둘.

경계가 깔끔하지는 않다

1번에 Beatrix Potter가, 3번에 Virginia Woolf가 끼어 있다. 왜 그런지 묻는 데서 해석이 시작된다.

1 관계를 데이터로

2 위키백과 링크 네트워크

3 중심성과 군집

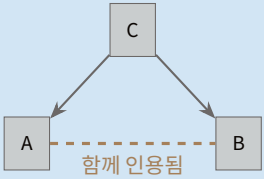
4 네트워크를 달리 정의하기
공인용 네트워크
방향 네트워크
텍스트 거리로 잇기

5 마무리

인용 대신 공인용

인용 네트워크의 약점

- 옛 글은 새 글을 인용할 수 없다(출판 순서).
- 긴 글일수록 링크를 많이 건다(분량).
- 몇 개만 바뀌어도 결과가 흔들린다.



공인용(co-citation)

제3의 문서 C가 A와 B를 **함께** 인용하면 A와 B를 잇는다. 같은 자리에서 함께 언급된다는 것은 관련이 있다는 뜻이라고 본다.

교재가 소개하는 SignsAt40 프로젝트는 페미니즘 학술지 *Signs*의 40년치 논문을 공인용 네트워크로 살폈다.

공인용 자료

```
page_cocitation <- read_csv(
  file.path("hdr", "data",
    "wiki_uk_cocitations.csv"))

set.seed(1)
nwork <- page_cocitation |>
  filter(count > 6) |>
  hdir_network_metrics()
node <- nwork$node
edge <- nwork$edge
```

```
# A tibble: 2,114 × 3
  doc_id           doc_id_out     count
  <chr>            <chr>          <dbl>
1 Marie de France  Matthew Arnold     1
2 Marie de France  Oscar Wilde        2
3 Marie de France  Samuel Pepys       1
4 Marie de France  T. S. Eliot        1
# ℹ 2,110 more rows
```

- count는 두 페이지에 함께 링크를 건 **위키백과의 다른 페이지 수**다. 방향이 없으므로 doc_id가 언제나 알파벳 순으로 앞에 온다.
- count > 6, 곧 **일곱 번 이상** 함께 인용된 쌍만 잇는다. 2,114쌍 가운데 303쌍이 남는다.
- ⚠ 6이라는 문턱은 정답이 아니라 연구자가 고른 값이다.

이번에는 Milton이 1위다

```
node |>
  arrange(desc(eigen)) |>
  select(id, degree, eigen)
```

```
# A tibble: 67 × 3
  id                  degree eigen
  <chr>                <dbl> <dbl>
1 John Milton             36 1
2 Charles Dickens         30 0.891
3 John Dryden             23 0.772
4 George Orwell           25 0.770
5 William Shakespeare     23 0.770
6 William Blake           23 0.768
7 Samuel Johnson          21 0.766
8 T. S. Eliot             23 0.731
# ℹ 59 more rows
```

읽는 법

Shakespeare가 5위로 내려갔다. Milton은 17세기 인물, 시인, 종교적 주제를 다룬 작가와 두루 함께 언급되어 36명과 이어졌다.

→ 위키백과는 계속 고쳐지는 문서라 인용과 공인용의 차이가 작은 편이다. 교재는 학술 인용이나 판례에서는 차이가 **훨씬 크다**고 말한다.

방향을 되살리면

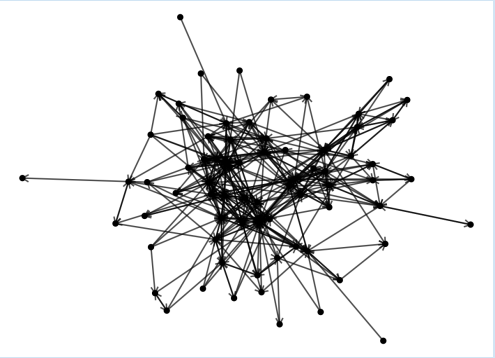
```
set.seed(1)
nwork <- hdir_network_metrics(page_citation, directed = TRUE)
nwork$node |>
  select(id, degree_out, degree_in, degree_total)
```

```
# A tibble: 72 × 4
  id               degree_out degree_in degree_total
  <chr>                 <dbl>     <dbl>        <dbl>
1 Marie de France           1         0            1
2 Geoffrey Chaucer          6        10           16
3 William Langland          0         3            3
4 John Gower                3         2            5
# ℹ 68 more rows
```

➔ degree가 셋으로 갈린다. 나가는 링크(degree_out), 들어오는 링크(degree_in), 그 합(degree_total). 합은 방향 없이 센 degree와 같다.

⚠ close 열은 사라진다. eigen은 방향을 무시해 값이 그대로지만, between은 화살표를 따라 다시 잰다(Shakespeare 571 → 943). 교재 본문의 설명과 다르다.

화살표로 그리면



바꾼 곳

`geom_segment()` 안에 한 줄을 더한다.

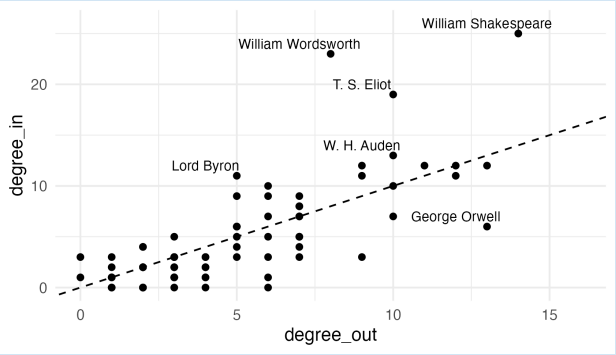
```
1 arrow = arrow(
2   length = unit(0.02, "npc"))
```

그러나

화살표 377개가 겹치면 **실뭉치**가 된다.

➔ 화살표는 노드가 열 개 남짓한 **작은 네트워크**에서나 도움이 된다. 큰 네트워크의 방향은 그림보다 **수로** 읽는다.

받는 쪽과 거는 쪽



점선 위: 받는 쪽

Wordsworth는 8개를 걸고 23개를 받는다. Byron도 5개를 걸고 11개를 받는다.

점선 아래: 거는 쪽

Orwell은 13개를 걸고 6개만 받는다.

➔ Orwell은 후대 작가라 앞 세대를 인용하지만, 앞 세대의 페이지가 그를 부를 일은 적다. **시간이 방향을 만든다.**

❗ 같은 degree라도 방향을 나누면 **부르는 쪽과 불리는 쪽**이 갈린다.

어휘가 비슷하면 잇는다

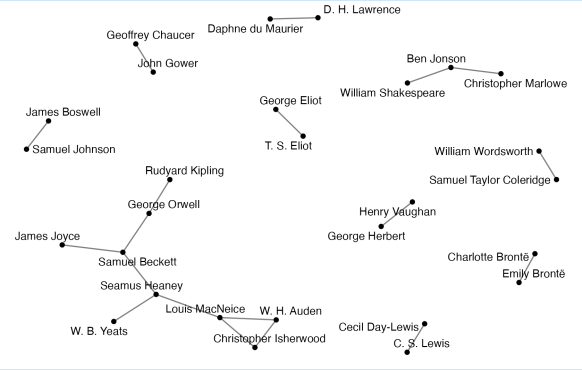
```
library(cleanNLP)

edges <- anno |>
  cnlp_utils_tfidf(token_var = "lemma") |>
  hdir_tidy_angle_distance() |>
  filter(document1 != document2) |>
  arrange(distance) |>
  filter(distance < 0.4) |>
  select(document1, document2)

set.seed(1)
nwork <- hdir_network_metrics(edges)
```

- anno는 8강에서 읽은 토큰 표, 거리는 8강의 **각도 거리**다.
- 링크가 아니라 **어휘가 비슷한 정도**로 잇는다. 각도 거리가 0.4보다 작은 쌍만 에지가 된다.

거리 네트워크



작은 무리 여럿

Chaucer와 Gower, Jonson과 Shakespeare처럼 **시대와 형식**으로 묶인다.

8강의 함정

두 Lewis, 두 Eliot. **성이 같아서** 이어졌다.

➔ 링크 네트워크에서 사라졌던 Charlotte Brontë가 여기서는 Emily와 곧바로 이어진다.

⚠ 두 명짜리 덩어리는 모두 `eigen`이 1이다. 덩어리마다 따로 계산한 탓이다.

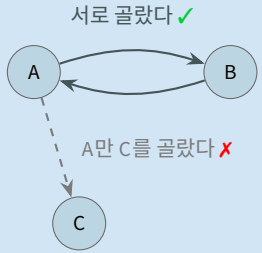
대칭 최근접 이웃 네트워크

문턱 대신 순위

거리 0.4 같은 문턱 하나를 쓰면 어떤 노드는 이웃이 수십, 어떤 노드는 0이 된다. 대신 각자 **가장 가까운 다섯**만 고른다.

서로 골라야 잇는다

A가 고른 다섯 안에 B가 있고, B가 고른 다섯 안에도 A가 있을 때만 에지를 만든다.



➔ 어느 노드도 에지가 5개를 넘지 않는다. 인기 있는 몇 노드에 에지가 몰리지 않고 **고르게 짜인** 네트워크가 된다.

💡 최근접 이웃(nearest neighbor)은 거리가 가장 가까운 상대라는 뜻이다.

코드 (1) 각자 가장 가까운 다섯

```
dists <- anno |>
  filter(upos %in% c("NOUN", "ADJ", "ADV", "VERB")) |>
  cnlp_utils_tfidf(token_var = "lemma") |>
  hdir_tidy_angle_distance() |>
  filter(document1 != document2) |>
  arrange(distance)

top_dists <- dists |>
  group_by(document1) |>
  arrange(distance) |>
  slice(1:5) |>          # 작가마다 앞의 다섯 행
  ungroup()
```

- dists는 8강의 각도 거리다. 이번에는 명사·형용사·부사·동사만 남겨 쟀다.
- top_dists는 75명 × 5 = 375행이다. 곰돌이 푸의 Milne이 고른 첫째는 피터 래빗의 Beatrix Potter(거리 0.382)다.

코드 (2) 서로 고른 쌍만

```
edges <- top_dists |>
  semi_join(top_dists, by = c("document1" = "document2",
                              "document2" = "document1")) |>
  select(document1, document2) |>
  filter(document1 < document2)    # 같은 쌍을 한 번만

set.seed(1)
nwork <- hdir_network_metrics(edges)
```

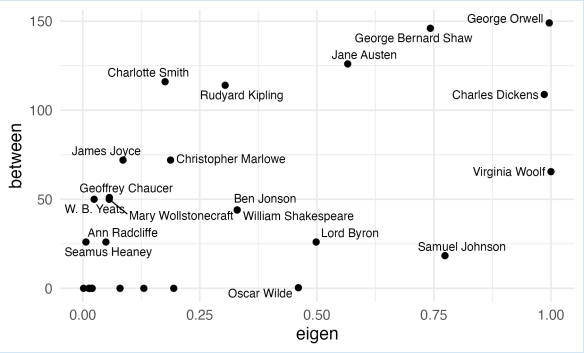
semi_join

5강의 anti_join과 짝이다. 상대 표에 **짝이 있는** 행만 남긴다. (A, B)는 (B, A)가 top_dists에 있을 때만 살아남는다.

➔ document1 < document2는 (A, B)와 (B, A) 가운데 알파벳 순으로 앞선 것 하나만 남긴다.

❗ 에지 50개, 노드 **49개**다. 서로 고른 짝이 하나도 없는 26명은 네트워크에서 빠졌다.

문지기 찾기



따로 노는 두 지표

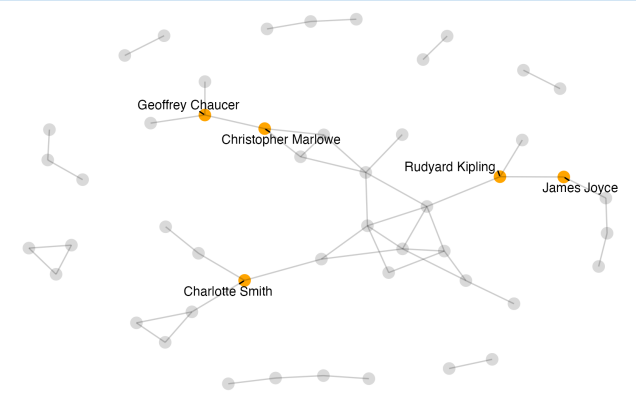
앞에서는 `eigen`과 `between`이 함께 움직였다. 여기서는 따로 논다.

문지기(gatekeeper)

`between`은 높고 `eigen`은 낮은 노드. Charlotte Smith, Kipling, Joyce, Marlowe.

➔ `eigen` 맨 위는 Woolf·Orwell·Dickens다. Shakespeare는 10위로 내려갔다.

문지기가 선 자리



색칠한 기준

`between > 50`이면서 `eigen < 0.5`인 노드를 주황색으로 칠했다.

읽는 법

지우면 가장 큰 덩어리가 **여러 조각으로** 갈라지는 자리에 서 있다.

⚠ 교재 본문은 네 명을 꼽지만 코드의 기준으로는 Chaucer(`between` 51)도 걸린다. 문턱은 언제나 연구자의 선택이다.

고르게 나뉜 무리

	가장 큰 덩어리의 군집 (eigen 순)	**읽기**
1	Woolf, Orwell, Dickens, Johnson, Austen, Byron, Wilde, Shelley	여러 시대의 대표 작가
2	Kipling, Joyce, Conrad, Yeats, Heaney, MacNeice	넷이 아일랜드 출신
3	Shaw, Jonson, Shakespeare, Beckett, Marlowe	극작가
4	Charlotte Smith, Radcliffe, Stoker	고딕 소설
5	Chaucer, More, Gower	초기 작가
6	Wollstonecraft, Lanier, Robinson	모두 여성 작가

- ➔ 3절의 `group_by(cluster)` 코드에 `filter(component == 1)`를 더해 가장 큰 덩어리만 보았다.
- ❗ 극작가·고딕 소설가·초기 작가처럼 **문학사의 분류와 맞아떨어지는** 무리가 나온다. 링크 네트워크보다 무리의 크기도 고르다.

같은 75명, 다섯 개의 네트워크

네트워크	에지를 잇는 기준	드러난 것
인용	한 페이지가 다른 페이지에 링크	이름난 정도 (Shakespeare 중심)
공인용	제3의 페이지가 함께 링크	함께 언급되는 사이 (Milton 1위)
방향	링크의 방향을 살림	부르는 쪽과 불리는 쪽 (Orwell)
거리	각도 거리 0.4 미만	시대·형식의 작은 무리
대칭 최근접 이웃	서로의 가장 가까운 다섯	문지기와 고른 무리

❗ 자료는 하나인데 답은 다섯이다. **에지의 정의가 곧 연구 질문**이다.

➔ 어느 것이 "맞는" 네트워크인가? 8강의 PCA와 UMAP처럼 **모두 맞고 모두 일부만 보여준다.**

1 관계를 데이터로

2 위키백과 링크 네트워크

3 중심성과 군집

4 네트워크를 달리 정의하기

5 **마무리**

망치를 든 사람

교재가 인용하는 말

“망치를 들면 모든 것이 못으로 보인다.” 디지털 인문학자 Scott Weingart가 네트워크를 두고 거듭 하는 경고다.

네트워크를 쓰기 전에 물을 것

1. 노드는 무엇인가? 빠진 노드는 없는가? (사라진 세 사람)
2. 에지는 무엇을 센 것인가? 방향이 있는가? 두 번 세지는 않았는가?
3. 문턱(`count > 6`, 거리 0.4, 다섯 명)은 왜 그 값인가?
4. 설정을 바꾸면 결과가 어떻게 달라지는가?

➔ 교재의 결론: 노드와 에지를 **엄밀하게** 정의할수록 네트워크는 쓸모 있어진다.

오늘의 함수

함수	하는 일	패키지
`tribble()`	표를 한 행씩 손으로 적기	tibble
`hdir_network_metrics()`	에지 리스트 → node·edge 표	hdir
`set.seed()`	무작위 배치를 고정	base R
`geom_segment()`	선분(에지) 긋기	ggplot2
`geom_text_repel()`	겹치지 않는 이름표	ggrepel
`arrow()`	선분 끝에 화살촉	grid
`anti_join()`·`semi_join()`	짝이 없는 행 / 있는 행만 남기기	dplyr
`paste(collapse = )`	여러 글자를 하나로 잇기	base R

네트워크 계산은 모두 `igraph`가 하고, `hdir`는 그 결과를 정돈된 표 두 개로 바꿔 준다.

오늘 배운 것

관계를 표로

- 노드와 에지, 방향의 유무
- 에지 리스트 vs. 인접 행렬
- 이어지지 않은 노드는 사라진다

그리기

- node의 점 + edge의 선분
- x·y 자체에는 뜻이 없다
- `set.seed()`로 배치를 고정한다

중심성과 군집

- 연결·고유벡터·근접·매개는 다른 질문
- 매개가 높고 고유벡터가 낮으면 다리
- 군집은 그림보다 표로 읽는다

달리 정의하기

- 인용·공인용·방향·거리·최근접 이웃
- 에지의 정의가 답을 바꾼다

확인 질문

스스로 답해 보기

1. 에지 리스트만으로는 적을 수 없는 노드는 어떤 노드인가?
2. Shakespeare의 `degree`는 39인데 이어진 작가는 31명이다. 왜 다른가?
3. 춘향과 방자의 고유벡터 중심성이 같은 까닭은? 이것은 무엇을 뜻하는가?
4. 매개 중심성은 높은데 고유벡터 중심성은 낮은 노드는 어떤 자리에 있는가?
5. 인용 대신 공인용으로 네트워크를 만드는 까닭을 두 가지 들어 보라.
6. 같은 코드를 다시 돌렸더니 그림이 뒤집혔다. 무엇이 바뀌었고 무엇은 그대로인가?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간

- 10강 (2026-10-21 수) — 네트워크 데이터 사례 연습
  - 실제 논문이 사료에서 네트워크를 어떻게 뽑아내고 무엇을 근거로 결론을 내렸는지 따라가 본다.
  - Dongmin Lim (2023), “Exploring a New Methodology for Studying Korean Ancient History Using Network Analysis,” *International Journal of Korean History* 28(2).
  - 동진·16국에서 송·북위에 이르는 시기의 교섭 기록. 사신이 오간 기록이 방향 있는 에지가 된다.

더 보고 싶다면

- `igraph` R 문서 — `https://r.igraph.org/`
- Ahnert 외, *The Network Turn: Changing Perspectives in the Humanities* (2020)
- Kolaczyk & Csárdi, *Statistical Analysis of Network Data with R* (2014)
- Wasserman & Faust, *Social Network Analysis: Methods and Applications* (1994)