2026학년도 2학기 인문데이터 수량분석

제12강 시계열 데이터 사례 연습

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 10월 28일 수요일

오늘의 목표

1. 게시물의 댓글이 시계열 자료가 되는 과정과 그 한계를 설명할 수 있다.
2. 글자로 적힌 시각을 서울 시각으로 읽고, 연·월·주 단위로 세고, 이동평균으로 흐름을 볼 수 있다.
3. `str_detect()`로 특정 단어가 든 댓글을 찾고, 그 비중을 해마다 계산할 수 있다.
4. 논문의 표와 그림을 다시 계산해 맞추어 보고, 결과를 해석할 수 있다.

사전 준비

eTL에서 `shim2023.zip`을 받아 Posit Cloud의 **Files** 창에서 **Upload**로 올린다. 압축이 풀리면서 `shim2023` 폴더가 생긴다. 패키지는 `tidyverse`와 `hdir`(8강)만 쓴다.

⚠ 실제 인터넷 댓글이라 욕설과 혐오 표현이 섞여 있다. 슬라이드에는 싣지 않았다.

1 **논문 읽기**
연구 질문
쿠키닷컴과 아행행

2 댓글을 시계열로

3 단어로 시점 찾기

4 비중의 변화

5 대표 표현과 해석

6 마무리

오늘 읽을 논문

서지 정보

저자 심형준, 서울대학교 인문학연구원

제목 성지 밈(聖地 meme) 소원 댓글의 유행과 온라인 종교문화상의 함의: ‘쿠키 닷컴’ 게시물 댓글 텍스트 분석을 중심으로

학술지 『종교연구』 83(2), 2023, 287–324쪽

한 문장으로

인터넷의 ‘성지’ 게시물에 달리는 소원 댓글이 **언제, 어떤 맥락에서** 생겨났는지를 2만여 개 댓글의 시간 흐름으로 추적한다.

💡 10강에서는 논문의 표를 다시 계산했다. 오늘은 한 걸음 더 나가 **자료를 다시 모으는 데서** 시작한다.

성지 밈과 소원 댓글

성지 밈

엄청난 주목을 받아 댓글이 무수히 달린 게시물을 네티즌은 '성지'라 부른다. 종교와는 아무 관련이 없다.

소원 댓글

"성지순례 왔습니다. ◯◯하게 해주세요." 로또 당첨, 시험 합격, 이직처럼 소원을 적고 간다.

저자의 관점

놀이처럼 보이지만, 무언가가 소원을 들어주리라 전제하고 비는 **종교 밖의 종교적 실천**이다. "소원 댓글은 종교적이다"를 증명하려는 것이 아니라 그 함의를 살핀다.

➔ 종교학의 물음이다. 온라인 환경에서 생겨난 종교적 상상과 실천이 있는가?

무엇을 묻는가

논문의 질문 (292–293쪽)

1. ‘성지’라는 규정이 먼저 생기고 소원 댓글이 뒤따랐을까, 아니면 따로 발전했을까?
2. “성지순례 왔습니다. ◯◯해주세요”라는 관용구는 **언제** 자리 잡았을까?
3. 쿠키닷컴 게시물 이후 성지 밈과 소원 댓글은 어떻게 변해 갔는가?

왜 시계열인가

세 질문이 모두 ‘언제’를 묻는다. 댓글마다 적힌 **작성 시각**이 답의 재료다.

❗ “이것은 댓글에 쓰인 텍스트를 정량적으로 분석하지 않으면 알 수 없다.”(294쪽)

쿠키닷컴 게시물



오늘 산 중저가형 모델 싸게 팝니다..

복숭아맛(163.180) | 2001.07.17 17:51

조회수 916510 | 추천 2063 | 댓글 21642

오늘산 중저가형 모델인 쿠키닷컴을 팝니다. 보다 고급 기종인 칙촉으로 가고 싶어서 내 놓게 되었습니다. 롯데 정품이구요 110 종 넘게 샀는데 100정도 받고 팔고 싶습니다. 오늘 산거구 정말 아껴 사용했기 때문에 비싼 가격은 아니라구 생각합니다. 위 사진에 보시는 것 처럼 물건은 깨끗하구요.(모서리에 약간의 기스가 있는데 사용엔 별 지장 없습니다) 비닐 케이스도 같이 드립니다. 필요 하시다면 두번 밖에 사용 안한 종이 컵(시가 50상당)도 같이 드립니다. 악성 리플 사양 하구요. 꼭 사실분만 연락 바랍니다.

언제, 어디에

2001년 7월 17일, 디시인사이드 HIT 갤러리(인기 글 모음)의 12번째 글.

무엇을

디지털카메라 중고 매물 글을 흉내 내, 먹다 만 과자 '쿠키닷컴'을 판다.

반응

첫 나흘 동안 댓글 15, 75, 165, 167개. 인기 글도 대개 200개 안팎이던 때다(293쪽).

리플의 신화에서 '성지'로

신기록 놀이 (2001년 여름)

"리플 신기록인가...??" "리플의 신화는계속된다∼∼" 댓글 수 자체가 놀이가 되었다. 1,500개를 넘자 '역사의 현장', '신화'라는 말이 붙었다.

성지 (2002년 여름)

1년 뒤 댓글이 5,000개에 다가갈 무렵: "수많은 행자들의 성지라오.." 열흘 남짓 뒤: "성지 순례 하고 갑니다."

- ➔ 리플은 댓글(reply)을 이르던 말이다. 논문은 이 말들을 댓글 원문에서 골라 인용했다 (294쪽).
- 💡 3절에서 이 댓글들을 **우리 자료에서 직접** 찾아 날짜를 맞추어 본다.

아행행과 행자

아행행

2002–2003년 디시인사이드에서 유행한 신조어. 엽기적인 것 앞의 실소에서 나와, 낮에 자고 밤에 라면으로 끼니를 때우는 '폐인' 생활을 스스로 일컫는 말이 되었다.

행자와 수행

그 생활에 **수행**(修行)의 뉘앙스가 붙어 수행, 행자 같은 말이 생겼다(298쪽 각주 14). 댓글에는 자기를 '소행'이라 낮추고 "새우겠소", "다녀가오"처럼 맺는 말투가 흔하다.

- 수행자들이 모이는 곳이니 '성지'요, 찾아오는 것은 '순례'다. 행자라는 말이 종교적 연상을 아주 자연스럽게 만들었다(298쪽).
- 이 말투는 5절의 TF-IDF에서 다시 만난다.

논문의 방법, 오늘의 방법

단계	논문 (Python)	오늘 (R)
모으기	selenium으로 댓글 수집	다시 모은 CSV
정리하기	삭제·중복 댓글, 결측 빼기	`distinct()`
단어 나누기	KoNLPy의 Okt 형태소 분석	띄어쓰기로 자르기
세기	연도별 빈도, 단어가 든 댓글의 비중	`count()`, `str_detect()`
중요도	연도·시기별 TF-IDF	`hdir_text_tfidf()` (8강)

➔ 도구는 달라도 **같은 질문에 같은 답이 나오는지** 본다. 10강의 재현과 같은 일이다.

💡 논문은 코드와 자료를 GitHub에 공개했다고 적었다(295쪽 각주 8). 다음 절에서 그 저장소에 무슨 일이 있었는지 본다.

1 논문 읽기

2 **댓글을 시계열로**
다시 모은 자료
연·월·주 단위로 세기

3 단어로 시점 찾기

4 비중의 변화

5 대표 표현과 해석

6 마무리

사라진 저장소

논문의 약속

"관련 코드와 데이터셋은 Github(…onlinesacredplace.info)에 공개하였다."(295쪽 각주 8) 작년 이 수업도 거기서 CSV를 바로 읽었다.

2026년 10월

저장소가 통째로 사라졌다. 주소는 404 Not Found이고 웹 아카이브에도 남아 있지 않다. 작년 실습 코드는 첫 줄부터 돌지 않는다.

그래서

원 게시물은 아직 열려 있다. 2026년 10월 3일, 달린 댓글 21,831개를 **다시 모았다**.

- 자료가 사라지면 남이 그 연구를 다시 따라갈 길도 사라진다. 5절에서 다시 본다.

다시 모으며 손본 것

손본 것	개수	까닭
광고(댓글돌이)·삭제된 댓글 빼기	2	댓글이 아니다
그림(디시콘)만 있는 댓글 빼기	48	글자가 없다
올해 댓글의 날짜에 2026 채우기	41	연도 없이 보인다 (`09.26 17:25:49`)
닉네임·IP 앞자리를 작성자 번호로	전부	개인정보 (`w00001` 꼴)
이메일·전화번호·번지 가리기	75	개인정보

➔ 21,831개에서 50개를 빼 **21,781개**가 남았다. 한 행이 댓글 하나다.

⚠ 2001년에는 중고 거래 흉내를 내며 진짜 연락처를 적은 댓글이 많았다. 규칙으로 가렸으므로 빠진 것이 있을 수 있다. 내려받은 자료는 수업 밖으로 옮기지 않는다.

자료 읽기

```
1 library(tidyverse)
2 comments <- read_csv(file.path("shim2023", "comments.csv"))
3 comments
```

```
# A tibble: 21,781 × 4
     id writer datetime            text
  <dbl> <chr>  <chr>               <chr>
1     1 w00001 2001.07.17 17:55:57 아참 운송료 미포함 가격 입니다.
2     2 w00002 2001.07.17 18:03:12 재미없스....
3     3 w00003 2001.07.17 18:13:45 야~ 참 재밋스신 분이시네요...한참 웃엇…
4     4 w00004 2001.07.17 18:57:20 >> ㅏ~~~~~~~ 안사안사~~~~~~~~
# i 21,777 more rows
```

➔ 게시물이 올라온 지 4분 뒤의 첫 댓글은 글쓴이의 덧붙임이다. “아참 운송료 미포함 가격 입니다.”

⚠ datetime이 <chr>(글자)다. 2001.07.17처럼 점으로 적은 날짜는 read_csv()가 알아보지 못한다. ISO 8601의 2001-07-17이어야 한다(6·11강).

서울 시각으로 읽기

```
comments <- comments |>
  mutate(datetime = ymd_hms(datetime, tz = "Asia/Seoul"))
comments
```

```
# A tibble: 21,781 × 4
     id writer datetime            text
  <dbl> <chr>  <dttm>              <chr>
1     1 w00001 2001-07-17 17:55:57 아참 운송료 미포함 가격 입니다.
2     2 w00002 2001-07-17 18:03:12 재미없스....
# i 21,779 more rows
```

➔ `tz =`를 주면 적힌 시각은 그대로 두고 **서울 시각**이라는 이름표만 붙인다. 11강의 `force_tz()`와 같은 일이다. 디시인사이드는 서울 시각으로 보여 준다.

⚠ `tz`를 빼면 UTC 이름표가 붙는다. 그 상태로 `with_tz()`로 서울 시각을 보면 **9시간이 어긋난다**(11강).

첫 나흘

```
comments |>
  count(day = as_date(datetime)) |>
  head(4)
```

```
# A tibble: 4 × 2
  day             n
  <date>      <int>
1 2001-07-17     15
2 2001-07-18     75
3 2001-07-19    165
4 2001-07-20    167
```

count() 안에서 새 열

count(day = as_date(datetime))은 mutate()로 day 열을 만든 뒤 count(day)를 한 것과 같다.

✓ 논문 본문(293쪽)의 15, 75, 165, 167개와 같다. 첫 확인을 통과했다.

➔ 자료가 이미 시각 순서로 놓여 있어 head()가 곧 '가장 이른 것'이다.

해마다 몇 개

```
comments |>
  count(year = year(datetime))
```

```
# A tibble: 26 × 2
   year     n
  <dbl> <int>
1  2001  3480
2  2002  3828
3  2003  5433
4  2004  2440
5  2005   687
6  2006    26
# i 20 more rows
```

논문 표 1

2001년 3,480, 2002년 3,828, 2003년 5,433, 2004년 2,440, 2005년 688, 2006년 26.

2006년의 26개

한 해 내내 26개뿐이다. 1차 유행이 끝난 뒤의 바닥이다.

➔ 2005년만 하나가 적다. 본문이 비어 있는 댓글 하나를 우리가 뺐기 때문이다.

논문 표 1과 나란히

연도	2001	02	03	04	05	06	07	08	09	10	11	12	13
논문(2023.2)	3,480	3,828	5,433	2,440	688	26	421	1,103	428	403	278	155	261
우리(2026.10)	3,480	3,828	5,433	2,440	**687**	26	421	1,103	428	403	278	155	261

연도	2014	15	16	17	18	19	20	21	22	23	24	25	26
논문(2023.2)	296	225	923	93	207	493	216	156	91	5			
우리(2026.10)	295	224	919	88	203	487	203	149	80	70	41	38	41

✓ 2001–2013년은 2005년 하나를 빼고 **모두 같다**. 같은 게시물을 다시 모았다는 증거다.

➔ 2014년 이후에 조금씩 적은 것은 대부분 디시콘만 있는 댓글 48개를 뺀 몫이다. 이를 되살리면 2015–2018년은 같고, 남는 차이(1–4개)는 그사이 지워진 댓글이다.

💡 논문의 2023년은 2월 초까지의 5개다. 그 뒤로 185개가 더 달렸다.

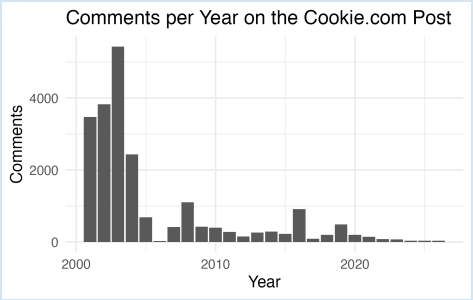
그림 3 다시 그리기

```
comments |>
  count(year = year(datetime)) |>
  ggplot(aes(year, n)) +
    geom_col() +
    labs(
      title = "Comments per Year on the Cookie.com Post",
      x = "Year", y = "Comments"
    )
```

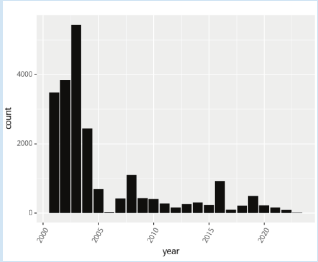
- 남에게 보일 그림이므로 `labs()`로 **제목과 축 이름**을 붙인다(3강, 숙제 04). `year`, `n` 같은 열 이름을 그대로 두지 않는다.
- → 3강의 형식대로 `ggplot()` 아래의 층은 네 칸 들여 쓴다. 오늘의 그림 코드는 모두 이렇게 쓴다.
- 그림 안의 글자는 3·5강처럼 영어로 썼다.

논문 그림 3과 나란히

우리 그림



논문 그림 3 (295쪽)



➔ 2004년까지 전체의 70%(15,181개)가 달렸다. 논문은 2001–2005년, 2008년, 2016년, 2019년을 유행기로 보았다.

💡 논문의 그림은 축 이름이 `year`, `count`로 열 이름 그대로이고 제목은 본문의 캡션이 대신한다.

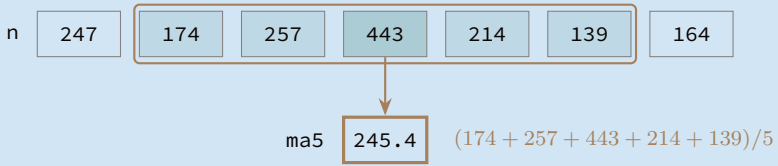
달마다 몇 개

```
comments |>
  count(month = floor_date(
    datetime, "month")) |>
  ggplot(aes(month, n)) +
    geom_line() +
    labs(
      title = "Comments per Month",
      x = "Month", y = "Comments"
    )
```



- `floor_date()`로 시각을 그달 1일 0시로 내린다(11강). 가장 많은 달은 2001년 8월(1,284개)이다.
- 2008년 8월(269), 2016년 7월(549), 2019년 11월(172)에 봉우리가 다시 솟는다. 무엇 때문인지는 3·4절에서 본다.

이동평균: 들쭉날쭉한 선 고르기



이동평균(moving average)

한 칸을 그 칸과 앞뒤 칸들의 평균으로 바꾼다. 들쭉날쭉한 오르내림이 눌려 **큰 흐름**이 드러난다.

11강의 `lag()`·`lead()`

두 칸 앞은 `lag(n, 2)`, 두 칸 뒤는 `lead(n, 2)`. 다섯 개를 더해 5로 나누면 '5주 이동평균'이다.

⚠ 한 행이 꼭 한 주여야 한다. 댓글이 없는 주는 행이 빠져, 다섯 행이 다섯 주가 아니게 된다(11강의 '사라진 열 행').

주마다 세고 이동평균 내기

```
weekly <- comments |>
  filter(year(datetime) < 2005) |>
  count(week = floor_date(
    datetime, "week")) |>
  mutate(ma5 = (lag(n, 2) +
    lag(n) + n + lead(n) +
    lead(n, 2)) / 5)
weekly
```

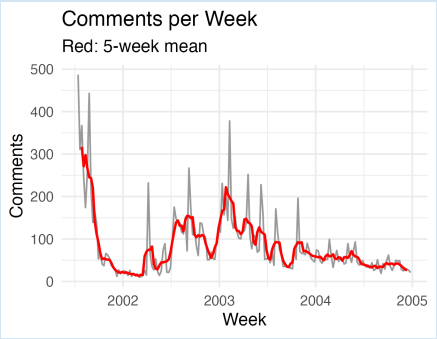
```
# A tibble: 181 × 3
  week                  n   ma5
  <dttm>              <int> <dbl>
1 2001-07-15 00:00:00   487   NA
2 2001-07-22 00:00:00   311   NA
3 2001-07-29 00:00:00   367  317.
4 2001-08-05 00:00:00   247  271.
5 2001-08-12 00:00:00   174  298.
6 2001-08-19 00:00:00   257  267
7 2001-08-26 00:00:00   443  245.
8 2001-09-02 00:00:00   214  243.
# i 173 more rows
```

➔ 첫 두 주는 NA다. 앞에 두 주가 없다. 마지막 두 주도 그렇다.

✓ 2001–2004년의 181주에는 모두 댓글이 있다. 빠진 주가 없으니 이동평균을 믿을 수 있다.

세 번의 물결

```
weekly |>
  ggplot(aes(week)) +
    geom_line(aes(y = n),
              color = "gray60") +
    geom_line(aes(y = ma5),
              color = "red") +
    labs(
      title = "Comments per Week",
      subtitle = "Red: 5-week mean",
      x = "Week", y = "Comments"
    )
```



- 선이 둘이라 `geom_line()`마다 `aes(y = )`를 따로 준다. 색의 뜻은 범례 대신 부제(`subtitle`)로 알렸다.
- 2001년 여름의 첫 물결 뒤, **2002년 가을**과 **2003년 초**에 물결이 다시 온다. 아행행이 유행하고 '성지'라는 말이 생긴 때다.

1 논문 읽기

2 댓글을 시계열로

3 **단어로 시점 찾기**
글자가 든 댓글
사건 전후 비교

4 비중의 변화

5 대표 표현과 해석

6 마무리

str_detect(): 글자가 들어 있는가

```
1 str_detect(c("성지순례 왔습니다", "리플 신기록", "실리콘 합성지"), "성지")
```

```
[1]  TRUE FALSE  TRUE
```

str_detect(글자열, 찾을 글자)

들어 있으면 TRUE, 없으면 FALSE.
결과가 논리값이라 filter() 안에 그대로 넣는다.

stringr

글자를 다루는 함수 모음이다.
tidyverse에 들어 있고, 이름이 모두 str_로 시작한다.

⚠ '합성지'에도 '성지'가 들어 있다. 글자가 **들어 있는지만** 볼 뿐 뜻은 모른다.

처음으로 '성지'가 나온 댓글

```
comments |>
  filter(str_detect(text, "성지")) |>
  select(datetime, text) |>
  head(2)
```

```
# A tibble: 2 × 2
  datetime            text
  <dttm>              <chr>
1 2001-07-31 23:44:17 프링글스 껍데기 필통으로 만든것과 어떻게 교환 안될까요?실…
2 2002-07-25 21:23:07 수많은 햄자들의 성지라오..
```

⚠ 첫 행은 "…실리콘 **합성지**라 방수도 됩니다"다. 바로 앞 장의 함정이다.

✓ 둘째 행이 논문이 인용한 첫 '성지'다(294쪽). 게시물이 올라온 지 1년, 4,817번째 댓글이다.

💡 규칙이 고른 것을 몇 개라도 **직접 읽어 보아야** 이런 것을 잡는다(11강의 되돌림 규칙).

‘성지 순례’와 정규 표현식

```
comments |>
  filter(str_detect(text, "성지 ?순례")) |>
  select(datetime, text) |>
  head(1)
```

```
# A tibble: 1 × 2
  datetime            text
  <dttm>              <chr>
1 2002-08-07 09:23:57 성지 순례 하고 갑니다. Ah~ Ye~ (2002-08-07) am9:10
```

정규 표현식(regular expression)

찾을 글자에 규칙을 적는다. ?는 바로 앞 글자(여기서는 빈칸)가 있어도 없어도 된다는 뜻이라 "성지 ?순례"는 ‘성지순례’와 ‘성지 순례’를 모두 찾는다. |는 ‘또는’이다.

✓ 논문이 든 첫 ‘성지순례’와 같은 댓글이다. 첫 ‘성지’에서 13일 뒤다.

소원은 언제부터

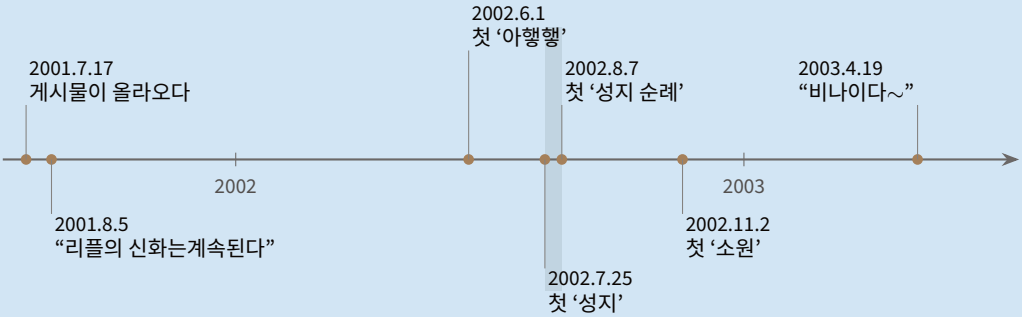
```
comments |>
  filter(str_detect(text, "소원")) |>
  select(datetime, text) |>
  head(3)
```

```
# A tibble: 3 × 2
  datetime            text
  <dttm>              <chr>
1 2002-11-02 01:50:12 여기가... 소원 쌔우면 이루어진다는 곳이오?
2 2003-01-17 00:01:39 마지막리플이되기를비오,그리고 여자친구생기길.소원도한번 빌…
3 2003-02-14 01:40:20 소원하나 쌔우겠소 소햏 원하는 대학 가고 싶다오..간절하오..
```

➔ '성지'라 불린 지 석 달 뒤, 이곳이 "소원 쌔우면 이루어진다는 곳"이냐는 물음이 나온다. 이듬해 초부터 소원이 하나둘 달린다. 여기서 '쌔우다'는 행자들의 말로 '(소원을) 빌다'쯤의 뜻이다.

✓ 논문이 든 2003년 4월 19일의 "비나이다~ 비나이다~"(304쪽 각주 19)도 "비나이다"로 찾으면 맨 처음에 나온다.

우리가 찾은 날짜



- ‘성지’라는 이름은 유행의 **한복판**에서, 아행행이 퍼진 직후에 생겼다. 소원은 그 뒤에 따라왔다. 논문의 첫째 질문에 대한 답이다.
- 첫 ‘아행행’도 `str_detect(text, "아햏햏")`으로 찾았다.

2008년, ‘성지 전쟁’

빠삐놈

같은 HIT 갤러리에 올라온 패러디 동영상 게시물이다. 빙과 ‘빠삐코’의 광고 노래에 여러 영상을 섞었다. 12일 만에 댓글 16,700여 개가 달려 그해 쿠키닷컴의 기록을 넘어섰다(296쪽).

성지 방어

‘댓글이 가장 많은 게시물’이라는 자리를 지키자는 댓글이 쿠키닷컴에 몰렸다. 2008년의 1,103개, 논문이 말한 2차 유행기다.

➔ 사건 하나가 시계열을 흔들었다면, 그 **전후**를 나란히 놓아 얼마나 달라졌는지 잰다. 그러려면 먼저 사건이 언제였는지를 정해야 한다.

사건은 언제였나

```
comments |>
  filter(str_detect(text, "빠삐|성지 ?방어")) |>
  select(datetime, text) |>
  head(3)
```

```
# A tibble: 3 × 2
  datetime            text
  <dttm>              <chr>
1 2008-07-25 00:12:17 빠바라 빠빠라밤~ 삐삐리 빠삐코 hey!
2 2008-07-25 19:47:33 빠바라 빠빠라 밤 삐삐리 빠삐코 hey~ 빠바라 빠빠라 밤 삐삐…
3 2008-07-26 03:16:04 빠삐놈이 더 낳네여 ㅈㅅ
```

- 2008년 7월 25일에 빠삐코 광고 노래가 처음 나온다. 8월 2일에는 “성지방어성지방어…”가 달린다.
- 이 자료로 정할 수 있는 사건 시점은 **7월 25일**이다. 빠삐놈 게시물이 올라온 날은 아닐 수 있다.

앞뒤 4주를 나란히

```
event <- ymd("2008-07-25")
comments |>
  mutate(day = as_date(datetime)) |>
  filter(day >= event - 28, day < event + 28) |>
  mutate(period = if_else(day < event, "before", "after")) |>
  count(period) |>
  mutate(per_day = n / 28)
```

```
# A tibble: 2 × 3
  period      n per_day
  <chr>   <int>   <dbl>
1 after     393    14.0
2 before     56     2
```

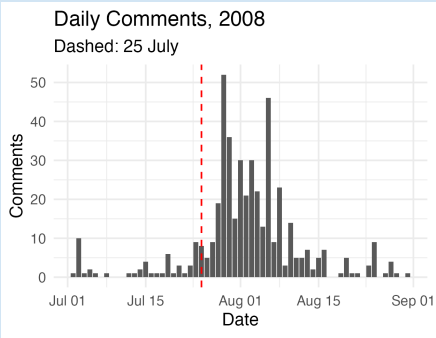
일곱 배

하루 평균 2개에서 14개로. <date>에 28을 더하고 빼면 4주 앞뒤다(11강).

⚠ count(day)로 하루씩 센 표의 평균을 내면 2.43과 15.1이 나온다. 댓글이 없는 날은 **행이 없기** 때문이다. 날 수(28)로 나누어야 한다.

그림으로 보는 전후

```
comments |>
  filter(year(datetime) == 2008,
         month(datetime) %in% 7:8) |>
  count(day = as_date(datetime)) |>
  ggplot(aes(day, n)) +
    geom_col() +
    geom_vline(xintercept = event,
               linetype = "dashed",
               color = "red") +
    labs(
      title = "Daily Comments, 2008",
      subtitle = "Dashed: 25 July",
      x = "Date", y = "Comments"
    )
```



➔ 세로선은 `geom_vline()`. 사흘 뒤 치솟아 3주 만에 가라앉는다. 효과는 **짧았다**.

1 논문 읽기

2 댓글을 시계열로

3 단어로 시점 찾기

4 **비중의 변화**
되풀이된 글 걸러 내기
단어마다 비중

5 대표 표현과 해석

6 마무리

2016년의 봉우리

```
comments |>
  filter(year(datetime) == 2016) |>
  group_by(writer) |>
  summarize(n = n(),
    texts = n_distinct(text)) |>
  arrange(desc(n))
```

```
# A tibble: 148 × 3
  writer      n texts
  <chr>   <int> <int>
1 w16648    327     1
2 w16638    207     1
3 w16646    201     1
4 w16655     10     1
5 w16687      6     6
# i 143 more rows
```

n_distinct()

서로 다른 값이 몇 개인지 센다. texts가 1이면 같은 글만 되풀이했다.

⚠ 세 작성자 번호가 **같은 11글자 문장 하나**를 735번 올렸다. 전직 대통령을 비하하는 문장이다(논문 각주 10). 같은 문장이 2019년에도 413번 나온다. 2016·2019년의 봉우리는 사실상 이 도배다.

distinct()로 걸러 내기

```
cleaned <- comments |>
  distinct(day = as_date(datetime),
           text, .keep_all = TRUE)
nrow(cleaned)
cleaned |>
  count(year = year(datetime)) |>
  filter(year %in% c(2016, 2019))
```

```
[1] 20190
```

```
# A tibble: 2 × 2
   year     n
  <dbl> <int>
1  2016   181
2  2019    90
```

distinct()

고른 열의 값이 모두 같은 행은 처음 하나만 남긴다. 여기서는 '같은 날, 같은 글'이다. `.keep_all = TRUE`는 나머지 열도 버리지 않고 남긴다.

➔ 2016년은 919개에서 181개로, 2019년은 487개에서 90개로 줄었다. 논문은 170개와 81개(296쪽)다. 논문은 '비슷한 시기'를 기준으로 삼아 조금 다르다. 이제부터는 `cleaned`를 쓴다.

TRUE의 평균은 비율이다

```
x <- c(TRUE, FALSE,
       FALSE, TRUE)
sum(x)
mean(x)
```

```
[1] 2
[1] 0.5
```

논리값으로 셈하기

계산에 넣으면 TRUE는 1, FALSE는 0이 된다. `sum()`은 TRUE의 개수, `mean()`은 TRUE의 **비율**이다.

그래서

`mean(str_detect(text, "성지"))`는 '성지'가 든 댓글의 비율이다.

왜 개수가 아니라 비율인가? 댓글이 2003년에는 5,418개, 2006년에는 26개다. 해마다 댓글 수가 크게 다르니 개수끼리는 비교할 수 없다.

해마다 네 가지 비중

```
shares <- cleaned |>
  group_by(year = year(datetime)) |>
  summarize(n = n(),
            reply      = mean(str_detect(text, "리플")),
            hang       = mean(str_detect(text, "행")),
            pilgrimage = mean(str_detect(text, "성지 ?순례")),
            wish       = mean(str_detect(text, "해 ?주|싶")))
```

열	찾는 글자	가리키는 것
reply	리플	댓글 신기록 놀이
hang	행	아행행·행자·소행
pilgrimage	성지순례, 성지 순례	성지순례
wish	해주, 해 주, 싶	소원(“…하게 해주세요”, “…하고 싶다”)

➔ 논문이 고른 표제어(299쪽)와 소원 표현(‘해주-’, ‘싶-’, 303–304쪽)을 따랐다.

결과 표

```
1 shares
```

```
# A tibble: 26 × 6
   year      n  reply   hang pilgrimage    wish
  <dbl> <int>  <dbl>  <dbl>      <dbl>   <dbl>
1  2001  3470 0.163  0          0       0.0507
2  2002  3825 0.207  0.08       0.00314 0.0327
3  2003  5418 0.172  0.0973     0.0653  0.0343
4  2004  2438 0.135  0.0628     0.228   0.0242
5  2005   686 0.0918 0.0233     0.302   0.0321
6  2006    26 0.115  0.0385     0.577   0
7  2007   396 0.0859 0.0480     0.447   0.00758
# i 19 more rows
```

➔ 2004년에 성지순례(0.228)가 리플(0.135)을 앞지른다. 2003년 댓글의 10%에는 '헿'이 있다.

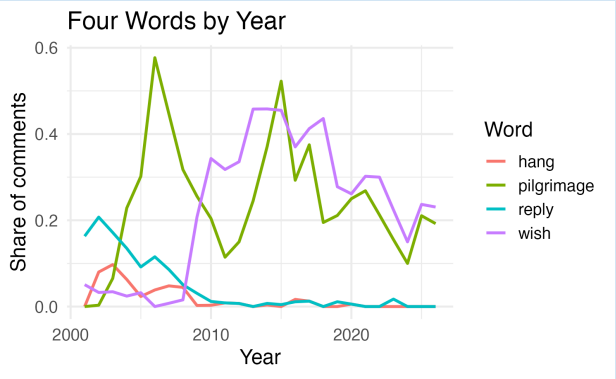
⚠ 2006년의 0.577은 26개 가운데 15개다. **분모가 작으면** 비율이 크게 흔들린다(11강의 '하루가 끌어올린 평균').

한 그림에 넷

```
shares |>
  pivot_longer(reply:wish,
               names_to = "word", values_to = "share") |>
  ggplot(aes(year, share, color = word)) +
    geom_line() +
    labs(
      title = "Four Words by Year",
      x = "Year", y = "Share of comments", color = "Word"
    )
```

- 네 열을 `pivot_longer()`(5강)로 길게 펴야 `color`로 가를 수 있다.
- 범례의 이름은 `labs(color = )`로 붙인다. 범례에 뜨는 값이 열 이름이므로 `reply`, `pilgrimage`처럼 읽을 수 있는 이름을 처음부터 지었다.

네 단어의 흐름



2002–2004년

리플(reply)과 행(hang)의 시기.

2004–2008년

성지순례(pilgrimage)가 앞선다.

2009년부터

소원(wish)이 대세다.

리플·행 → 성지순례 → 소원. 논문이 말한 순서 그대로다.

‘성지순례 왔습니다’는 언제

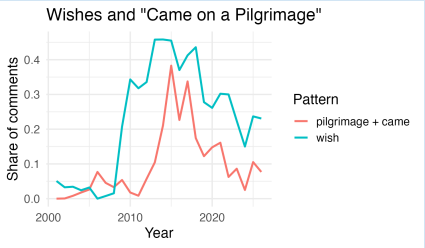
```
cleaned |>
  group_by(year = year(datetime)) |>
  summarize(
    wish = mean(str_detect(
      text, "해 ?주|싶"")),
    came = mean(str_detect(
      text, "성지 ?순례") &
      str_detect(text, "왔"))) |>
  filter(year >= 2009,
         year <= 2018)
```

```
# A tibble: 10 × 3
    year  wish    came
   <dbl> <dbl>   <dbl>
 1  2009 0.207 0.0537
 2  2010 0.343 0.0178
 3  2011 0.318 0.00847
 4  2012 0.336 0.0571
 5  2013 0.458 0.104
 6  2014 0.458 0.211
 7  2015 0.455 0.383
 8  2016 0.370 0.227
 9  2017 0.412 0.338
10  2018 0.436 0.174
```

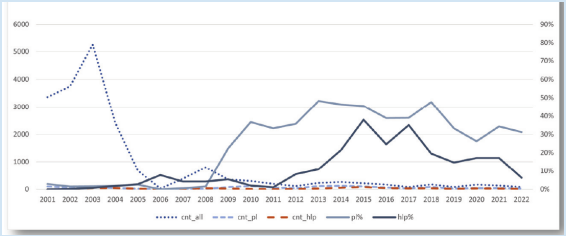
- &는 두 조건이 모두 참일 때 참이다(4강). ‘성지순례’와 ‘왔’이 함께 든 댓글이다.
- 소원은 2009년에 치솟지만, ‘성지순례 왔습니다’가 그 곁까지 오는 것은 **2015년**이다.

논문 그림 10과 나란히

우리 그림 (2001–2026)



논문 그림 10 (304쪽, 오른쪽 축)



➔ 논문의 pl%가 우리의 `wish`, hlp%가 `pilgrimage + came`이다. 2009년에 소원이 치솟고, '성지순례'와 '왔'이 함께 든 댓글은 2015년과 2017년에 봉우리를 이룬다. **모양이 같다**.

❗ 논문의 결론: "성지순례 왔습니다. ◯◯해주세요"의 정식화는 2015년 무렵 완성되었다(304쪽).

규칙이 잡은 엉뚱한 댓글

```
cleaned |>
  filter(year(datetime) == 2001, str_detect(text, "해 ?주|싶")) |>
  select(datetime, text)
```

```
# A tibble: 176 × 2
  datetime            text
  <dttm>              <chr>
1 2001-07-18 12:37:54 저...죄송하지만 어려운 사람 돕는 셈치고. 먹다남은 새우깡…
2 2001-07-18 14:02:43 미치겠네 먹고는 싶은데 파는님이 절대 네고 안하실듯 .....
3 2001-07-18 16:45:34 제가 알기론 매매가격을 중고가로 책정하는 것 보다는 현 시세…
# i 173 more rows
```

⚠ 2001년에도 176개가 걸린다. 대부분 중고 거래 흉내다(“교환했으면 **싶**네요”, “먹고는 **싶**은데”).

➔ 8번째와 11번째 행은 “이용**해주**시기바랍니다”, “축하**해주**세요”다. 논문이 각주 18에서 소원이 아니라고 든 예와 같다. 2001년의 0.05는 이런 잡음이다.

1 논문 읽기

2 댓글을 시계열로

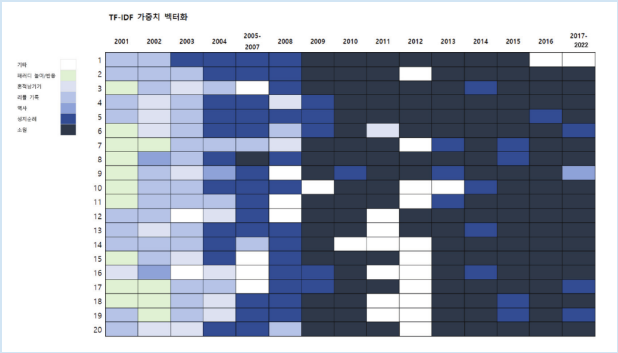
3 단어로 시점 찾기

4 비중의 변화

5 **대표 표현과 해석**
TF-IDF로 본 시기
논문의 결론과 한계

6 마무리

논문의 그림 11



읽는 법 (305쪽)

열은 연도, 행은 TF-IDF 순위 (1–20위), 색은 그 표현이 쓰인 댓글의 유형이다.

유형

연두 패러디, 연한 파랑 흔적·리플 기록·역사, 파랑 성지순례, 남색 소원.

➔ 2001년 패러디 → 2002–2003년 리플 기록·역사 → 2004–2008년 성지순례 → 2009년부터 소원.

시기를 문서로

```
periods <- tribble(
  ~period,      ~start, ~end,
  "2001",       2001,   2001,
  "2002",       2002,   2002,
  "2003",       2003,   2003,
  "2004",       2004,   2004,
  "2005-2010", 2005,   2010,
  "2011-2026", 2011,   2026)
```

논문 표 2의 여섯 시기

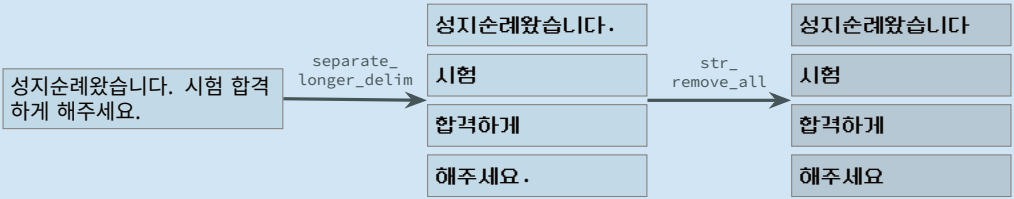
댓글이 적은 해는 묶어 시기마다 2,000개 안팎이 되게 했다(297쪽). 마지막 시기는 2026년까지 늘렸다.

11강의 범위 조인

연도가 `start`와 `end` 사이에 드는 시기를 댓글마다 붙인다(다음 장).

➔ 8강에서는 작가 한 명의 페이지가 문서 하나였다. 오늘은 **한 시기의 댓글**이 문서 하나다.

띄어쓰기로 자르기



어절로 자르기

빈칸마다 잘라 어절 하나가 행 하나가 되게 한다. 논문과 달리 형태소 분석은 하지 않는다.

"[^가-힣]"

대괄호는 '이 가운데 한 글자', ^는 '아닌 것'. 한글(가부터 힣까지)이 아닌 글자를 지운다.

💡 2014년 7월 2일의 실제 댓글이다. '성지순례왔습니다'는 붙여 써서 한 어절이다.

어절 표 만들기

```
tokens <- cleaned |>
  mutate(year = year(datetime)) |>
  inner_join(periods, join_by(between(year, start, end))) |>
  separate_longer_delim(text, delim = " ") |>
  mutate(token = str_remove_all(text, "[^가-힣]")) |>
  filter(str_length(token) >= 2) |>
  distinct(id, period, token)
```

줄	하는 일
`separate_longer_delim()`	빈칸마다 잘라 어절 하나가 행 하나가 되게 편다
`str_length(token) >= 2`	두 글자 이상만 남긴다(논문과 같다)
`distinct(id, period, token)`	한 댓글에서 되풀이한 어절은 한 번만 센다

➔ 결과는 96,464행이다. 한 행이 ‘어느 댓글, 어느 시기, 어떤 어절’이다.

자주 나오는 어절

```
common <- tokens |>
  count(token) |>
  filter(n >= 50)
common |>
  arrange(desc(n))
```

```
# A tibble: 125 × 2
  token        n
  <chr>    <int>
1 성지순례  1369
2 리플       816
3 해주세요   651
4 내가       551
5 나도       474
6 리플이     393
7 이거       360
8 쿠키닷컴   347
# i 117 more rows
```

어휘 줄이기

50개 이상의 댓글에 나온 어절 125개만 남긴다.
논문의 워드 클라우드는 25회 이상이었다.

⚠ '리플'과 '리플이'가 따로 세진다. 형태소 분석을 하지 않은 값이다. '성지순례'와 '성지순례왔습니다'도 다른 어절이다.

시기마다 대표 어절 다섯

```
tokens |>
  semi_join(common, by = "token") |>
  hdir_text_tfidf(doc_var = "period", token_var = "token") |>
  arrange(desc(tfidf)) |>
  group_by(doc_id) |>
  slice(1:5) |>
  summarize(token = paste(token, collapse = "; "))
```

	doc_id	token
	<chr>	<chr>
1	2001	그거; 혹시; 저거; 리플은; 너무
2	2002	그거; 대단하오; 하오; 있소; 싶소
3	2003	대단하오; 하오; 있소; 다녀감; 역사에
4	2004	대단하오; 성지순례하고; 다녀감; 것이오; 압박
5	2005-2010	성지순례왔습니다; 성지순례하고; 성지순례; 다녀감; 로또
6	2011-2026	성지순례왔습니다; 로또; 성지순례; 성지순례하고; 시험

➔ `semi_join()`(9강)으로 125개 어절만 남긴다. 8강의 `doc_id`·`lemma` 자리에 시기와 어절을 넣었다.

읽어 보면

2001년

그거·혹시·저거. “혹시 팔렸나요???” 중고 거래 흉내, 곧 패러디다.

2002–2004년

대단하오·하오·있소·싶소·것이오. 핼자들의 **하오체**다. 다녀감·역사에는 흔적 남기기와 ‘역사의 현장’.

2005년부터

성지순례왔습니다·로또·시험. 성지순례와 소원이다.

- 논문 그림 11의 흐름이 띄어쓰기 단위로도 보인다. 그리고 논문이 따로 짚지 않은 **말투의 변화**가 드러났다. 하오체 어미가 든 댓글은 2001년 0.5%, 2003년 17%, 2007년 0.7%다.
- 문턱 50을 25로 낮추면 한 시기에 몰린 도배 문장과 비속어가 위로 올라온다. 8강에서처럼 **설정을 바꿔 보며 비교**한다.

논문의 답

세 질문에 대한 답

1. ‘성지’라는 규정은 유행의 한복판(2002년 여름)에 아햏햏의 ‘햏자’와 함께 생겼다. 소원 댓글은 그 뒤에 드문드문 나타났다.
2. “성지순례 왔습니다. ◯◯해주세요”가 정형이 된 것은 유행이 끝난 뒤다. 소원은 2009년부터 대세가 되고, 정식화는 2015년 무렵이다.
3. 놀이의 열기가 식은 뒤, 소원을 빌려는 소수만 남아 댓글을 달았다.

저자의 해석

온라인 성지도 오프라인 성지처럼 기억의 공간이자 관광지·놀이터·낙서장이다. 그러나 소원을 들어줄 초자연적 존재에 대한 인식이나 종교적 사유의 흔적은 희박했다.

조심해서 읽을 것

남은 댓글만

지워진 댓글과 그림 댓글은 없다. 같은 게시물도 모은 때(2023년 2월 vs. 2026년 10월)에 따라 자료가 다르다.

작은 분모

2006년은 26개다. 비율이 크게 흔들리는 해는 개수를 함께 본다.

글자 일치의 어림

‘합성지’, ‘사고 싶은데’도 걸린다. 규칙이 고른 댓글을 몇 개라도 직접 읽어 본다.

게시물 하나

쿠키닷컴은 ‘최초의 성지’라는 특별한 자리다. 논문도 4장에서 다른 성지 글들을 따로 살핀다.

❗ 댓글 수의 시계열은 사람들의 마음이 아니라 **남아 있는 댓글**의 지도다. 10강의 “남은 사료의 지도”와 같은 말이다.

재현이 알려 준 것

맞은 것

2001–2013년의 연도별 댓글 수, 첫 나흘의 댓글 수, 첫 ‘성지’·‘성지 순례’·“비나이다”의 날짜, 소원과 ‘성지순례 왔습니다’의 흐름.

다른 것

중복을 거른 2016·2019년의 개수(170 vs. 181, 81 vs. 90). 기준(‘비슷한 시기’)을 정확히 적지 않으면 같은 값을 얻을 수 없다.

자료를 남기는 법

GitHub 저장소는 주인이 지우면 사라진다. Zenodo나 OSF처럼 **DOI**를 주는 연구 자료 보관소는 자료를 오래 보존하기로 약속한다. 모은 방법과 코드도 함께 남긴다.

우리가 다시 모은 자료도 몇 해 뒤에는 달라진다. 수집일(2026년 10월 3일)을 적어 둔 까닭이다.

1 논문 읽기

2 댓글을 시계열로

3 단어로 시점 찾기

4 비중의 변화

5 대표 표현과 해석

6 **마무리**

오늘의 함수

함수	하는 일	패키지
`ymd_hms(tz = )`	글자를 서울 시각으로 읽기	lubridate
`count(새 열 = 식)`	새 열을 만들며 세기	dplyr
`lag()·lead()`	앞뒤 칸으로 이동평균 내기(11강)	dplyr
`str_detect()`	글자가 들어 있는지	stringr
`str_remove_all()·str_length()`	글자 지우기 / 글자 수	stringr
`distinct()`	같은 행은 처음 하나만	dplyr
`n_distinct()`	서로 다른 값의 개수	dplyr
`mean(논리값)`	TRUE의 비율	base R
`separate_longer_delim()`	구분 기호로 잘라 행으로 펴기	tidyr
`geom_vline()`	세로선 긋기	ggplot2

💡 글자 함수는 대부분 `stringr`에 있다. 치트시트 — `https://rstudio.github.io/cheatsheets/strings.pdf`

오늘 배운 것

논문 읽기

- 성지 밈과 소원 댓글
- 세 질문은 모두 ‘언제’를 묻는다

단어와 사건

- `str_detect()`와 ‘합성지’
- 사건 전후는 날 수로 나눈다

시계열 만들기

- 사라진 저장소, 다시 모은 자료
- `ymd_hms(tz = )`, 연·월·주 단위
- 5주 이동평균

비중과 대표 표현

- `distinct()`로 도배 거르기
- 논리값의 평균 = 비율
- 하오체에서 소원으로

확인 질문

스스로 답해 보기

1. `2001.07.17 17:55:57`을 읽을 때 `tz = "Asia/Seoul"`을 주는 까닭은?
2. 댓글이 없는 주가 있으면 5주 이동평균이 왜 틀어지는가?
3. `str_detect(text, "성지")`가 엉뚱한 댓글을 고른 예와 그 까닭은?
4. 사건 전후의 하루 평균을 `count(day)`의 평균으로 내면 왜 틀리는가?
5. 해마다 개수가 아니라 비율을 비교한 까닭은? `mean()`이 비율이 되는 까닭은?
6. 띄어쓰기로 자르면 '리플'과 '리플이'가 따로 세진다. 무엇을 잃는가?

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

다음 시간

- 13강 (2026-11-02 월) — 공간 데이터 (교재 9장)
  - 오늘은 게시물 하나에 쌓인 시간을 따라갔다. 다음에는 **장소**를 다룬다.
  - 10강에서 미뤄 둔 '지도 위에 점 놓기': 좌표를 지도에 찍고, 지역별로 묶어 센다.

더 보고 싶다면

- 심형준·이원섭·오준혁·이유나, 「한국의 온라인 종교문화에 대한 시론적 연구」, 『대순사상논총』 45 (2023), 187–226쪽.
- Wickham, Çetinkaya-Rundel & Grolemund, *R for Data Science* (2판, 2023), 14장 Strings, 15장 Regular expressions — `https://r4ds.hadley.nz/`
- `stringr` 문서 — `https://stringr.tidyverse.org/`