2026학년도 2학기 인문데이터 수량분석

제16강 이미지 데이터 사례 연습

박수민

서울대학교 인문대학 연계전공 인문데이터과학

2026년 11월 11일 수요일

오늘의 목표

1. 논문의 네 특징량이 섬네일의 무엇을 재는지 설명하고, R로 직접 계산해 표의 값과 맞출 수 있다.
2. 회귀표의 계수와 p값을 읽고, '통제'가 무슨 뜻인지 설명할 수 있다.
3. 시기로 나누어 비교해서, 전체 상관이 시기 탓인지 확인할 수 있다.
4. 같은 방법을 새 자료에 쓴 결과를 자료, 측정, 시점의 차이를 고려해 해석할 수 있다.

사전 준비

eTL에서 `yoo2023.zip`을 받아 Posit Cloud의 **Files** 창에서 **Upload**로 올린다 (`yoo2023` 폴더가 생긴다). 새로 설치할 패키지는 없다.

```
1 library(tidyverse)
2 library(hdir)
```

1 **논문 읽기**
연구 질문
회귀표 읽기

2 자료 다시 모으기

3 섬네일 재보기

4 섬네일과 투표수

5 해석과 한계

6 마무리

오늘 읽을 논문

서지 정보

저자 유승희(이화여대), 김호림(동양대), 최진욱(한남대)

제목 한국 웹툰 플랫폼의 섬네일 특징이 웹툰 선택에 미치는 영향: 이미지 분석을 적용하여

학술지 『상품학연구』 41(4), 2023, 17–25쪽

한 문장으로

네이버웹툰 1,953편의 섬네일에서 네 가지 시각적 특징을 재어, 첫 화 투표수와의 관계를 음이항 회귀로 본다.

💡 10강은 논문의 표를 다시 계산했고, 12강은 자료를 다시 모았고, 14강은 본문으로 표를 만들었다. 오늘은 자료를 다시 모아 **그림에서 수를 직접 잰다**.

왜 섬네일인가

저자들의 논리

독자는 섬네일이 펼쳐진 페이지에서 작품을 고르고, 클릭하기 전에 섬네일을 가장 먼저 본다(18쪽). 웹툰의 성공 요인을 다룬 연구는 평점·좋아요·댓글을 보았지 섬네일은 보지 않았다.

연구 문제(18쪽)

1. 웹툰 섬네일은 웹툰의 선택에 영향을 미치는가?
2. 웹툰 섬네일의 어떤 특징이 선택에 영향을 미치는가?

➔ 앞선 연구는 사람(코더)이 그림을 보고 표에 적었다. 이 논문은 **컴퓨터가 픽셀에서 잰다**. 15강의 distant viewing이다.

💡 웹툰 섬네일을 계량적으로 분석한 연구는 드물다. 저자들은 이 빈자리를 채우려 한다.

네 가지 특징량

특징	논문의 설명(21쪽)	오늘 쓰는 열
명도	회색 스케일로 바꾼 뒤 픽셀값의 평균	`brightness`
채도	Hasler & Süsstrunk(2003)의 공식	`colorfulness`
색상 다양성	Ke 외(2006). 20개 색상 중 임곗값을 넘는 색상의 개수	`hue_count`
시각적 복잡성	비슷한 픽셀을 묶어 나눈(segmentation) 부분의 개수	`segments`

- ➔ 모두 Python 라이브러리 Athec(Peng 2022)으로 재고, 평균 0, 표준편차 1로 표준화했다.
- ➔ 선행 연구의 결과는 엇갈린다. 명도와 채도는 플랫폼마다 부호가 다르고, 복잡성은 중간일 때 가장 좋다는 주장(거꾸로 된 U자)도 있다(20–21쪽).
- 💡 3절에서 앞의 셋은 R로 직접 계산한다.

자료와 변수

자료(21쪽)

2023년 1월 30일에 네이버웹툰에서 웹 크롤링한 2,115편. 결측 118편, 24비트가 아닌 섬네일 44편을 빼고 1,953편.

통제변수

전체 평점, 작가의 전작 개수·평점, 연재 누적일, 장르, 완결 여부, 성인 여부, 제목 군집(KoBERT와 K-평균으로 4개).

종속변수: 선택의 대용치

첫 화의 평점 투표수. 작품 내용의 영향을 줄이려고 첫 화를 골랐다.

누적일을 넣은 까닭

투표수는 시간이 지나면 쌓이므로 첫 화 이후 지난 날수를 함께 넣었다.

⚠ 대용치(proxy)는 직접 재기 어려운 것 대신 재는 것이다. 저자들도 투표수를 선택의 대용치라고 밝혔다.

왜 음이항 회귀인가

회귀는 여러 변수를 한꺼번에 넣어 결과를 설명하는 모형

우리는 직접 돌리지 않고 **표를 읽는 법**만 배운다. 3강의 회귀직선을 변수 여럿으로 늘렸다고 생각한다.

세는 값

투표수는 $0, 1, 2, \ldots$로 세는 값이다. 세는 값의 기본 모형은 포아송 회귀인데, **평균과 분산이 같다**고 가정한다.

과대 산포

실제 투표수는 분산이 평균보다 훨씬 크다 (저자들의 점검에서 비율 19,212.7, 22쪽). 그래서 이를 허용하는 음이항 회귀를 골랐다.

➔ 음이항 회귀의 계수는 투표수 자체가 아니라 **투표수의 로그**에 더해지는 값이다. 다음 장에서 읽는다.

논문의 표 3

<표 3> 음이항 회귀분석 결과

변수	계수 값	표준오차	p-value
(Intercept)	8.93	.44	.00
명도	.02	.03	.43
채도	.01	.02	.57
색상 다양성	− .09	.02	.00
시각적 복잡성	.07	.02	.00
전체 평점	− .05	.09	.55
전작 개수 평균	.05	.01	.00
전작 평점 평균	.05	.09	.59
연재 누적일	.00	.00	.00
장르 1	− .05	.07	.50
장르 2	.04	.07	.57
장르 3	− .31	.21	.15
장르 4	.00	.10	.97
장르 5	− .20	.13	.12
장르 6	− .17	.09	.05
장르 7	− .15	.09	.10
장르 8	− .12	.18	.49
장르 9	− .08	.16	.60
완결 여부	.21	.05	.00
성인 웹툰 여부	.00	.13	.99
제목 군집 1	.01	.06	.87
제목 군집 2	.01	.06	.93
제목 군집 3	− .06	.08	.50
AIC		42,067	

읽는 순서

1. 부호: 늘어나는가, 줄어드는가
2. p값: 우연으로 보기 어려운가
3. 크기: 투표수가 얼마나 달라지나

➔ 논문 22쪽. 장르 1–9는 로맨스(0)와, 제목 군집은 군집 0과 비교한 값이다.

계수와 p값

색상 다양성: $-.09$, p $= .00$

- 표준화했으므로 색상 다양성이 **1 표준편차** 오를 때 로그 투표수가 $.09$ 준다.
- $e^{-.09} = .914$. 투표수로는 약 **9% 적다**는 뜻이다.

p값

관계가 전혀 없을 때 이만큼 큰 계수가 우연히 나올 확률. 관례로 $.05$보다 작으면 '통계적으로 유의하다'고 한다. `.00`은 반올림한 값이다(본문은 p $< .001$).

- p값은 관계가 얼마나 큰지 말해 주지 않는다. 자료가 많으면 작은 차이도 유의해진다. 그래서 계수의 크기(위의 약 9%)를 함께 읽는다.
- 연재 누적일의 계수 `.00`은 효과가 없다는 뜻이 아니다. 단위가 **하루**라 작을 뿐이다(p $= .00$).

‘통제’의 뜻

다른 변수를 통제한다

표 3의 $-.09$는 “장르·평점·누적일·...의 값이 **같다고 칠 때**” 색상 다양성만 다른 작품들의 차이다. 실제로 같은 작품을 모아 비교한 것이 아니라, 모형이 그렇게 계산한 값이다.

논문의 결론(22쪽)

명도와 채도는 유의하지 않다. 색상 다양성은 $-$, 시각적 복잡성은 $+$ 방향으로 유의하다.

- 모형은 **넣은 변수만, 넣은 모양대로** 통제한다. 넣지 않은 변수는 통제되지 않고, 누적일을 직선으로 넣으면 직선만큼만 통제된다.
- → 모든 회귀에 해당하는 말이다. 4절에서 우리 자료로 직접 살펴본다.

1 논문 읽기

2 **자료 다시 모으기**
수집
논문과 맞추기

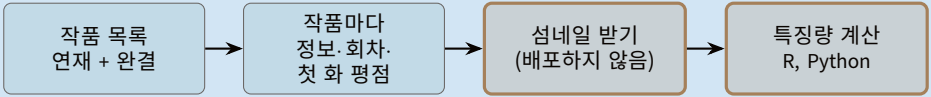
3 섬네일 재보기

4 섬네일과 투표수

5 해석과 한계

6 마무리

같은 플랫폼에서 새로 모으기



2026년 11월 3일의 자료

플랫폼의 값은 날마다 바뀌고 섬네일은 저작물이라 나눌 수 없다. 12강처럼 교수자가 같은 플랫폼에서 새로 모았다. 3,776편에 작품마다 요청 네 번, 요청 사이에 1초씩 쉬면 약 4시간 걸린다.

- ➔ 결과는 표 하나(`webtoon.csv`)다. 수집 스크립트와 정리 과정은 저장소에 남겼다.
- ⚠ 수집을 여러분이 다시 돌리지 않는다. 한 반이 같은 요청을 보내면 서비스에 부담을 준다.

모으기 전에 확인한 것

robots.txt

사이트가 자동 접근에 대해 적어 둔 안내. 네이버웹툰은 /webtoon/detail 등을 금지한다. 우리가 쓴 /api 경로는 적혀 있지 않다.

막지 않았다 ≠ 허락했다

웹툰 본문은 받지 않았지만, 첫 화의 평점은 받았다. 판단이 필요한 회색 지대다. 이용약관도 따로 읽어야 한다.

저작권

섬네일은 작가의 저작물이다. 그래서 **수치와 주소만** 나눠 주고, 슬라이드에는 설명에 꼭 필요한 세 장만 작게 싣는다.

성인 작품

회차 목록이 로그인을 요구한다. 로그인을 흉내 내지 않고 190편을 뺐다(논문에는 포함).

12강의 “자료를 남기는 법”과 15강의 “저작권과 이용 조건”이 여기서 실제 결정이 된다.

오늘의 자료

```
webtoon <- read_csv(file.path("yoo2023", "webtoon.csv"))
webtoon |> select(title, genre, status, first_date, votes, rating)
```

```
# A tibble: 3,776 × 6
  title      genre  status   first_date votes rating
  <chr>      <chr>  <chr>    <date>     <dbl>  <dbl>
1 사랑in     로맨스 finished 2005-12-12   382   9.51
2 골방환상곡 일상   finished 2005-12-12  4631   9.93
3 수사9단    스릴러 finished 2006-01-05  7997   9.90
4 타투       드라마 finished 2006-01-05   658   9.21
# i 3,772 more rows
```

votes 첫 화의 별점 투표수. 논문의 종속변수다.

status finished(완결), ongoing(연재 중), hiatus(휴재).

first_date 첫 화 연재일. 한 행이 한 작품이다.

섬네일에서 잰 열

```
webtoon |>
  select(title, brightness, colorfulness, hue_count, segments, file_kb)
```

```
# A tibble: 3,776 × 6
  title      brightness colorfulness hue_count segments file_kb
  <chr>           <dbl>        <dbl>     <dbl>    <dbl>   <dbl>
1 사랑in           0.72         93.1         2      579    43.3
2 골방환상곡       0.586        15.5         7      488    33.9
3 수사9단          0.676        20.6         3      231    28.3
4 타투             0.628        34.4         2     1245    59.2
# i 3,772 more rows
```

- 앞의 네 수치 열이 논문의 네 특징량이다. `file_kb`는 파일 크기로, 논문에는 없고 3절에서 쓴다.
- `thumb_url`에 섬네일 주소가, `README.txt`에 각 열의 뜻과 만든 방법이 있다.

논문의 시기로 자르기

```
webtoon |> count(status)
```

```
# A tibble: 3 × 2
  status       n
  <chr>    <int>
1 finished  2762
2 hiatus     248
3 ongoing    766
```

```
paper <- webtoon |>
  filter(first_date <=
           ymd("2023-01-30"))
nrow(paper)
```

```
[1] 2092
```

➔ 2023년 1월 30일 뒤에 시작한 작품이 1,684편이나 된다. 논문의 수집일 뒤에 나온 작품이므로 뺀다.

➔ 2,092편은 논문의 2,115편에 가깝다. 성인 작품이 없는데도 비슷한 것은 그동안 서비스에서 내려간 작품, 새로 들어온 작품이 있기 때문으로 보인다(추정).

💡 앞으로 투표수를 보는 곳에서는 paper를 쓴다.

표 1과 비교

```
paper |>
  summarize(mean = mean(votes),
            sd = sd(votes),
            max = max(votes))
```

```
# A tibble: 1 × 3
    mean     sd    max
   <dbl>  <dbl>  <dbl>
1 20967. 23050. 251430
```

	논문	재수집
작품	1,953	2,092
투표수 평균	20,543	20,967
투표수 표준편차	23,207	23,050
투표수 최댓값	248,830	251,430
평점 평균	9.76	9.73
누적일 평균	1,474	3,037
완결 비율	.65	.92

- ➔ 투표수가 놀랍게 비슷하다. 3년 9개월이 지났는데 최댓값이 1%만 늘었다. 첫 화의 표는 대부분 연재 초기에 쌓이는 듯하다(추정).
- ➔ 누적일과 완결 비율은 크게 다르다. 수집일이 달라졌으니 당연하다.

2023년과 2026년 사이에 달라진 것

투표수의 시점

논문은 2023년 1월, 우리는 2026년 11월의 값이다. 표가 더 쌓인 뒤의 수다.

걸려 있는 섬네일

우리가 받은 것은 2026년에 걸려 있는 섬네일이다. 논문이 본 것과 같은지, 처음 연재할 때의 것인지 알 수 없다.

‘완결’의 뜻

92%가 완결된 지금, 남은 연재작은 오래 살아남은 작품들이다. 같은 열이어도 논문에서와 뜻이 다르다.

우리가 뺀 것

성인 작품, 제목 군집, 전작 평점. 측정 설정은 Athec의 기본값을 썼다.

❗ 그러므로 오늘의 작업은 같은 자료로 다시 계산하는 **재현**이 아니다. 같은 방법을 새 자료에 쓰는 **반복 연구**(replication)에 가깝다. 다르게 나오면 시점과 표본의 차이부터 살핀다.

1 논문 읽기

2 자료 다시 모으기

3 **섬네일 재보기**
한 장씩 재기
함수로 묶어 대조하기

4 섬네일과 투표수

5 해석과 한계

6 마무리

세 장을 눈으로







왼쪽부터 임총「공감.jpg」, 9P「ㄹㅇ 관종」, 최규석「송곳」. © 각 작가, 네이버웹툰. 수업 설명을 위해 작게 인용했다.

	공감.jpg	ㄹㅇ 관종	송곳
명도 / 채도	.759 / 115.6	.490 / 91.2	.383 / 0
색상 수 / 조각 수	2 / 258	19 / 700	0 / 420
투표수	251,430	47,031	138,120

➔ 단색 배경, 많은 색, 흑백. 눈으로 본 차이가 수에 나타나는가?

주소로 받기

```
three <- webtoon |>
  filter(title_id %in% c(686911, 710764, 602922)) |>
  mutate(name = c("Songgot", "Gonggam.jpg", "RL Gwanjong"),
         path = file.path("yoo2023", "thumbs",
                          paste0(title_id, ".jpg")))
dir.create(file.path("yoo2023", "thumbs"))
walk2(three$thumb_url, three$path, download.file, mode = "wb")
```

- ➔ name: 그림에 쓸 영어 이름. 표가 첫 연재일 순이라 송곳이 먼저다.
- ➔ download.file(**주소, 저장할 곳**): 인터넷의 파일을 내 폴더로 받는다. mode = "wb"는 그림 파일을 깨뜨리지 않고 받으라는 뜻이다.
- ➔ walk2(): map2()와 같되 결과를 모으지 않는다. 파일 받기처럼 할 일만 있을 때 쓴다.
- ⚠ 이 세 장만 받는다. 받은 파일을 다시 올리거나 나누지 않는다.

표로 펴기

```
px <- hdir_pixels_long(three$path[2], three$name[2])
px |> select(row, col, red, green, blue, hue, saturation, value)
```

```
# A tibble: 299,040 × 8
    row   col   red green  blue   hue saturation value
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>      <dbl> <dbl>
1     1     1 0.714 0.906 0.110 0.207      0.879 0.906
2     2     1 0.714 0.906 0.110 0.207      0.879 0.906
3     3     1 0.714 0.906 0.110 0.207      0.879 0.906
4     4     1 0.714 0.906 0.110 0.207      0.879 0.906
# i 299,036 more rows
```

- 15강에서 배운 표다. 세로 623 $\times$ 가로 480 $=$ 299,040픽셀, 곧 299,040행이다.
- 공감.jpg의 왼쪽 위 픽셀은 연두색이다(hue $= 0.207$). 이제 `summarize()` 한 번이 특징량 하나다.

명도: 회색으로 바꾼 평균

```
px |>
  summarize(brightness =
    mean(0.299 * red + 0.587 * green + 0.114 * blue))
```

```
# A tibble: 1 × 1
  brightness
       <dbl>
1      0.759
```

➔ 세 채널의 가중 평균이 회색 값이다. 사람 눈이 초록에 가장 민감해서 초록의 비중이 가장 크다.

➔ HSV의 value(15강)와 다르다. value는 셋 중 가장 큰 값이라, 순수한 파랑도 1이다.

❗ 표의 brightness와 소수 셋째 자리까지 같다. 공식을 알면 그림 한 장의 측정은 코드 세 줄이다.

채도: colorfulness 공식

```
px |>
  mutate(rg = 255 * (red - green),
         yb = 255 * ((red + green) / 2 - blue)) |>
  summarize(colorfulness = sqrt(var(rg) + var(yb)) +
                           0.3 * sqrt(mean(rg)^2 + mean(yb)^2))
```

```
# A tibble: 1 × 1
  colorfulness
         <dbl>
1         116.
```

➔ rg: 빨강과 초록의 차이, yb: 노랑과 파랑의 차이. 회색 픽셀은 둘 다 0이다. 차이가 크게 퍼질수록, 평균이 0에서 멀수록 값이 커진다.

💡 논문이 채도를 재는 데 쓴 공식이다(21쪽). 15강의 HSV 채도와는 다른 척도다(전체 순위 상관 .72). 같은 말도 **어떤 공식인지** 확인하며 읽는다.

색상 다양성: 20칸 세기

```
hues <- px |>
  filter(saturation >= 0.2, value >= 0.15, value <= 0.95) |>
  count(bin = floor(hue * 20))
hues |> summarize(hue_count = sum(n > 0.05 * max(n)))
```

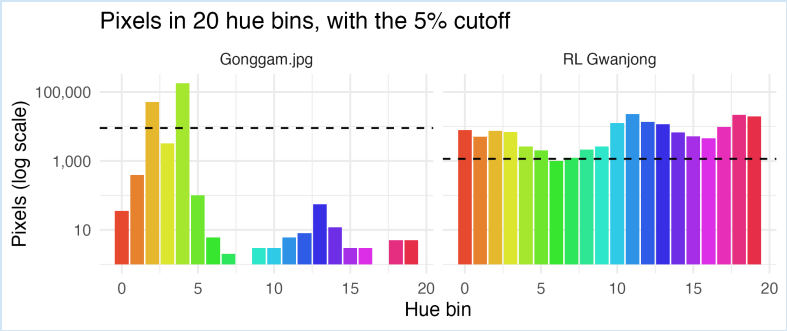
```
# A tibble: 1 × 1
  hue_count
      <int>
1         2
```

1. 색이 뚜렷한 픽셀만 남긴다. 회색에 가깝거나 너무 어둡거나 너무 밝으면 색상을 믿기 어렵다.
2. 15강의 `floor(hue * 12)` 처럼 색상을 구간으로 나눈다. 오늘은 20칸이다.
3. 가장 많은 칸의 5%를 넘는 칸만 센다.

같은 틀로 두 장 그리기

```
hue_one <- function(path, name) {
  hdir_pixels_long(path, name) |>
    filter(saturation >= 0.2, value >= 0.15, value <= 0.95) |>
    count(filename, bin = floor(hue * 20)) |>
    mutate(cutoff = 0.05 * max(n))
}
bins <- map2(three$path[2:3], three$name[2:3], hue_one) |>
  list_rbind()
bins |>
  ggplot(aes(bin, n)) +
    geom_col(aes(fill = hsv((bin + 0.5) / 20, 0.8, 0.9))) +
    geom_hline(aes(yintercept = cutoff), linetype = "dashed") +
    scale_fill_identity() +
    scale_y_log10(labels = scales::comma) +
    facet_wrap(~ filename) +
    labs(title = "Pixels in 20 hue bins, with the 5% cutoff",
         x = "Hue bin", y = "Pixels (log scale)")
```

점선 위의 막대만 센다



- 공감.jpg는 180,088픽셀의 4번 칸, 51,590픽셀의 2번 칸만 넘는다. 3번 칸(3,214)은 문턱(9,004)에 못 미친다.
- ㄹㅇ 관종은 19칸을 고르게 쓴다. 색 값이 많다기보다 **넓게 쓴 색이 많다**는 뜻이다.
- 20칸, 5%, 0.2, 0.15는 모두 사람이 정한 값이다. 15강의 "12칸도 우리의 선택"과 같다.

시각적 복잡성: 조각으로 나누기



- quickshift 알고리즘이 색과 위치가 비슷한 픽셀을 한 조각으로 묶는다. 조각 수가 `segments`다. FSA-OWI 사진에 같은 설정을 쓴 예.
- 하늘은 큰 조각 몇 개, 수레바퀴는 잘게 나뉜다. 바탕을 비워 두면 조각이 적고, 채우면 많다.
- R에 간편한 함수가 없어 Python(Athec, scikit-image)으로 미리 계산했다. 한 장에 약 5초씩 걸린다.

복잡성의 다른 대용치: 파일 크기

```
file.size(three$path) / 1024
```

```
[1] 53.01758 28.55078 45.64062
```

```
cor(paper$segments,
    paper$file_kb)
```

```
[1] 0.2289316
```

왜 파일 크기인가

JPEG는 단순한 그림을 작게 압축한다. 그래서 파일 크기도 복잡성의 지표로 쓰인다(Athec 문서). 코드 한 줄이면 되고, 표의 값과 같다.

⚠ 그런데 분할 조각 수와의 상관은 .23뿐이다. 파일 크기는 그림 말고 **저장 방식**도 잰다. 2021년 11월 무렵 시작한 작품에 유독 큰 파일이 몰려 있는데(최대 398 KB), 그림보다 그때의 저장 방식 때문으로 보인다(추정).

➔ 같은 '복잡성'이라는 이름으로 다른 것을 잰다. 4절의 회귀표에서 차이가 드러난다.

한 함수로

```
feature_one <- function(path, name) {
  px <- hdir_pixels_long(path, name)
  hues <- px |>
    filter(saturation >= 0.2, value >= 0.15, value <= 0.95) |>
    count(bin = floor(hue * 20))
  px |>
    mutate(rg = 255 * (red - green),
           yb = 255 * ((red + green) / 2 - blue)) |>
    summarize(
      name = first(filename),
      brightness = mean(0.299 * red + 0.587 * green + 0.114 * blue),
      colorfulness = sqrt(var(rg) + var(yb)) +
        0.3 * sqrt(mean(rg)^2 + mean(yb)^2),
      hue_count = sum(hues$n > 0.05 * max(hues$n))
    )
}
```

15강의 color_one과 같은 틀이다. 지금까지의 코드를 그대로 옮겨 담았다.

표의 값과 대조

```
1 map2(three$path, three$name, feature_one) |> list_rbind()
2 three |> select(name, brightness, colorfulness, hue_count)
```

name	brightness	colorfulness
<chr>	<dbl>	<dbl>
1 Songgot	0.383	0
2 Gonggam.jpg	0.759	116.
3 RL Gwanjong	0.490	91.2

name	brightness	colorfulness
<chr>	<dbl>	<dbl>
1 Songgot	0.383	0
2 Gonggam.jpg	0.759	116.
3 RL Gwanjong	0.490	91.2

- ➔ 왼쪽이 방금 계산, 오른쪽이 표의 값이다(hue_count 0, 2, 19도 같다).
- ➔ 송곳은 경고가 하나 뜬다. 남은 픽셀이 없어 max() 가 빈 값을 받는다. 결과 0은 맞다.
- ❗ 표를 만든 쪽의 검증: 200장을 Athec과 대조해 명도 $r = 1.000$, 채도 $r = .9999$, 색상수 $r = .99$를 얻었다.

1 논문 읽기

2 자료 다시 모으기

3 섬네일 재보기

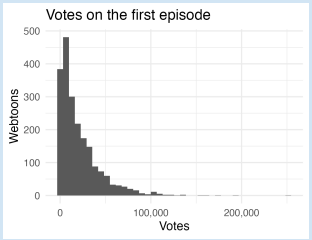
4 **섬네일과 투표수**
전체를 보기
시기로 나누기

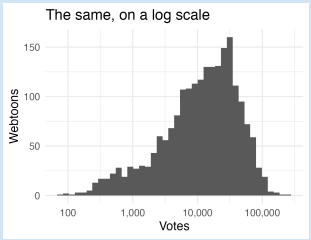
5 해석과 한계

6 마무리

투표수의 모양

```
paper |>
  ggplot(aes(votes)) +
    geom_histogram(bins = 40) +
    scale_x_log10(labels = scales::comma) +
    labs(title = "The same, on a log scale",
         x = "Votes", y = "Webtoons")
```





➔ 왼쪽은 `scale_x_log10()` 대신 `scale_x_continuous(labels = scales::comma)`를 썼다. `scales::comma`는 수에 쉼표를 찍는다.

평균, 중앙값, 분산

```
paper |> summarize(mean = mean(votes), median = median(votes),
                   variance = var(votes))
```

```
# A tibble: 1 × 3
    mean median   variance
   <dbl>  <dbl>      <dbl>
1 20967.  13493 531317062.
```

➔ 오른쪽 꼬리가 길어 평균(20,967)이 중앙값(13,493)보다 훨씬 크다. 그래서 집단을 비교할 때 **중앙값**을 쓴다.

➔ 분산은 평균의 약 25,000배다. 포아송 회귀가 가정하는 '평균 = 분산'과 거리가 멀다. 논문의 과대 산포가 바로 이것이다.

💡 로그 척도로 보면 대략 종 모양이다. 그래서 오늘의 그림에서는 투표수를 로그 축에 놓는다.

cor(): 표 2 다시 계산하기

```
paper |>
  mutate(days = as.numeric(ymd("2026-11-03") - first_date),
         finished = status == "finished") |>
  select(votes, brightness, colorfulness, hue_count, segments,
         rating, works, days, finished) |>
  cor() |>
  round(2)
```

상관계수

두 변수가 함께 움직이는 정도를 -1에서 1 사이의 수로 나타낸 값(3강). 직선 관계만 잰다. `cor()`에 표를 주면 모든 쌍의 상관을 행렬로 돌려준다.

➔ 결과의 `votes` 열만 다음 장의 표로 옮겼다. `TRUE`/`FALSE`는 1/0으로 계산된다.

표 2와 나란히

투표수와의 상관	논문	재수집
명도	.04	.07
채도	.01	−.03
색상 다양성	−.13	−.11
시각적 복잡성	.00	−.01
전체 평점	−.03	.01
작가 작품 수	.22	.05
연재 누적일	.41	.27
완결 여부	.26	−.05

닮은 곳

네 특징량은 거의 같다. 3년 9개월 뒤, 다른 표본, 지금의 섬네일인데도 색상 다양성의 상관이 −.11이다.

다른 곳

완결은 부호가 다르다. 수집 시점이 달라 열의 뜻이 달라진 듯하다. 지금 연재 중인 작품은 오래 이어진 작품이고, 투표수 중앙값이 21,343이다(완결 13,141).

복잡성은 상관이 .00인데 표 3의 계수는 +.07이다. 다른 변수를 함께 넣으면 값이 달라질 수 있다.

가장 많은 표를 받은 작품

```
paper |>
  arrange(desc(votes)) |>
  select(title, votes, hue_count, brightness)
```

```
# A tibble: 2,092 × 4
  title          votes hue_count brightness
  <chr>          <dbl>     <dbl>      <dbl>
1 공감.jpg      251430         2      0.759
2 오빠 왔다     190220         2      0.754
3 연애혁명      175212         4      0.645
4 호랑이형님    158646         6      0.595
5 외모지상주의  156312         6      0.344
# i 2,087 more rows
```

➔ 전체 평균 색상 수는 6이다. 위의 다섯은 모두 6 이하다. 색을 적게 쓰면 인기가 많다?

⚠ 다섯 작품으로는 아무 말도 할 수 없다. 2,092편을 집단으로 나누어 본다.

색상 수로 나누어 비교

```
paper <- paper |>
  mutate(hue_group = cut(hue_count, breaks = c(-1, 3, 6, 9, 20),
                         labels = c("0-3", "4-6", "7-9", "10+")))
paper |>
  group_by(hue_group) |>
  summarize(n = n(), median_votes = median(votes))
```

	hue_group	n	median_votes
	<fct>	<int>	<dbl>
1	0-3	475	17410
2	4-6	785	14175
3	7-9	522	12030.
4	10+	310	9687

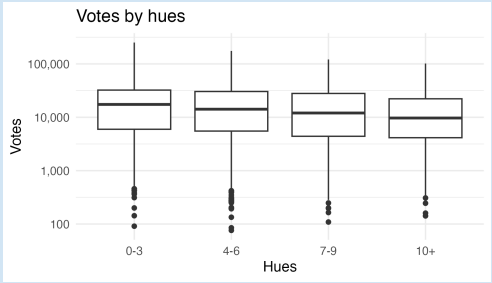
뚜렷한 계단

색상 수가 늘수록 중앙값이 줄어 17,410에서 9,687까지 내려간다. 논문의 −.09와 같은 방향이다.

➔ `cut()`(14강)으로 수를 구간으로 나눈다. `-1`부터 시작해야 0이 첫 구간에 든다.

상자로 보면

```
paper |>
  ggplot(aes(hue_group, votes)) +
    geom_boxplot() +
    scale_y_log10(
      labels = scales::comma) +
    labs(title = "Votes by hues",
         x = "Hues", y = "Votes")
```



➔ 상자의 굵은 선이 중앙값이다. 계단은 있지만, 상자끼리 크게 겹친다. 네 집단의 차이는 집단 안의 차이보다 훨씬 작다.

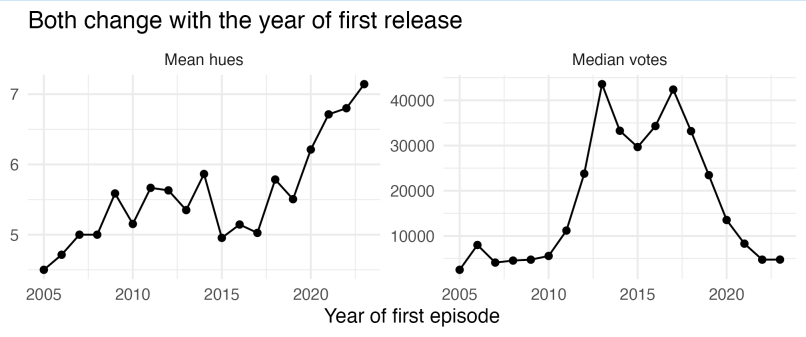
❗ 여기까지는 논문과 같다. 우리 자료에서 시기를 나누어 더 살펴본다.

첫 연재 연도별로

```
by_year <- paper |>
  group_by(year = year(first_date)) |>
  summarize(`Median votes` = median(votes),
            `Mean hues` = mean(hue_count))
by_year |>
  pivot_longer(-year, names_to = "measure") |>
  ggplot(aes(year, value)) +
    geom_line() +
    geom_point() +
    facet_wrap(~ measure, scales = "free_y") +
    labs(title = "Both change with the year of first release",
         x = "Year of first episode", y = NULL)
```

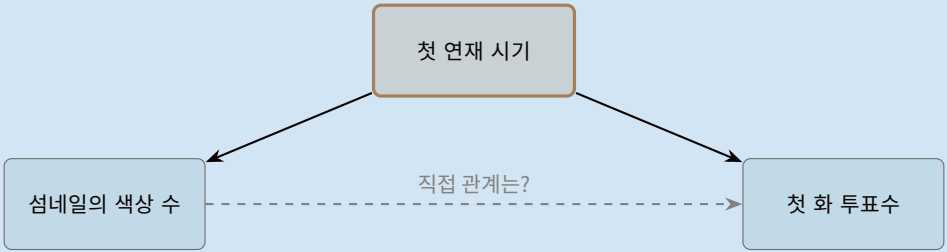
➔ 단위가 다른 두 값을 한 축에 놓지 않는다. `facet_wrap(scales = "free_y")`로 칸마다 축을 따로 준다.

시기가 둘 다 움직인다



- ➔ 투표수의 중앙값은 2013–2018년에 산을 이루고, 그 뒤 빠르게 내려간다. 2022년에는 420편이 시작했다(2013년 80편).
- ➔ 색상 수는 2020년 무렵부터 올라간다. **최근 작품일수록 색이 많고 표가 적다.**
- ⚠ 우리 자료의 투표수는 산 모양이다. **직선** 하나로는 이 모양을 다 담기 어렵다.

제3의 변수



혼입(confounding)

시기가 색상 수와 투표수를 함께 움직이면, 둘 사이에 직접 관계가 없어도 전체 상관은 음수로 나온다.

➔ 확인하는 법: 시기가 비슷한 작품끼리 나누어 비교한다. '통제'를 눈으로 하는 셈이다.

시기별로 다시 재기

```
paper <- paper |>
  mutate(era = cut(year(first_date),
                   breaks = c(2004, 2012, 2016, 2019, 2021, 2023),
                   labels = c("2005-12", "2013-16", "2017-19",
                              "2020-21", "2022-23")))
paper |>
  group_by(era) |>
  summarize(n = n(), median_votes = median(votes),
            mean_hues = mean(hue_count),
            r = cor(hue_count, log10(votes)))
```

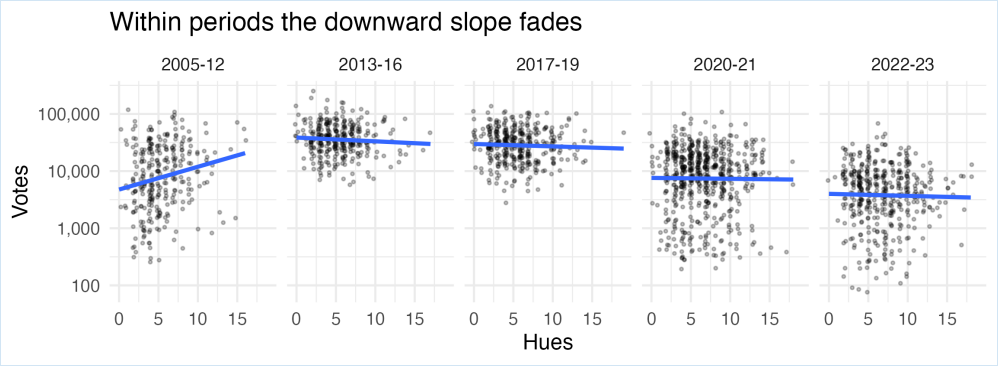
```
  era         n median_votes mean_hues        r
  <fct>   <int>        <dbl>     <dbl>    <dbl>
1 2005-12   300         8125      5.39  0.196
2 2013-16   332        35568      5.32 -0.0674
3 2017-19   386        29948      5.49 -0.0452
4 2020-21   626         9632.     6.51 -0.00955
5 2022-23   448         4749      6.82 -0.0226
```

시기마다 한 칸

```
paper |>
  ggplot(aes(hue_count, votes)) +
    geom_jitter(alpha = 0.25, size = 0.7, width = 0.25) +
    geom_smooth(method = "lm", se = FALSE) +
    scale_y_log10(labels = scales::comma) +
    facet_wrap(~ era, nrow = 1) +
    labs(title = "Within periods the downward slope fades",
         x = "Hues", y = "Votes")
```

- `geom_jitter()`: 색상 수는 정수라 점이 겹친다. 점을 옆으로 조금 흩뜨린다.
- `geom_smooth(method = "lm")`: 칸마다 직선을 하나씩 긋는다(3강의 회귀직선).

시기 안에서는 기울기가 옅어진다



➔ 전체 상관은 −.09인데(로그 투표수), 2013년 이후 네 시기 안에서는 −.07에서 −.01 사이다. 2005–12년은 오히려 +.20이다.

❗ 우리 자료에서는 음의 관계 가운데 상당 부분이 **시기 사이의 차이**다.

같은 틀을 우리 자료에(교수자가 돌린 결과)

	논문 표 3	재수집, 같은 틀	재수집, 시기 구간
명도	.02 (.43)	.05 (.054)	.02 (.40)
채도	.01 (.57)	−.03 (.25)	.02 (.32)
색상 다양성	**−.09** (.00)	**−.09** (<.001)	**−.04** (.067)
시각적 복잡성	**.07** (.00)	**.01** (.84)	**.05** (.012)
완결 여부	.21 (.00)	−.47 (<.001)	−.58 (<.001)
시기 통제	누적일 직선	누적일 직선	다섯 구간
작품 수 / AIC	1,953 / 42,067	2,092 / 45,493	2,092 / 44,780

- ➔ 괄호는 p값. 평점, 작품 수, 장르도 넣었다. AIC는 같은 자료끼리 비교하며 낮을수록 좋다.
- ✓ 3년 9개월 뒤의 자료에서도 부호가 논문과 같다. 명도와 채도는 유의하지 않고, 색상은 −, 복잡성은 +다.
- ➔ 계수의 크기와 유의성은 시기를 넣는 방법에 달려 있다. 구간을 넣으면 색상은 줄고 복잡성은 유의해진다(연도별 구간, 2차식도 같다).

측정을 바꾸어도

복잡성을 무엇으로 재는가	누적일 직선	시기 구간
조각 수(segments)	.01 (.84)	+.05 (.012)
파일 크기(file_kb)	−.11 (<.001)	−.05 (.011)

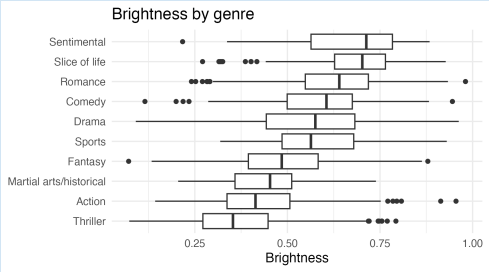
같은 이름, 반대 부호

"복잡한 섬네일이 표를 더 받는가?"의 답이 재는 방법에 따라 달라진다. 파일 크기는 저장 방식도 함께 재므로, 그림의 내용에는 논문의 조각 수가 더 직접적이다.

- ➔ 오늘 본 두 갈래의 선택: 무엇으로 잴 것인가(측정), 무엇을 어떤 모양으로 통제할 것인가(모형).
- ❗ 선택에 따라 결과가 달라질 수 있으니, 결과를 말할 때 **그 선택을 함께 적는다**.

투표수 말고 물을 수 있는 것

```
webtoon |>
  ggplot(aes(brightness,
    fct_reorder(genre_en,
                brightness))) +
    geom_boxplot() +
    labs(title =
      "Brightness by genre",
      x = "Brightness", y = NULL)
```



- 스릴러(평균 .37)는 어둡고 일상(.68)·로맨스(.63)는 밝다. 장르가 섬네일의 시각 언어를 만든다.
- 인문학의 질문은 “표를 더 받는가”만이 아니다. 장르의 관습은 언제 생겼고, 어떻게 달라졌나? `fct_reorder()`는 값의 크기 순으로 범주를 늘어놓는다.

1 논문 읽기

2 자료 다시 모으기

3 섬네일 재보기

4 섬네일과 투표수

5 **해석과 한계**
논문의 해석
우리 작업의 한계

6 마무리

저자들의 해석(23쪽)

색상 다양성

전문가는 색상 수를 제한한다는 선행 연구를 이어, 낮은 색상 다양성을 전문가적 미적 특징으로 해석한다.

기여

섬네일을 계량적으로 분석해 웹툰 연구의 방법을 넓혔다. 인간 코더의 주관적 판단을 보완하는 길이다.

시각적 복잡성

복잡한 섬네일이 정보를 전하고 각성 수준을 높여 선택을 이끌 수 있다고 본다.

저자들이 밝힌 한계

한 플랫폼의 자료, 변수 간 상호작용, 화면 노출의 통제. 각각 후속 연구를 제안했다.

❗ 논문은 결과만이 아니라 **해석과 한계**까지 함께 읽는다.

관찰 자료로 말할 수 있는 것

회귀표의 계수

표에 넣은 변수의 값이 같다고 칠 때의 **통계적 관련**이다. 관찰 자료의 회귀에 두루 해당한다.

대용치의 성격

첫 화의 별점은 1화를 읽고 별점을 누른 독자의 수다. 플랫폼에서 얻을 수 있는 가장 가까운 값 가운데 하나다.

노출

첫 화면의 정렬은 선택에 중요하다. 저자들도 이 자료를 구하면 더 정확히 볼 수 있다고 했다(23쪽).

다음 단계

섬네일을 무작위로 바꾸어 보이는 실험이 가능하다면 인과에 더 다가갈 수 있다.

관련과 인과를 구별하는 것은 어느 관찰 연구를 읽을 때나 필요하다.

실무적 함의를 읽는 법

논문의 실무적 함의(23쪽)

"웹툰의 섬네일을 작업할 때 많은 색상을 쓰지 않고, 섬네일 내에 비워진 공간을 두는 것보다는 다양한 부분으로 채워 시각적으로 복잡하게 만드는 것이 오히려 긍정적인 효과를 볼 수 있다."

크기와 함께

1 표준편차(색상 약 3칸)에 약 9%다. 작품 간의 차이(표준편차 23,050표)와 나란히 놓고 읽는다.

평균과 개별 작품

경향은 평균의 이야기다. 1위 공감.jpg는 색상 2칸, 조각 258개다. 작품마다 사정이 다르다.

➔ 우리 자료에서도 방향은 같았다(색상 $-$, 복잡성 $+$). 계수의 크기는 시기를 다루는 방법에 따라 달라졌다.

우리 작업의 한계

지금 남아 있는 작품만

서비스에서 내려간 작품은 표에 없다. 살아남은 것만 보는 생존 편향이다.

지금의 섬네일

인기를 얻은 뒤 새로 그린 섬네일이라면, 투표수가 섬네일을 바꾼 셈이다. 우리는 구별할 수 없다.

구간도 우리의 선택

다섯 구간은 그림을 보고 정했다. 연도별 구간이나 2차식으로도 같은 방향이었지만, 시기 안의 차이는 여전히 남는다.

논문의 자료와는 다르다

오늘의 수는 2026년 자료의 것이다. 2023년 자료에 시기 구간을 넣으면 어떨지는 이 작업으로 알 수 없다.

오늘의 작업은 논문을 판정하는 것이 아니다. 우리 자료에서 **시기를 다루는 방법이 계수의 크기를 바꾼다**는 것을 배웠다.

이미지 표 앞에서 물을 것

수치를 믿기 전에

1. 이 열은 어떤 공식으로 계산했는가? (colorfulness와 HSV 채도)
2. 누가 정한 문턱과 구간인가? (20칸, 5%, 다섯 시기)
3. 다른 대용치로 재면 같은 답이 나오는가? (조각 수와 파일 크기)
4. 언제의 값인가? 그림과 수의 시점이 같은가? (2023년, 2026년, 지금의 섬네일)
5. 시간에 따라 함께 움직이는 변수는 없는가? (색상 수와 투표수)
6. 표에 없는 것은 무엇인가? (성인 작품, 내려간 작품, 노출)

15강의 “몇 장은 반드시 가까이서”에 하나를 더한다. 집단을 **나누어서도** 본다.

1 논문 읽기

2 자료 다시 모으기

3 섬네일 재보기

4 섬네일과 투표수

5 해석과 한계

6 **마무리**

오늘의 함수

함수	하는 일	패키지
`download.file(url, path, mode = "wb")`	인터넷의 파일을 내 폴더로	base R
`walk2()`	한 쌍씩 함수에 넣고 결과는 버리기	purrr
`hdir_pixels_long()`	사진을 픽셀 표로(15강)	hdir
`count(bin = floor(hue * 20))`	만든 구간으로 바로 세기	dplyr
`cor()`	상관계수(표를 주면 행렬)	base R
`cut(breaks, labels)`	수를 구간으로(14강)	base R
`file.size()`	파일 크기(바이트)	base R
`geom_hline(aes(yintercept = ...))`	칸마다 다른 가로선	ggplot2
`scale_fill_identity()`	열의 색 값을 그대로 칠하기	ggplot2
`scales::comma`	축의 수에 쉼표 찍기	scales
`fct_reorder()`	값의 크기 순으로 범주 늘어놓기	forcats

💡 Athec 문서 — `https://github.com/yilangpeng/computational-aesthetics`

오늘 배운 것

회귀표 읽기

- 부호, p값, 계수의 크기 순으로
- $e^{-.09} = .914$: 약 9% 적다
- 통제는 넣은 모양대로만

그림에서 수로

- 공식을 알면 `summarize()` 한 번
- 채도는 colorfulness 공식으로
- 20칸, 5%는 사람의 선택

나누어 보기

- 색상 수의 계단은 상당 부분 시기의 차이
- 시기 안에서는 옅어진다
- 측정을 바꾸면 부호도 바뀐다

반복 연구의 태도

- 시점과 표본의 차이를 먼저 적는다
- 측정과 모형의 선택을 적는다
- 관련과 인과를 구별한다

확인 질문

스스로 답해 보기

1. 표준화한 변수의 계수가 $-.09$이면 투표수는 몇 % 달라지는가? 무엇이 1만큼 오를 때인가?
2. 표 3의 연재 누적일 계수 `.00`은 왜 관계가 없다는 뜻이 아닌가?
3. 공감.jpg의 3번 칸(3,214픽셀)이 색상 수에 들어가지 않은 까닭은?
4. 흑백 섬네일의 `hue_count`가 0인 까닭을 코드의 어느 줄로 설명하는가?
5. 전체 상관이 $-.09$인데 시기 안에서 거의 0이다. 이 차이를 어떻게 설명하는가?
6. 2026년에 받은 섬네일과 투표수로 "섬네일이 투표수에 영향을 미쳤다"고 말하기 어려운 까닭을 둘 들어 보라.

💡 답이 막히는 항목이 있으면 eTL Q&A 게시판에 질문을 올린다 (참여 점수 1점).

[숙제06] 논문 발제 및 튜토리얼 (15점)

- 조별로 논문 한 편을 읽고, 분석의 일부를 R로 다시 해 본 뒤 발표한다(40분).
- 제출: `hw06-group1.Rmd`와 발표 자료 `hw06-group1.pdf`(1은 조 번호)
- 제출 기한: **발표 당일 오전 9시** eTL. 연장은 없다.
- 조 편성과 자세한 안내는 eTL 공지 참조.

❗ Knit이 오류 없이 되는지 반드시 확인하고 제출할 것!

조	발표일	논문	이어지는 강의
1조	11/25(수)	김미혜 (2023)	11–12강 시계열
2조	11/30(월)	최유식 (2023)	13–14강 공간, 8강 텍스트
3조	12/02(수)	이재연 (2014)	9–10강 네트워크

💡 오늘처럼 수치가 논문과 달라도 감점하지 않는다. 왜 다른지 설명하는 것이 과제의 일부다.

다음 시간

- 기말고사 (2026-11-16 월) — 범위: 9–16강
- 인문데이터과학 특강 (2026-11-18 수)
- 논문 발제 (11-25 수, 11-30 월, 12-02 수) — [숙제06]

더 보고 싶다면

- Peng, “Athec: A Python Library for Computational Aesthetic Analysis of Visual Media in Social Science Research,” *Computational Communication Research* 4(1) (2022) — 오늘의 특징량
- Hasler & Süsstrunk, “Measuring Colorfulness in Natural Images,” *Human Vision and Electronic Imaging VIII* (2003)
- Koh & Cui, “An Exploration of the Relation between the Visual Attributes of Thumbnails and the View-through of Videos,” *Decision Support Systems* 160 (2022)